

人工智能与循环神经网络 (RNN) 综合全题库

一、选择题

1. 下列哪个不属于 NLP 的应用？

- A. 机器翻译
- B. 信息检索
- C. 智能客服
- D. 图像分割

答案：D

解析：图像分割属于计算机视觉领域，而自然语言处理的应用包括机器翻译、文本分类、信息检索、智能客服等。

2. “我爱上海的交通大学，不爱上海的交通”体现语言的哪个特点？

- A. 离散性
- B. 上下文相关性
- C. 可微性
- D. 平稳性

答案：B

解析：由于同一个词在不同语境下含义不同，如 PPT 中举例“我爱上海的交通大学，不爱上海的交通”，这体现了语言的上下文相关性。

3. 数据质量提升的直接收益不包括：

- A. 节约算力
- B. 增加模型稳定性
- C. 减少错误信息
- D. 保证 100% 无偏见

答案：D

解析：数据质量的提升可以节约算力、增加模型稳定性并减少错误信

息。虽然可以防止模型学习偏见，但无法保证 100% 无偏见。

4. 去重可以在哪些粒度进行？

- A. 只能句子级
- B. 只能文档级
- C. 句子/文档/数据集级都可以
- D. 只能 token 级

答案： C

解析：数据去重可以在句子级别、文档级别和数据集级别等多种粒度上进行。

5. 词元化的主要目的更贴近：

- A. 把文本变成可处理的符号单元序列
- B. 把文本直接变成图像文件
- C. 把所有单词都替换为单个 UNK 词元
- D. 把句子强制切成等长

答案： A

解析：词元化的核心就是将属于同一个语义或语法单元的字符聚合在一起，以便转换为可处理的单元序列。

6. BPE 每轮迭代选择合并的依据是：

- A. 最罕见的相邻词元对
- B. 最频繁共现的相邻词元对
- C. 随机选择
- D. 人工指定

答案： B

解析：BPE 算法通过计算两个连续词元的共现频率，每次迭代合并语料库中最频繁出现的一对词元。

7. “Next Token Prediction” 更准确的描述是：

- A. 预测第一个 token
- B. 预测最后一个 token
- C. 预测序列中每个位置的下一个 token
- D. 预测句子长度

答案： C

解析：在 Next Token Prediction 框架中，输出序列的每一个 token 即为输入序列的下一个 token。

8. Next Token Prediction 常用的损失函数是：

- A. MSE
- B. 交叉熵
- C. Hinge Loss
- D. Dice Loss

答案： B

解析：对于 Next Token Prediction 任务，通常通过计算预测概率与真实标签之间的交叉熵损失来进行优化。

9. 机器翻译任务“输入输出不等长”常用的 RNN 架构是：

- A. MLP
- B. Encoder-Decoder
- C. AutoEncoder
- D. GAN

答案： B

解析：Encoder-Decoder 架构的循环神经网络常用于处理诸如机器翻译这类输入和输出序列不等长的任务。

10. 在 RNN 中，BPTT 的含义最贴近：

- A. 只在一个时间步反传
- B. 在时间维展开后做反向传播
- C. 只更新输入层参数

- D. 只更新输出层参数

答案： B

解析： BPTT (BackPropagation Through Time) 即随时间反向传播，它在时间维度上展开计算，梯度会经过多个时间步进行链式反传。

11. 普通 RNN 更容易出现的问题是：

- A. 梯度消失/爆炸
- B. 过拟合一定发生
- C. 无法处理语言序列
- D. 无法做分类

答案： A

解析： 普通 RNN 在 BPTT 训练时，梯度要经过多个时间步的链式计算，由于权重的不断累乘，极易导致梯度消失或梯度爆炸。

12. LSTM 中“遗忘门”的作用是：

- A. 决定遗忘旧记忆的比例
- B. 决定写入新知识的比例
- C. 决定输出的权重
- D. 决定学习率大小

答案： A

解析： 在 LSTM 门控结构中，遗忘门负责输出“遗忘的比例”，控制上一时刻记忆状态的保留程度。

13. LSTM 中“输入门”的作用是：

- A. 决定遗忘旧记忆的比例
- B. 决定写入新知识的比例
- C. 决定输出的比例
- D. 决定 batch size 的大小

答案： B

解析： LSTM 的输入门结构负责输出“写入的比例”，以此控制新知识写入细胞状态的程度。

14. LSTM 中“输出门”的作用是：

- A. 决定遗忘旧记忆的比例
- B. 决定写入新知识的比例
- C. 决定输出的比例
- D. 决定词表大小

答案： C

解析： LSTM 的输出门负责输出“输出的比例”，它决定了当前细胞状态有多少比例作为隐藏状态向外输出。

15. 什么网络具有“权重不断累乘，容易消失或者爆炸”的特征：

- A. CNN
- B. RNN
- C. MLP
- D. GAN

答案： B

解析： 普通 RNN 的梯度计算涉及隐藏状态历史的链式求导，导致权重不断累乘，具有极易出现梯度消失或爆炸的特征。

16. Ilya 中把 LSTM 类比成“旋转 90° 的 ResNet”，强调的是：

- A. 门控结构与残差/捷径信息流的相似性
- B. LSTM 只能用于图像
- C. ResNet 不可训练
- D. LSTM 没有梯度问题

答案： A

解析： Ilya 将 LSTM 比作旋转了 90° 的 ResNet，是因为两者的信息流动具有相似性：LSTM 的细胞状态 C_t 通过门控与求和进行线性传递，类似于残差网络 (ResNet) 的恒等快捷连接。

17. 下列关于 RNN 与 LSTM 的说法，哪一项最正确？

- A. 普通 RNN 不需要 BPTT 就能训练，因为没有时间依赖
- B. LSTM 主要通过门控与细胞状态 (cell state) 提供更稳定的信息/梯度通路，从而更适合建模长程依赖
- C. LSTM 之所以更强，是因为它把激活函数从 $\tanh$ 换成了 ReLU
- D. 梯度消失/爆炸只会出现在 CNN 中，RNN 不会出现

答案： B

解析： LSTM 引入了遗忘门、输入门、输出门和候选记忆等机制，门控输出在 $[0,1]$ 之间，使梯度能在合理范围内传递，从而更好地建模长程依赖。

18. Next Token Prediction 的训练标签通常来自：

- A. 随机采样的 token
- B. 当前 token 本身
- C. 当前 token 的下一个 token
- D. 句子的情感标签

答案： C

解析： 在 Next Token Prediction 中，模型期望的输出序列即为输入序列向后偏移一位，因此标签直接来自当前 token 的下一个 token。

19. “梯度消失”在 BPTT 中最核心的成因之一是：

- A. 激活函数不适用
- B. 多步链式求导
- C. 学习率设置的过大
- D. batch size 一定太大

答案： B

解析： 在随时间反向传播 (BPTT) 过程中，由于梯度要经过多个时间步的链式计算，矩阵连乘效应是造成梯度消失的核心成因。

20. 给定一个最基本的 Elman RNN (Elman Net)，其中输入向量维度

为 $d = 4$ ，隐状态维度为 $h = 6$ ，词表大小为 $V = 10$ 。下列哪组矩阵维度是正确的？

- A. $W_x \in \mathbb{R}^{6 \times 4}, W_h \in \mathbb{R}^{6 \times 6}, W_y \in \mathbb{R}^{10 \times 6}$
- B. $W_x \in \mathbb{R}^{4 \times 6}, W_h \in \mathbb{R}^{6 \times 6}, W_y \in \mathbb{R}^{6 \times 10}$
- C. $W_x \in \mathbb{R}^{6 \times 6}, W_h \in \mathbb{R}^{4 \times 6}, W_y \in \mathbb{R}^{10 \times 4}$
- D. $W_x \in \mathbb{R}^{10 \times 4}, W_h \in \mathbb{R}^{10 \times 10}, W_y \in \mathbb{R}^{6 \times 10}$

答案： A

解析：在基本 RNN 公式中，隐藏状态计算为 $S_t = f(U \cdot x_t + W \cdot S_{t-1} + b)$ ，输出为 $o_t = g(V \cdot S_t)$ 。若隐状态为 6 维、输入为 4 维，则输入权重 U （或 W_x ）需为 6×4 ，循环权重 W （或 W_h ）为 6×6 ；若词表为 10，输出权重 V （或 W_y ）需为 10×6 。

21. 关于词元化 (Tokenization) 中 BPE 算法的优势，下列理解最准确的是？

- A. 它能保证所有切分出来的词元都是有明确字典定义的完整单词
- B. 它通过强制将所有单词切分为单个字符，解决了词表过大的问题
- C. 它在“字符级过细”和“单词级过稀疏”之间取得了平衡，能有效处理未登录词 (OOV)
- D. 它主要通过人工定义的语言学规则来识别词根词缀

答案： C

解析：BPE 通过计算共现频率合并字符，它从基本字符开始迭代构建，既避免了单词级词表的无限膨胀，又保证了常见子词结构的完整保留。

22. 为什么在深度学习中，通常使用 Word Embedding 替代 One-hot 编码？

- A. 因为 One-hot 编码无法在计算机中存储
- B. 因为 One-hot 编码中任意两个不同词向量是正交的，无法衡量语义相似度

- C. 因为 Word Embedding 的维度通常比 One-hot 更高，能容纳更多信息
- D. 因为 Word Embedding 计算距离时使用的是欧氏距离，而 One-hot 只能用余弦相似度

答案： B

解析：独热编码中任何一对词语的距离相同，无法衡量广义语境中的语义关系；而词嵌入则通过连续低维空间映射，使不同词语间的距离取决于语义相似度。

23. 从经典的 Linux 代码生成实验（如 Karpathy 的实验）来看，RNN 模型通常是基于什么粒度进行生成的？

- A. 逐个单词 (Word-level)
- B. 逐个字符 (Character-level)
- C. 逐行生成
- D. 逐个函数生成

答案： B

解析：在 Karpathy 的 C 语言代码生成实验中，RNN 采用了基于字符 (Character) 级别的训练，生成的序列甚至逐个字符拼写出了源代码。

24. 传统 RNN 能够处理任意长度的序列输入，其根本原因在于？

- A. RNN 的隐藏层神经元数量无限多
- B. RNN 在不同时间步共享同一组权重参数 (U, W, V)
- C. RNN 会自动截断超过固定长度的输入
- D. RNN 使用了 BPTT 算法进行训练

答案： B

解析：RNN 在每个时间步 t 使用统一的参数矩阵 (U, W, V) 更新状态，这种权重共享机制使其能够处理任意长度的序列输入。

25. 在 RNN 的梯度计算中，导致“梯度消失”或“梯度爆炸”的数学本质是？

- A. 激活函数 Sigmoid 的输出恒大于 0
- B. 损失函数选择了交叉熵而非均方误差
- C. 随时间反向传播时, 梯度包含权重矩阵 W 的连乘项
- D. 输入序列 x_t 的数值过大或过小

答案: C

解析: 在 BPTT 推导中, 对循环权重矩阵 W 的求导包含了多个时间步状态 $\frac{\partial S_t}{\partial S_{t-k}}$ 的偏导数乘积, 产生连续的矩阵连乘, 进而导致梯度消失或爆炸。

26. LSTM 设计“遗忘门”(f_t) 的核心动机是?

- A. 为了增加模型的非线性, 提高拟合能力
- B. 为了让模型能够主动丢弃历史中不再重要的信息, 防止信息冗余和干扰
- C. 为了防止梯度爆炸, 强制将梯度截断为 0
- D. 为了将当前的输入 x_t 转化为细胞状态

答案: B

解析: 遗忘门的输出 f_t 落在 $[0, 1]$ 区间, 用于决定上一时刻记忆状态 C_{t-1} 保留或遗忘的比例, 以此丢弃冗余历史信息。

27. 在 LSTM 单元中, 如果输入门 i_t 的输出接近 0, 意味着什么?

- A. 模型将完全忽略上一时刻的隐藏状态 S_{t-1}
- B. 模型将完全丢弃历史细胞状态 C_{t-1}
- C. 当前时刻的候选记忆 $\tilde{C}_{t+1}$ 几乎不会被写入新的细胞状态
- D. 当前时刻的输出 o_t 将接近 0

答案: C

解析: 输入门输出 i_t 控制新知识“写入的比例”。若 i_t 接近 0, 则候选记忆 $\tilde{C}_{t+1}$ 不会被写入新的细胞状态中。

28. 为什么说“语言是离散的符号序列”这一特点给深度学习带来了挑战?

- A. 因为离散符号无法被存储在硬盘上

- B. 因为离散符号之间没有天然的距离度量，且不可微，难以直接用梯度下降优化
- C. 因为离散符号的数量是无限的
- D. 因为离散符号不能转化为二进制

答案： B

解析：自然语言是离散的符号序列，与连续像素不同，原始符号缺乏天然的数值距离衡量标准，这导致模型无法直接处理，需转换为嵌入向量。

29. 为什么标准的 LSTM 单元中，候选记忆 $\tilde{C}_{t+1}$ 使用 tanh 而非 Sigmoid 作为激活函数？

- A. 因为 tanh 的计算速度比 Sigmoid 快
- B. 因为 tanh 的输出范围是 $[-1, 1]$ ，允许状态增减，且均值为 0 有利于收敛
- C. 因为 Sigmoid 函数在 LSTM 中只能用于门控，不能用于特征提取
- D. 因为 tanh 能解决梯度消失问题，而 Sigmoid 不能

答案： B

解析：候选记忆通过 tanh 函数被映射，产生可以为正也可为负的“新知识”。

30. 在 Image Captioning (Show and Tell) 任务中，CNN 和 RNN 是如何协作的？

- A. CNN 处理图像生成 caption，RNN 负责对 caption 进行语法纠错
- B. RNN 生成初步描述，CNN 将描述转化为图像进行验证
- C. CNN 将图像编码为特征向量，作为 RNN (LSTM) 的初始输入或上下文
- D. CNN 和 RNN 分别独立处理图像和文本，最后拼接结果

答案： C

解析：在“Show and Tell”等模型中，输入图像首先经过 CNN 提取特征（如长度为 D 的区域特征），然后与 RNN/LSTM 结合生成文本描述。

31. 为什么在训练语言模型时，Next Token Prediction 被认为是一种“自监督”学习？

- A. 因为它需要人工标注大量的 [CLS] 和 [SEP] 符号
- B. 因为训练标签 (Label) 直接来源于文本序列本身 (下一个词)，无需额外的人工标注
- C. 因为模型可以自己检查语法的正确性
- D. 因为它使用了强化学习的奖励机制

答案： B

解析：Next Token Prediction 模型仅需大量的文本数据本身进行训练，通过前文语境预测自身的下一个词元，不依赖复杂的人工标注规则。

32. 为什么 Karpathy 的可视化实验中，某些神经元会对“换行符”或“引号”特别敏感？

- A. 因为这是人工硬编码进去的规则
- B. 因为 LSTM 在训练过程中自动学会了捕捉文本的长期结构特征（如引号的开闭匹配）
- C. 因为训练数据中只包含代码，没有自然语言
- D. 因为这些符号的词向量模长特别大

答案： B

解析：实验表明，LSTM 通过海量数据训练后，内部会自动浮现出某些具备可解释功能的神经元（如引用检测细胞、if 语句细胞），专门追踪文本的特定结构。

33. 在引入注意力机制 (Attention) 的 Image Captioning 模型中，Context Vector (上下文向量) 是如何生成的？

- A. 直接取 CNN 输出的最后一个全连接层向量
- B. 对 CNN 输出的所有区域特征向量进行平均

- C. 根据当前 LSTM 的隐藏状态计算权重，对所有区域特征向量进行加权求和
- D. 随机选择一个区域的特征向量

答案： C

解析： Soft Attention 通过 Softmax 计算出基于 L 个位置的注意力分布 a_{ti} ，然后对各个区域特征 v_i 进行加权组合（加权求和）形成上下文表示。

34. 为什么 Soft Attention 通常比 Hard Attention 更受青睐用于端到端的模型训练？

- A. Soft Attention 计算量更小
- B. Soft Attention 的加权机制是可微的 (Differentiable)，可以直接使用反向传播训练
- C. Hard Attention 只能关注一个像素，信息太少
- D. Soft Attention 不需要计算 Softmax

答案： B

解析： Soft Attention 计算的是加权特征的期望值，是确定性且可微的，这使得梯度可以通过该机制在整个网络中进行反向传播。

35. 在数据预处理中，如果未进行“数据去重”，最严重的潜在后果是？

- A. 模型训练速度变慢，但最终效果更好
- B. 测试集可能包含训练集中的数据 (Data Leakage)，导致测试准确率虚高，无法真实反映模型泛化能力
- C. 词表 (Vocabulary) 会变得非常大，导致内存溢出
- D. BPE 算法将无法运行

答案： B

解析：数据集中的重复数据会令模型的上下文处理能力降低，且可能导致数据泄露和过拟合。

36. Encoder-Decoder 架构在处理机器翻译任务时，相比于定长输入的 CNN/DNN，最大的结构优势是？

- A. 它可以处理输入序列和输出序列长度不一致的情况
- B. 它不需要任何激活函数
- C. 它的编码器和解码器必须共享权重
- D. 它只能处理英文到中文的翻译

答案： A

解析： Encoder-Decoder 架构的循环神经网络具有处理机器翻译这样输入和输出不等长任务的显著优势。

37. 在 LSTM 中，如果 $C_t = C_{t-1}$ （即 $f_t = 1, i_t = 0$ ），这类似于什么？

- A. 梯度消失
- B. 梯度爆炸
- C. 恒等映射（Identity Mapping），记忆无损传递
- D. 激活函数饱和

答案： C

解析：当遗忘门 $f_t = 1$ 时，细胞状态的传递类似于残差网络（ResNet）中的恒等快捷连接（Identity Mapping），能够无损传递记忆。

38. BPE 算法在构建词表时，其停止迭代的条件通常是？

- A. 语料库中所有字符对都被合并了
- B. 达到预设的词汇表大小（Vocab Size）
- C. 出现频率最高的词对频率低于 1
- D. 语料库的大小减少了一半

答案： B

解析：BPE 算法通过反复寻找并合并最高频出现的相邻词元，循环往复直至达到所设置的终止词汇量大小。

39. 如果将 LSTM 的遗忘门偏置 b_f 初始化为一个较大的正数（如 +1），会有什么效果？

- A. 导致模型无法训练

- B. 开始训练时遗忘门 f_t 接近 1，使 LSTM 行为接近普通 RNN，容易梯度爆炸
- C. 开始训练时遗忘门 f_t 接近 1，鼓励模型在初期记住更多的历史信息，有助于梯度流传导
- D. 强制模型遗忘所有历史信息

答案： C

解析：在训练初期，较大的正偏置会使得遗忘门的 Sigmoid 输出接近 1，从而类似于残差连接保留所有旧记忆流，防止梯度过早消失。

40. 在自然语言处理中，使用 [SEP] 符号的主要目的是？

- A. 增加句子的长度，防止过拟合
- B. 显式地告诉模型句子或段落的边界，特别是在处理多句输入任务时
- C. 作为句子的情感分类标签
- D. 替换掉文本中的敏感词

答案： B

解析：特殊符号 [SEP] 专门用于表示句子的结束，或者在多句输入的情况下用于分隔不同的句子。

41. 如果在训练 LSTM 时发现模型无法收敛，且梯度数值变得非常大 (NaN)，最可能的原因和解决方案是？

- A. 原因：梯度消失；方案：使用 ReLU
- B. 原因：梯度爆炸；方案：梯度裁剪 (Gradient Clipping)
- C. 原因：遗忘门初始值太小；方案：将遗忘门偏置设置为负数
- D. 原因：数据太少；方案：做数据增强

答案： B

解析：梯度爆炸是 RNN 在长序列 BPTT 训练中因为权重不断累乘极易引发的问题，通常表现为数值溢出 (NaN)，需要用截断等方法解决。

42. 在 Next Token Prediction 任务中，如果词表大小为 V ，模型输出层的大小必须是？

- A. V ，对应每个词的预测概率
- B. 隐藏层维度 H
- C. 1，对应预测的单词索引
- D. 词嵌入维度 D

答案： A

解析：预测下一个词元时，模型会对整个词表进行 Softmax 操作，因此输出层大小必定与词表大小 V 完全一致。

43. 对于“敏感内容过滤”，除了使用分类器模型外，通常还会结合“启发式方法（如关键字）”，这是因为？

- A. 分类器只能处理图像，不能处理文本
- B. 关键字方法计算速度更快，可以作为第一道防线，且针对特定隐私信息（如电话号码正则）更精准
- C. 分类器的准确率永远是 100%
- D. 关键字方法可以自动学习新词

答案： B

解析：对于敏感内容的过滤，除了使用分类器处理有毒内容外，针对隐私内容（PII），通常使用启发式方法（如关键字识别）来检测和删除私人信息。

44. 在注意力机制中，如果图像特征是 $L \times D$ ，产生的注意力权重 α 的维度应该是？

- A. D （特征维度）
- B. L （区域数量），即每个区域对应一个权重
- C. 1，只有一个标量权重
- D. $L \times L$

答案： B

解析：输入图像经过 CNN 划分为 L 个区域，注意力机制会对这 L 个位置生成对应的分布（Distribution over L locations），即每个区域一个标量权重。

45. 为什么 IMDB 影评数据集的二分类任务（正面/负面）适合用来作为 NLP 入门实验？

- A. 因为数据量极大，需要超级计算机
- B. 因为任务目标明确，标签平衡（1:1），且不需要复杂的序列生成，只需处理语义理解
- C. 因为它包含了图片和音频等多模态信息
- D. 因为它是无监督学习任务

答案： B

解析： IMDB 是一个被广泛用于自然语言情感分析（二分类）的经典数据集，其正负极性样本严格平衡（各占 50%）。

46. 在 BPE 算法运行过程中，随着合并次数的增加，词表大小和序列长度通常会发生什么变化？

- A. 词表变大，序列长度变短
- B. 词表变小，序列长度变长
- C. 词表变大，序列长度变长
- D. 词表变小，序列长度变短

答案： A

解析：随着 BPE 迭代合并高频词对，原本由小字符组成的序列会被替换为更长的新词元，导致词汇表不断变大，而文本切分后的序列总长度逐渐变短 [cite: 78, 80]。

47. RNN 状态更新公式 $S_t = f(U \cdot x_t + W \cdot S_{t-1} + b)$ 中，参数 U 的含义是？

- A. 输入权重矩阵
- B. 循环权重矩阵
- C. 输出权重矩阵
- D. 偏置项

答案： A

解析：根据 RNN 的公式 $S_t = f(U \cdot x_t + W \cdot S_{t-1} + b)$ ， U 与当前输

入 x_t 相乘，代表输入权重矩阵。

48. LSTM 细胞状态更新公式 $C_t = f_t \cdot C_{t-1} + i_t \cdot \hat{C}_t$ 中， i_t 代表？

- A. 遗忘门输出
- B. 输出门输出
- C. 候选记忆
- D. 输入门输出

答案： D

解析：在 LSTM 中， i_t 代表输入门输出，负责控制候选“新知识”写入细胞状态的比例。

49. BPE（字节对编码）算法的初始词汇表由什么构成？

- A. 高频子词组合
- B. 完整单词集合
- C. 人工定义词表
- D. 基础字符（字母、边界符号等）

答案： D

解析：BPE 算法初始化时，是从一组最基本符号（例如单字母和边界字符）开始构建初始词汇表的。

50. 循环神经网络（RNN）的初始隐藏状态 S_0 的默认取值是？

- A. 随机向量
- B. 全 1 向量
- C. 全 0 向量
- D. 单位矩阵

答案： C

解析：RNN 的状态初始化公式明确定义了 $S_0 = 0$ ，即通常将初始隐藏状态设为全 0 向量。

51. LSTM 细胞状态更新的核心公式是？

- A. $C_t = f_t + i_t \cdot \hat{C}_t$
- B. $C_t = f_t \cdot C_{t-1} + i_t \cdot \hat{C}_t$
- C. $C_t = o_t \cdot \tanh(C_{t-1})$
- D. $C_t = W \cdot S_{t-1} + U \cdot x_t$

答案： B

解析： LSTM 的细胞状态更新公式由遗忘旧记忆和写入新知识两部分相加构成： $C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$ 。

52. 下列哪组属于常用的词元化（分词）方法？

- A. BPE、WordPiece、Unigram
- B. CNN、RNN、Transformer
- C. 独热编码、词嵌入、随机投影
- D. 梯度下降、Adam、SGD

答案： A

解析： 自然语言处理中最常用的词元化（分词）方法包括 BPE 分词、WordPiece 分词以及 Unigram 分词。

53. Johnson-Lindenstrauss 引理的核心作用是？

- A. 推导梯度下降算法在模型训练中的收敛速度
- B. 证明深度神经网络具有能够逼近任意连续函数的能力
- C. 说明高维数据可通过随机映射嵌入低维空间并保持距离
- D. 解释长短期记忆网络（LSTM）门控机制的工作原理

答案： C

解析： Johnson-Lindenstrauss 引理说明高维数据可通过随机线性映射嵌入到远低于原始维数的低维空间，且能近似保持点与点之间的距离。

54. Encoder-Decoder 架构中，“Encoder”的主要功能是？

- A. 对输入序列进行特征编码
- B. 根据上下文向量生成目标序列结果
- C. 计算交叉熵损失

- D. 缓解循环神经网络训练的梯度消失问题

答案： A

解析：在 Encoder-Decoder 结构中，Encoder（编码器）通过循环网络逐步吸收输入序列信息，生成最终的隐藏状态对特征进行编码传递。

55. 下列关于语言处理中“递归性”特征的描述，最符合自然语言结构的是？

- A. 语言必须从左到右依次处理，不可回溯
- B. 句子结构可以无限嵌套，例如名词从句可以充当另一个句子的成分
- C. 语言的每个单词都是独立生成的，与前文无关
- D. 语言的词汇量是有限且固定的

答案： B

解析：语言具备递归性这一层次结构特点，例如名词从句能够充当另一个句子的主语、宾语或表语，形成无限嵌套。

56. 假设一个语料库中只有“loop”、“pool”、“tool”三个单词，在使用 BPE 进行分词时，如果统计频率发现字符组合“oo”出现的次数最多，那么第一步合并操作是？

- A. 将“l”和“o”合并为“lo”
- B. 将“o”和“l”合并为“ol”
- C. 将“o”和“o”合并为“oo”
- D. 将“p”和“o”合并为“po”

答案： C

解析：在统计“loop”“pool”等词频后发现，“oo”这一组合在语料库中出现频率最高，因此第一条合并规则是（“o”，“o”）→“oo”。

57. 在数据预处理中，使用“基于分类器的方法”进行质量过滤时，通常如何构建训练集？

- A. 将所有网页数据都标记为正样本

- B. 手工编写规则，符合规则的为正样本
- C. 将高质量来源（如维基百科）作为正样本，不良数据作为负样本
- D. 随机抽取一部分数据标记为负样本

答案： C

解析：基于分类器的质量过滤方法，会利用高质量来源建立文本分类器，例如将维基百科数据作为正样本，网页不良数据作为负样本进行训练。

58. 在循环神经网络中，如果我们需要对图像进行描述 (Image Captioning)，输入通常是图像特征，输出是文本序列。此时输入数据的处理方式通常是？

- A. 将图像像素拉直成一个长向量直接输入 RNN
- B. 使用 CNN 提取图像特征，将其作为 RNN 的初始状态或输入的一部分
- C. 图像不参与计算，仅作为 RNN 的输出目标
- D. RNN 能够直接处理原始图像矩阵，不需要其他网络辅助

答案： B

解析：看图说话任务中，通常利用 CNN（如 VGG 网络）对图像进行处理并提取出特征向量集 (Annotation vectors)，再输入给 RNN 解码生成文本。

59. 为什么说 [PAD] 符号对于批量 (Batch) 训练是必须的？

- A. 因为它能增加句子的语义信息
- B. 因为神经网络通常要求输入张量具有规整的形状，需将不同长度句子补齐
- C. 因为它代表句子的结束，告诉模型停止生成
- D. 因为它能防止模型过拟合

答案： B

解析：特殊符号 [PAD] 是填充符号，主要用于将批次中不同长度的句

子补齐到相同长度，以满足神经网络矩阵运算对形状对齐的要求。

60. 在自然语言处理的数据准备阶段，如果发现训练数据中存在大量的“**Alice is writing a paper**”和“**Somebody is writing a paper**”这类高度相似的句子，我们应该主要考虑哪种操作？

- A. 词元化 (Tokenization)
- B. 数据去重 (Deduplication)
- C. 敏感内容过滤
- D. 增加数据量

答案： B

解析：数据集中包含大量高度相似或重合的句子，需要通过句子级别的近似匹配或精确匹配算法进行数据去重，以防降低模型能力。

61. 考虑 LSTM 的遗忘门公式 $f_t = \sigma(W_{Sf}S_t + W_{xf}x_{t+1} + b_f)$ ，其中 σ 是 Sigmoid 函数。如果 f_t 计算结果为 0.1，这在物理意义上表示什么？

- A. 这一时刻的信息非常重要，需要被强化 10 倍
- B. 这一时刻的信息将会有 90% 被遗忘，只保留 10% 的旧记忆
- C. 这一时刻的信息将会有 10% 被遗忘，保留 90% 的旧记忆
- D. 这一时刻的信息会被完全替换为新输入

答案： B

解析：遗忘门 f_t 输出表示旧记忆“保留的比例”。计算结果 0.1 意味着上一时刻旧记忆只有 10% 被保留，其余 90% 被遗忘。

62. 在 Next Token Prediction 任务中，如果输入序列是“**Deep Learning is**”，模型预测的下一个词是“**hard**”，而真实标签是“**fun**”。计算损失时，主要计算的是哪两个分布之间的差异？

- A. 输入序列的词向量分布与输出词向量分布
- B. 模型预测的词表概率分布与真实标签的 One-hot 分布
- C. “hard”的词向量与“fun”的词向量之间的欧氏距离
- D. 隐藏层状态与输出层状态之间的差异

答案： B

解析： Next Token Prediction 采用交叉熵损失，即比较模型对整个词表做 Softmax 输出的预测概率分布，与真实下一个标签 (One-hot) 之间的误差。

63. 假设词表大小 $N = 10000$ ，我们使用 Word Embedding 将每个词映射到 $d = 256$ 维的空间。相比于 One-hot 编码，Word Embedding 的参数矩阵 W_{emb} 的大小是？

- A. 10000×10000
- B. 256×256
- C. 256×10000
- D. 10000×1

答案： C

解析：词嵌入矩阵 $W_{emb} \in \mathbb{R}^{d \times N}$ ，其中 d 是嵌入空间维度 (256)， N 是词表大小 (10000)，因此参数大小为 256×10000 。

64. 在 RNN 的 BPTT 训练过程中，如果损失函数为 L ，参数为 W ，在计算 $\frac{\partial L_t}{\partial W}$ 时，需要累加的项包含 $\frac{\partial S_t}{\partial S_{t-k}}$ 。这一项主要反映了什么？

- A. 当前时刻的输出仅依赖于当前时刻的输入
- B. 梯度需要沿着时间轴向前传播
- C. 当前时刻的状态受过去 k 个时刻状态的连锁影响，梯度需回溯历史
- D. 损失函数只与最后一个时间步有关

答案： C

解析：在时间维展开后做 BPTT 反向传播，为了计算当前权重的梯度 $\frac{\partial L_t}{\partial W}$ ，必须通过链式法则累加过去所有时间步 S_{t-k} 传递回来的梯度贡献。

65. 为什么在 Karpathy 的 Linux 代码生成实验中，生成的代码虽然看起来像 C 语言，但可能无法编译通过？

- A. 因为模型没有学习到任何语法规则

- B. 因为模型是基于字符级别的概率预测，它学习的是局部结构而非严谨的逻辑语义
- C. 因为训练数据本身包含大量错误代码
- D. 因为 RNN 无法生成长序列

答案： B

解析： RNN 通过统计字符频率（如逐字符的 `char_rnn`）生成代码，它学习的是局部字符结构概率，而非严格的抽象语法树，因此容易产生语法逻辑错误导致编译失败。

66. 在 Encoder-Decoder 架构中，如果将 Decoder 的初始状态 S'_0 设为 0 向量而不是 Encoder 的最终状态 S_n ，最可能导致什么后果？

- A. 解码器将无法生成任何内容
- B. 解码器生成的序列将不再依赖输入序列的信息，变成无条件生成
- C. 解码器的生成速度会变快
- D. 模型的泛化能力会增强

答案： B

解析： Encoder-Decoder 的核心是利用 Encoder 最后的隐状态（上下文向量）初始化 Decoder，若强行置 0，则截断了输入特征的传递，输出与输入完全脱钩。

67. 对于 IMDB 数据集，如果某条评论包含大量诸如“worst”，“boring”，“waste”等词汇，LSTM 模型通过训练最可能将其分类为？

- A. 正面评价 (Positive)
- B. 负面评价 (Negative)
- C. 中性评价 (Neutral)
- D. 无法分类

答案： B

解析： 诸如“worst”、“boring”等极端词汇携带强烈的负面情感特征，IMDB 训练的情感分类器会将其判定为负面评价 (Negative)。

68. 在 Soft Attention 机制中, 注意力权重 a_{ti} 是通过 Softmax 函数计算得到的, 这保证了 $\sum_i a_{ti}$ 等于多少?

- A. 0
- B. 1
- C. L (特征区域的数量)
- D. D (特征维度)

答案: B

解析: Soft Attention 机制的本质是通过 Softmax 函数计算各区域的注意力得分 a_{ti} , 其天然保证了所有区域权重的非负性及总和为 1。

69. 如果在 Kaggle 竞赛中训练一个 NLP 模型, 发现训练集准确率很高但测试集准确率很低, 且检查发现数据预处理时没有进行“去重”操作。这最可能是因为?

- A. 数据量太少导致欠拟合
- B. 重复数据导致模型记忆了特定样本, 发生了 Data Leakage 或过拟合
- C. 学习率设置得太低
- D. 词元化方法选择错误

答案: B

解析: 重复的训练数据如果没有被过滤, 可能导致模型过度记忆这些样本; 当测试集中也出现这些冗余句子时, 会产生信息泄露 (Data Leakage), 进而表现出虚高但不具有泛化性的评估结果。

二、判断题

1. 循环神经网络 (RNN) 的一个核心特征是: 同一组参数在不同时间步被重复使用。

答案: T

解析: RNN 在时间维度展开后, 每个时间步使用相同的权重进行状

态更新，这使得模型能够处理不同长度的序列，并保持参数规模不随序列长度增长。

2. RNN 的隐藏状态只由当前输入决定，与历史信息无关。

答案：F

解析：RNN 的隐藏状态通常由“上一时刻隐藏状态 + 当前输入”共同决定，因此会携带并压缩历史信息，而不是只看当前输入。

3. 在序列建模中，如果完全忽略顺序信息，只把序列当作无序集合，通常会丢失重要的语义或结构信息。

答案：T

解析：序列任务往往依赖顺序（例如先后关系、依赖关系）。将序列无序化会破坏上下文与依赖，从而影响建模效果。

4. 在 BPTT 中，梯度只在单个时间步内传播，不会跨越多个时间步。

答案：F

解析：BPTT 的关键就是让梯度跨多个时间步传播，从而学习“过去输入如何影响未来输出”的参数。

5. 序列越长，普通 RNN 训练越容易出现梯度消失或梯度爆炸。

答案：T

解析：由于梯度在时间维度上反复相乘，长序列会放大连乘效应，更容易导致梯度范数过小（消失）或过大（爆炸）。

6. LSTM 的门控机制可以控制信息在时间维度上的保留、写入与输出，从而提升长程依赖建模能力。

答案：T

解析：LSTM 通过遗忘门、输入门、输出门调节记忆状态（cell state）与隐藏状态（hidden state）的信息流动，增强长期信息传递的稳定性。

7. LSTM 的遗忘门主要控制旧记忆保留的比例；遗忘门输出越接近 0，旧记忆保留越多。

答案：F

解析：遗忘门输出越接近 0，表示越“忘记”，旧记忆会被更大幅度清除；输出越接近 1，表示更多保留旧记忆。

8. LSTM 的输入门控制新信息写入记忆状态的比例；输入门输出越接近 1，写入越充分。

答案：T

解析：输入门决定候选新信息进入 cell state 的强度，是“写入”的关键控制量之一。

9. LSTM 的输出门控制从记忆状态产生当前隐藏状态/输出的比例。

答案：T

解析：输出门相当于“对外展示的阀门”，即使 cell state 中存在信息，也可能被输出门抑制而不显著反映在当前输出中。

10. 在序列到序列 (Seq2Seq) 任务中，Encoder-Decoder 结构允许输入序列与输出序列长度不同。

答案：T

解析：编码器对输入序列进行编码，解码器再逐步生成输出，因此可自然处理不等长映射（如翻译、摘要）。

11. 如果解码器生成时不依赖编码器得到的表示，那么模型仍能稳定完成“基于输入生成对应输出”的条件生成任务。

答案：F

解析：条件生成的关键是输出要受输入约束；若解码器不使用编码器信息，就会更像无条件生成，难以与输入内容对齐。

12. 在“逐步生成”的序列生成任务中，模型通常使用已有前缀来预测下一步，从而体现上下文依赖。

答案：T

解析：自回归生成在位置 t 使用前缀信息预测下一个符号，生成过程天然依赖上下文。

13. 在 Next Token Prediction 中，模型在每个位置都需要对词表产生一个概率分布，用于预测下一个词元。

答案：T

解析：该目标等价于对每个位置做一次“词表分类”(softmax)，并通过损失函数（如交叉熵度量）预测与目标的差异。

14. Next Token Prediction 的损失函数通常不需要考虑概率分布，只比较预测 token 与目标 token 是否相同即可。

答案：F

解析：训练通常基于概率分布 (softmax 输出)，用交叉熵等连续可导的损失来优化；仅用“是否相同”的 0/1 指标不可导，无法直接用于梯度优化。

15. 即使两个序列在当前时间步输入完全相同，只要历史不同，RNN 在该时间步的隐藏状态也可能不同。

答案：T

解析：隐藏状态依赖上一时刻隐藏状态，历史差异会通过递归状态传递到当前，从而导致相同输入下产生不同状态。

16. 在 LSTM 中，如果输入门始终输出 0（完全不写入新信息），模型的输出一定恒为 0。

答案：F

解析：即使不写入新信息，只要遗忘门保留旧记忆，输出门仍可能从已有 cell state 中产生非零输出，因此不必退化为恒零输出。

17. 语言可以被视为连续的像素信号，因此不必强调“符号序列”的顺序特性。

答案：F

解析：语言本质上是离散的符号序列，顺序与上下文会显著影响含义；忽略顺序往往会导致语义信息丢失。

18. 自然语言中常见“长程依赖”和“上下文相关性”，因为同一个词或短语在不同上下文中可能表达不同含义。

答案：T

解析：长程依赖体现在跨较远位置的信息关联；上下文相关性体现在同样的局部片段在不同上下文下含义可能变化。

19. 传统全连接网络或卷积网络在序列任务上的一个局限是：输入往往需要固定长度，并且缺少对历史输入的显式记忆。

答案：T

解析：这类结构通常不自带“时序状态”，对历史信息的保留需要额外设计，否则难以直接表达“历史影响当前”的机制。

20. 数据质量过滤可以同时采用启发式规则方法与基于分类器的方法，它们在工程中常被组合使用。

答案：T

解析：启发式规则便于快速过滤；分类器方法能学习更复杂的模式。两者结合可在成本与效果之间取得平衡。

21. 词元化（分词）的目标是把属于同一语义或语法单元的字符聚合起来；因此词元不一定等同于“完整单词”。

答案：T

解析：词元化追求的是语义/语法单元的合理划分，既可能是词，也可能是子词片段；划分方式取决于规则或统计策略。

22. 在 Next Token Prediction 的训练框架下，监督信号可以直接来自文本本身（用前缀预测下一个词元），因此通常不需要额外人工标注标签。

答案：T

解析：该框架把“下一个词元”作为目标，训练目标由序列自身产生，常见做法是对每个位置输出词表分布并计算交叉熵损失。

23. 自然语言处理的目标之一是让计算机能够理解、生成和处理人类自然语言。

答案：T

解析：NLP 的核心目标之一就是让计算机能够理解、生成、处理人类语言。

24. 语言是连续信号（类似像素），因此适合直接用 CNN 处理，不需要序列模型。

答案：F

解析：语言并不是像像素那样的连续信号，而是离散符号序列，而且强依赖顺序与上下文。

25. 语言具有长程依赖关系。

答案：T

解析：自然语言中存在大量长程依赖（如指代、主谓一致、跨句信息等）。

26. 数据准备时，重复数据可能降低模型的上下文处理能力。

答案：T

解析：数据中大量重复样本会降低有效信息量，导致训练分布偏斜、模型更易记忆/过拟合。

27. 敏感内容过滤常用启发式方法与基于分类器的方法。

答案：T

解析：敏感内容过滤常见两类：启发式/规则、分类器/模型方法。

28. 词元化（分词）的目标是把字符切成单个字母，越细越好。

答案: F

解析: 词元化的目标不是“切成单个字母越细越好”。过细会导致序列过长、语义破碎。

29. BPE 的核心操作是反复合并语料里最常出现的相邻词元对。

答案: T

解析: BPE 的核心操作就是不断合并语料中出现频率最高的相邻 token 对。

30. WordPiece、Unigram 也属于常用词元化方法。

答案: T

解析: WordPiece、Unigram 都是常用的子词词元化方法。

31. CLS 通常用于表示句子开始并作为分类任务的整体表示。

答案: T

解析: [CLS] 常放在序列开头, 用于汇聚全句信息, 常被用作分类任务的整体表示。

32. Next Token Prediction 的训练目标是: 输出序列每个 token 预测输入序列的下一个 token。

答案: T

解析: 等价于“输出序列每个 token 预测下一个 token”。

33. Next Token Prediction 训练中常用交叉熵损失。

答案: T

解析: NTP 常用交叉熵损失 (对下一个 token 的 softmax 分类)。

34. Encoder-Decoder 架构可用于机器翻译这类输入输出不等长任务。

答案: T

解析: 很适合机器翻译、摘要等输入输出长度不等任务。

35. RNN 训练时可能出现梯度消失或梯度爆炸。

答案：T

解析：RNN 的梯度在时间维度上反复相乘，容易出现梯度消失/爆炸。

36. LSTM 通过门控机制缓解了普通 RNN 权重连乘导致的不稳定问题。

答案：T

解析：LSTM 通过门控与 cell state 的设计，显著缓解普通 RNN 因反复连乘导致的不稳定。

37. LSTM 中遗忘门控制“写入新知识的比例”。

答案：F

解析：遗忘门主要控制“保留多少旧的 cell state”，写入新信息主要由输入门决定。

38. LSTM 中输入门控制“遗忘旧记忆的比例”。

答案：F

解析：输入门控制“写入新信息的比例”，遗忘门控制“遗忘旧记忆的比例”。

39. LSTM 中输出门控制“输出的比例”。

答案：T

解析：输出门控制从 cell state 向外输出到 hidden state 的信息比例。

40. Kaggle 竞赛涵盖自然语言处理和计算机视觉两大领域。

答案：F

解析：Kaggle 竞赛涵盖多个领域，并非仅两大领域。

41. 传统全连接卷积网络能够灵活处理变长序列数据，并保留历史输入记忆。

答案：F

解析：全连接卷积网络的输入长度固定，无法适配变长序列，且缺乏对历史输入的记忆能力。

42. 循环神经网络在每个时间步都会利用之前的隐藏状态。

答案：T

解析：隐藏状态的递归更新使其能够处理序列信息。

43. RNN 的状态更新公式 $S_t = f(U \cdot x_t + W \cdot S_{t-1} + b)$ 中， W 是输入权重矩阵。

答案：F

解析： U 为输入权重矩阵， W 是循环权重矩阵。

44. LSTM 的核心创新是通过“细胞状态 + 门控”分离“长期记忆存储”和“短期记忆处理”。

答案：T

解析：细胞状态存储长期记忆（线性传递），隐藏状态处理短期记忆。

45. 敏感内容过滤仅需通过关键词识别即可删除所有隐私信息。

答案：F

解析：需双重机制：分类器 + 启发式关键词。

46. LSTM 的细胞状态 (C_t) 通过线性传递保留历史信息，缓解梯度消失。

答案：T

解析：通过线性传递减少梯度衰减。

47. 词元化的核心是将文本切分为具有独立语义或语法功能的基本单元。

答案：T

解析：词元化是文本结构化的基础步骤。

48. LSTM 的输出门直接将细胞状态 C_t 作为隐藏状态 S_t 输出。

答案: F

解析: 输出门先通过 Sigmoid 函数筛选, 再经 tanh 函数压缩。

49. 基于统计的分词方法依据预定义的空格、标点等规则进行文本切分。

答案: F

解析: 基于规则的分词依赖预定义符号, 基于统计的分词通过分析频率。

50. 与 RNN 相比, LSTM 的参数量更少、计算速度更快。

答案: F

解析: LSTM 参数量比 RNN 更多, 计算复杂度更高。

51. Next Token Prediction 的训练目标是预测序列中任意位置的缺失词元。

答案: F

解析: 目标是基于前文语境预测序列中的下一个词元。

52. 循环神经网络 (RNN) 的初始隐藏状态通常设为 0 向量。

答案: T

解析: 初始状态 S_0 默认设为 0 向量。

53. BPTT (通过时间反向传播) 算法训练 RNN 时不会出现梯度问题。

答案: F

解析: 容易导致梯度消失或爆炸。

54. 词嵌入可将高维稀疏的词向量转换为低维稠密的语义向量。

答案: T

解析: 词嵌入的核心作用是降维与语义编码。

55. IMDB 数据集包含 50000 条标注影评，训练集和测试集各 25000 条，且正负样本比例均为 1:1。

答案：T

解析：样本分布均衡。

56. 独热编码 (One-hot Encoding) 的一个根本局限性是任意两个不同词向量的内积均为 0，因此无法直接衡量词与词之间的语义相似度。

答案：T

解析：独热编码中向量两两正交，欧氏距离相等，无法反映“猫”和“狗”比“猫”和“汽车”更相似的语义关系。

57. 在 Image Captioning (看图说话) 任务的经典架构中，通常使用 RNN/LSTM 作为编码器来处理图像，使用 CNN 作为解码器来生成文本。

答案：F

解析：恰恰相反，通常用 CNN 编码图像特征，用 RNN/LSTM 解码生成文本序列。

58. 在软注意力机制 (Soft Attention) 中，为了保证所有注意力权重的和为 1，通常使用 Softmax 函数对计算出的注意力得分进行归一化。

答案：T

解析：Softmax 函数可以将输入向量映射为概率分布，确保所有元素非负且和为 1，符合注意力权重的物理含义。

59. 在文本生成任务中，模型只要生成了句号 “。” 或感叹号 “！”，就会立即强制停止生成，不需要预测专门的终止符。

答案：F

解析：标点符号只是普通的 token，生成过程通常由预测到专门的终止符（如 [SEP] 或 [EOS]）来决定结束。

60. 可视化实验表明，LSTM 内部的某些隐层神经元具有可解释性，例如存在专门追踪“引号内内容”或“代码缩进长度”的神经元。

答案：T

解析：Karpathy 等人的研究发现，RNN/LSTM 在训练后会自动分化出具有特定功能的神经元，用于捕捉文本的结构特征。

61. 词嵌入 (Word Embedding) 的主要优势之一是将词映射到了低维稠密空间，这与高维稀疏的独热编码形成了鲜明对比。

答案：T

解析：词嵌入维度通常在几百维（如 512），而独热编码维度等于词表大小（可能上万），且嵌入向量大部分元素非零（稠密）。

62. BPE（字节对编码）分词算法的初始化步骤是将语料库中所有出现的完整单词直接加入词表，然后再进行拆分。

答案：F

解析：BPE 的初始化是从基本字符（如字母）开始，通过反复合并高频共现的子词对来逐步构建词表，是由小到大的过程。

63. 如果 LSTM 的遗忘门输出始终为 1 且输入门输出始终为 0，那么细胞状态 C_t 将完全保留上一时刻的值，这在数学形式上类似于残差网络 (ResNet) 的恒等映射。

答案：T

解析：此时公式退化为 $C_t = 1 \cdot C_{t-1} + 0$ ，即 $C_t = C_{t-1}$ ，实现了信息的无损直通。

64. Next Token Prediction 任务属于自监督学习，因为它不需要额外的人工标注，训练数据的标签就直接来源于文本序列本身。

答案：T

解析：“下一个词”就是天然的标签，无需像分类任务那样人工打标签，因此被称为自监督。

65. 在最基本的 Encoder-Decoder 模型中，编码器的作用是将整个输入序列的信息压缩为一个固定长度的上下文向量 (Context Vector)，并传递给解码器。

答案：T

解析：编码器的最终隐藏状态通常作为 Context Vector，承载了输入序列的全部语义信息供解码器使用。

66. 在计算 RNN 的梯度时，当前时刻参数的梯度计算不仅涉及当前时刻的损失，还需要累加来自未来所有时间步反向传播回来的梯度。

答案：T

解析：BPTT 算法要求梯度沿时间轴反向传播，参数在 t 时刻的更新需要考虑它对 t 之后所有时刻输出的影响。

67. “硬注意力” (Hard Attention) 机制通常是指以概率采样的形式只关注图像的某一个区域，这种机制通常不可微，难以直接使用标准的反向传播进行训练。

答案：T

解析：Hard Attention 是一个随机选择过程 (Stochastic)，不可导，通常需要强化学习等方法训练；而 Soft Attention 是加权平均，可导。

三、填空与计算题

1. IMDB 数据集的核心任务是 _____ 分析，需区分影评的正面和负面评价，属于二分类问题。

答案：情感

解析：IMDB 数据集由 50000 条标注影评构成，每条数据标记为“正面”或“负面”，核心用途是训练情感分类模型。

2. 在词嵌入训练中，相比独热编码，Embedding 层能够显著降低输入维度，其根本原因在于 _____。

答案：词嵌入通过共享低维连续表示而非为每个词分配独立高维向量

解析：独热编码为每个词分配一个互不共享的高维稀疏向量，而词嵌入将所有词映射到同一低维连续向量空间，不同词之间通过参数共享表达语义关系。

3. RNN 的隐藏状态 S_t 融合了当前输入 x_t 和 _____ 的信息，是其实现“短期记忆”功能的核心。

答案：上一时刻隐藏状态（或 S_{t-1} ）

解析：隐藏状态的递归更新是 RNN 的核心特性，将历史信息传递到下一时间步。

4. 独热编码中，若词表大小为 V ，则每个单词对应的编码向量长度为 _____。

答案： V

解析：独热编码的“一位有效”特性决定了向量长度与词表大小完全一致。

5. LSTM 中输入门的激活函数是 _____，输出范围为 $[0, 1]$ ，用于控制新信息写入细胞状态的比例。

答案： Sigmoid

解析：输入门需输出“写入比例”，Sigmoid 函数的输出恰好落在 $[0, 1]$ 区间。

6. Next Token Prediction 框架的训练损失通常采用 _____ 损失函数计算。

答案： 交叉熵

解析：该框架通过对比模型预测的下一个词元与真实词元的差异，使用交叉熵损失衡量预测误差。

7. RNN 的状态更新公式中， W 代表 _____ 权重矩阵，负责传递历史隐藏状态信息。

答案：循环

解析：RNN 的状态更新公式 $S_t = f(U \cdot x_t + W \cdot S_{t-1} + b)$ 中， W 是循环权重矩阵。

8. LSTM 的候选记忆 $\hat{C}_t$ 经过 _____ 函数激活后，取值范围被映射到 $[-1, 1]$ 区间。

答案：tanh

解析：tanh 函数是 LSTM 生成候选记忆的常用激活函数，能有效控制数值范围。

9. 自然语言的 _____ 特性要求模型捕捉跨长序列的语义关联，例如“他昨天买的书今天被同事借走了”中“书”与“借走”的关联。

答案：长程依赖关系

解析：长程依赖关系是自然语言的核心特点之一。

10. 特殊符号 MASK 用于 _____ 语言模型 (MLM) 任务，通过掩盖单词提升模型语义理解能力。

答案：掩码

解析：MASK 符号的核心作用是在训练中随机掩盖部分单词，迫使模型通过上下文预测被掩盖词。

11. RNN 的输出计算中，激活函数 g 通常采用 _____，将隐藏状态转换为词表上的概率分布。

答案：Softmax

解析：Softmax 函数能将任意实数向量映射为概率分布。

12. LSTM 的遗忘门通过 _____ 函数输出 0-1 之间的权重，控制历史细胞状态的保留比例。

答案：Sigmoid

解析: Sigmoid 函数的输出范围为 $[0, 1]$, 恰好匹配“保留比例”的语义。

13. 在某一时刻, LSTM 的细胞状态为 $C_t = 2.0$, 遗忘门输出 $f_t = 0.25$, 输入门输出 $i_t = 0.5$, 候选记忆 $\hat{C}_{t+1} = 1.0$, 则新的细胞状态 $C_{t+1} =$ _____。

答案: 1.0

解析: $C_{t+1} = f_t \cdot C_t + i_t \cdot \hat{C}_{t+1} = 0.25 \times 2.0 + 0.5 \times 1.0 = 0.5 + 0.5 = 1.0$ 。

14. 若 BPE 算法处理的语料中, “lo” 出现 20 次, “oo” 出现 35 次, “ot” 出现 18 次, 则第一次合并的词对是 _____。

答案: (“o”, “o”)

解析: BPE 第一次合并的是共现频率最高的相邻词元, 35 次最高。

15. LSTM 的细胞状态更新公式为 $C_t = f_t \cdot C_{t-1} +$ _____ $\cdot \hat{C}_t$ 。

答案: i_t

解析: i_t 乘以候选记忆写入新信息。

16. 与连续的图像像素不同, 自然语言处理处理的对象本质上是 _____ 的符号序列。

答案: 离散

解析: 语言是由单词、字符等离散单位组成的, 这也是 NLP 建模与计算机视觉处理连续信号的主要区别之一。

17. 在自然语言处理的数据准备阶段, 为了能够对不同长度的句子进行批量 (batch) 处理, 通常需要使用 _____ 符号将短句补齐到统一长度。

答案: PAD

解析: PAD 符号 (填充符) 是解决变长序列批量计算问题的标准手段。

18. 语言具有复杂的层次结构, 其中 _____ 这一

特点（如名词从句可以充当另一个句子的主语或宾语）使得句子的长度和深度在理论上可以是无限的。

答案：递归性

解析：递归性是语言结构的重要特征，它允许我们在一个结构中嵌套另一个相同类型的结构。

19. BPE（字节对编码）算法在初始化时，其词汇表是由语料库中所有的 _____ 构成的，随后才开始迭代合并。

答案：基础符号（或字母/边界字符）

解析：BPE 的构建过程是“自底向上”的，最初只有最基本的字符，通过统计共现频率逐步生成子词。

20. 独热编码 (One-hot Encoding) 的一个数学特性是：任意两个不同单词的向量之间的点积(Dot Product)恒为 _____。

答案：0

解析：独热向量是正交的单位向量，不同索引位置的 1 互不错位，导致点积为 0，这解释了为何它无法通过距离衡量相似度。

21. Johnson-Lindenstrauss 引理为词嵌入提供了理论支持，它指出高维空间的数据可以嵌入到低维空间，同时近似保持点与点之间的 _____。

答案：距离

解析：这解释了为什么我们可以将几万维的独热向量压缩到几百维的嵌入向量中，而不丢失太多的几何结构信息。

22. 在 Next Token Prediction 框架中，如果模型的输入序列是 $(x_1, x_2, \dots, x_n)$ ，那么用于计算损失的真实标签序列 (Target Sequence) 应该是 _____。

答案： $(x_2, x_3, \dots, x_{n+1})$

解析：NTP 的目标是预测下一位，因此标签序列是输入序列向左移动一位的结果。

23. 在 LSTM 结构中，_____ 门负责控制将当前的细胞状态 C_t 转换为隐藏状态 S_t 的比例。

答案：输出

解析：输出门决定了细胞内部的记忆有多少会被“暴露”给外部作为当前的隐藏状态。

24. Ilya Sutskever 曾将 LSTM 比作是旋转了 90 度的 _____，因为细胞状态的线性传递路径类似于残差连接，有助于梯度流动。

答案：ResNet（残差网络）

解析：这一类比生动地揭示了 LSTM 能够缓解梯度消失问题的核心机制——类似于 ResNet 的恒等映射路径。

25. 在 Image Captioning（图像描述）任务的经典架构 Show and Tell 中，_____ 扮演了编码器（Encoder）的角色，负责将图像转换为特征向量。

答案：CNN（卷积神经网络）

解析：这是一个典型的 Encoder-Decoder 跨模态任务，CNN 负责视觉编码，RNN 负责语言解码。

26. 在注意力机制中，为了确保计算出的注意力权重 α_{ti} 之和为 1，通常会对注意力得分应用 _____ 函数。

答案：Softmax

解析：Softmax 函数能够将一组实数转换为概率分布，满足非负且归一化的要求，适合表示“权重”或“关注度”。

27. 相比于“硬注意力”(Hard Attention)，_____ 注意力机制计算的是特征的加权平均，由于其可微性，可以直接通过反向传播进行端到端的训练。

答案：软 (Soft)

解析：Soft Attention 是确定性的加权求和，而 Hard Attention 涉及随机采样，前者在工程实现和训练上更为简便。

28. 数据去重是提升模型性能的重要步骤，它可以在句子级别、文档级别以及 _____ 级别等多个粒度上进行。

答案：数据集

解析：不同粒度的去重能解决不同层面的冗余问题，防止模型死记硬背。

29. Karpathy 的可视化实验发现，RNN 中存在一些具有特定功能的神经元，例如有的神经元会在遇到 _____ 时激活，直到其闭合。

答案：引号 (或注释)

解析：这证明了 RNN 即使在没有显式规则的情况下，也能通过训练自动学习到文本的某些结构特征。

30. 假设词嵌入维度为 d ，词表大小为 N ，则词嵌入矩阵 W_{emb} 的维度大小为 _____ (或 $N \times d$ ，取决于具体实现定义)。

答案： $d \times N$

解析：词嵌入矩阵本质上是一个查找表，存储了 N 个单词的 d 维向量表示。

31. 若一句话长度为 5 (不含任何特殊符号)，按 Next Token Prediction 训练时，不额外引入终止符 (EOS/SEP) 会产生 _____ 个“预测目标 token”；若在末尾额外添加一个终止符，使序列长度变为 6，则会产生 _____ 个“预测目标 token”。

答案：4; 5

解析：1) 句长 $L = 5$ ，最后一个 token 没有“下一个 token”可预测，因

此目标 token 数: $L - 1 = 5 - 1 = 4$ 。2) 末尾加终止符后新长度 $L' = 6$, 同理目标 token 数: $L' - 1 = 6 - 1 = 5$ 。

32. 给定词表大小 $V = 12$, 嵌入维度 $d_e = 5$, $batch = 2$, 序列长度 $seq_len = 4$ 。其 one-hot 输入张量形状是 _____, 经过 embedding 后张量形状是 _____, embedding 后共有 _____ 个浮点数 (元素个数)。

答案: $(2, 4, 12)$; $(2, 4, 5)$; 40

解析: 1) one-hot 形状为 $(batch, seq_len, V) = (2, 4, 12)$ 。2) embedding 后形状为 $(batch, seq_len, d_e) = (2, 4, 5)$ 。3) 元素个数: $2 \times 4 \times 5 = 40$ 。

33. 给定一个最基本 RNN 的输入维 $d = 3$, 隐状态维 $h = 5$, 词表大小 $V = 7$ 。其矩阵 W_x, W_h, b_h, W_y, b_y 的形状依次为 _____, 总可训练参数量为 _____。

答案: $W_x(5 \times 3), W_h(5 \times 5), b_h(5), W_y(7 \times 5), b_y(7)$; 87

解析: 1) W_x 需要将 3 维输入映射到 5 维, W_h 为隐状态自循环。2) 参数量: $15 + 25 + 5 + 35 + 7 = 87$ 。

34. 双向 RNN (forward + backward) 中, 每个方向都有自己的参数 (W_x, W_h, b_h) 。给定输入维 $d = 4$, hidden 维 $h = 3$, 双向 RNN (仅 encoder, 不含任何输出层) 的总参数量是 _____。

答案: 48

解析: 单向参数量: $12 + 9 + 3 = 24$ 。双向有两套独立的参数: $2 \times 24 = 48$ 。

35. 进行 Next Token Prediction 时, 给定词表大小 $V = 10$, $batch = 3$, 序列长度 $seq_len = 5$ 。输出 logits 的张量形状是 _____; 若只对前 4 个位置计算损失 (最后一个位置不算), 参与计算损失的分布一共有 _____ 个。

答案: (3, 5, 10); 12

解析: 1) 形状为 $(batch, seq_len, V) = (3, 5, 10)$ 。2) 参与计算损失的分布总数 $= batch \times 4 = 3 \times 4 = 12$ 个。

36. 一个 batch 有 4 个序列, 若每个序列长度都是 8 (不引入终止符), 总预测目标 token 数是 _____; 若引入终止符使每个序列长度变为 9, 总预测目标 token 数是 _____。

答案: 28; 32

解析: 1) $4 \times (8 - 1) = 28$ 。2) $4 \times (9 - 1) = 32$ 。

37. 若编码器用最基本 RNN (只算 W_x, W_h, b_h), 之后接线性分类头 (W_c, b_c) 把隐藏态映射到 $C = 6$ 类。给定输入维 $d = 2$, hidden 维 $h = 3$, 总可训练参数量是 _____。

答案: 42

解析: RNN 参数: $3 \times 2 + 3^2 + 3 = 18$ 。分类头参数: $6 \times 3 + 6 = 24$ 。总计 $18 + 24 = 42$ 。

38. 生成过程中, 从起始符开始逐步生成, 每生成 1 个 token 记为 1 步; 一旦生成到终止符就停止。若某次生成序列中普通 token 共 7 个, 之后第 8 个 token 是终止符, 则总共进行了 _____ 步生成。

答案: 8

解析: 每次生成一个 token 即为一步, 共生成 8 个 token, 因此为 8 步。

39. 给定输入维 $d = 3$, hidden 维 $h = 4$, 基本 RNN 的一层参数量是 _____, 标准 LSTM 的一层参数量是 _____, LSTM 的参数量是 RNN 的 _____ 倍。

答案: 32; 128; 4

解析: 1) RNN: $4 \times 3 + 16 + 4 = 32$ 。2) LSTM (拥有四个门): $4 \times 32 = 128$ 。
3) $128/32 = 4$ 倍。

40. 一个双向 RNN 编码器, 每方向输入维 $d = 2$, hidden 维 $h = 3$, 输出端将双向拼接后的向量 (维度 $2h = 6$) 映射到 $V = 5$ 类。其双向编码器参数数量为 _____, 输出层参数数量为 _____。

答案: 36; 35

解析: 1) 单向 $3 \times 2 + 3^2 + 3 = 18$, 双向 $18 \times 2 = 36$ 。2) 输出层 $5 \times 6 + 5 = 35$ 。

41. 在一个 RNN 版的 Encoder-Decoder 模型中, 编码器输入 $d_e = 4$, hidden $h = 3$; 解码器输入 $d_d = 2$, hidden $h = 3$; 输出层 $V = 6$ 。其总参数数量为 _____。

答案: 66

解析: 编码器: $12 + 9 + 3 = 24$ 。解码器: $6 + 9 + 3 = 18$ 。输出层: $6 \times 3 + 6 = 24$ 。总计 $24 + 18 + 24 = 66$ 。

42. RNN 处理 $batch = 2$ 的序列, 序列长度 $seq_len = 7$, 隐藏维 $h = 4$ 。若保存所有时间步的隐藏态, 张量形状是 _____, 总元素个数是 _____。

答案: $(2, 7, 4)$; 56

解析: 1) 形状为 $(batch, seq_len, h) = (2, 7, 4)$ 。2) $2 \times 7 \times 4 = 56$ 。

43. 给定隐藏维 $h = 8$, 词表大小 $V = 20$ 。输出层的 W_y 与 b_y 的形状分别是 _____, 输出层参数数量是 _____。

答案: $W_y(20 \times 8), b_y(20)$; 180

解析: 1) 权重矩阵负责从隐藏态映射到词表。2) 参数量: $20 \times 8 + 20 = 180$ 。

44. 给定语料词频为 $loop : 3, pool : 1, loot : 3, tool : 1, loots : 1$ 。BPE 算法第 1 轮应合并的 pair 是 _____, 其共现频率为 _____; 执行第 1 轮合并后, 第 2 轮应合并的 pair 是 _____, 其共现频率为 _____; 执行到第 3 轮合并后 (合并 $loot$), 单词 $loops$ 的最终 token 序列为 _____。

答案: oo; 9; loo; 7; [loo, p, s]

解析: 1) “oo”共现频率最高, 为 $3(loop) + 1(pool) + 3(loot) + 1(tool) + 1(loots) = 9$ 。2) 第一轮后, loo 出现频率最高为 $3(loop) + 3(loot) + 1(loots) = 7$ 。3) 第三轮合并 $loot$ (频次 4)。对字面上的 $loops$ 进行切分, 只能切为 loo, p, s。

45. 采用 Next Token Prediction 训练序列 [CLS, A, B, C, SEP], 其中预测 B, C, SEP 的分布分别为 p_2, p_3, p_4 。若 p_2 中 B 的概率为 $1/2$, p_3 中 C 的概率为 $1/4$, p_4 中 SEP 的概率为 $1/2$ 。则这三步的交叉熵 (以 2 为底) 分别为 $l_2 =$ _____、 $l_3 =$ _____、 $l_4 =$ _____; 三步平均交叉熵 $L_{avg} =$ _____, 困惑度 $PPL =$ _____; 若 p_3 完整分布为 $(1/8, 1/8, 1/4, 1/4, 1/4)$ 且真值是第 4 个分量, 交叉熵对 logits 的梯度 $\partial l_3 / \partial z =$ _____。

答案: 1; 2; 1; $4/3$; $2 \cdot 2^{1/3}$; $(1/8, 1/8, 1/4, -3/4, 1/4)$

解析: (1) $l_2 = -\log_2(1/2) = 1$, $l_3 = -\log_2(1/4) = 2$, $l_4 = -\log_2(1/2) = 1$ 。(2) 平均交叉熵: $L_{avg} = (1 + 2 + 1)/3 = 4/3$ 。困惑度: $PPL = 2^{4/3} = 2 \cdot 2^{1/3}$ 。(3) 第 3 步真值是 C , 梯度公式为 $p_3 - y = (1/8, 1/8, 1/4, 1/4 - 1, 1/4) = (1/8, 1/8, 1/4, -3/4, 1/4)$ 。

46. 若同时输入 4 个句子、每个句子长度为 10、每个 token 表示维度为 128, 则输入张量形状为 _____。

答案: (4, 10, 128)

解析: 标准的序列输入张量形状为 $(batch_size, sequence_length, hidden_size)$ 。

47. 已知简化 RNN 的隐藏状态更新公式为 $h_t = 0.5h_{t-1} + x_t$, 且 $h_0 = 0, x_1 = 2, x_2 = 0, x_3 = 2$, 则 h_1, h_2, h_3 的值分别为 _____。

答案: 2, 1, 2.5

解析: 逐步计算: $h_1 = 2, h_2 = 0.5(2) + 0 = 1, h_3 = 0.5(1) + 2 = 2.5$ 。

48. 已知简化 RNN 的隐藏状态更新公式为 $h_t = h_{t-1} + x_t$, 且 $h_0 = 1, x_1 = 2, x_2 = -3$, 则 h_2 的值为 _____。

答案: 0

解析: 逐步计算: $h_1 = 1 + 2 = 3, h_2 = 3 - 3 = 0$ 。

49. 在 LSTM 中, 若某一时刻遗忘门 $f_t = 1$ 且输入门 $i_t = 0$, 则当前细胞状态 c_t 与上一时刻细胞状态 c_{t-1} 的关系是 _____。

答案: $c_t = c_{t-1}$

解析: 代入公式: $c_t = 1 \cdot c_{t-1} + 0 \cdot \hat{c}_t = c_{t-1}$ 。此状态实现了记忆的恒等映射。

50. 给定一个标准 LSTM (包含四个门 i, f, o, g), 输入维 $d = 40$, hidden 维 $h = 50$ 。该 LSTM 一层的可训练参数数量是 _____。

答案: 18,200

解析: 单个门参数量: $50 \times 40 + 50^2 + 50 = 4550$ 。四个门总参数量: $4550 \times 4 = 18200$ 。

51. 考虑一个简单 RNN 模型, 其方程为 $h_t = \tanh(W_{xh}x_t + W_{hh}h_{t-1} + b_h)$ 和 $y_t = W_{hy}h_t + b_y$ 。已知输入维度 $d_x = 4$, 隐藏维度 $d_h = 3$, 输出维度 $d_y = 2$ 。该网络的总参数数量为 _____。

答案: 32

解析: $W_{xh} : 3 \times 4 = 12$; $W_{hh} : 3 \times 3 = 9$; $b_h : 3$; $W_{hy} : 2 \times 3 = 6$;

$b_y : 2$ 。总计: 32。

52. 若在序列预测中, 连续三步的正确 token 概率分别为 $1/2$ 、 $1/4$ 、 $1/8$, 则这三步的平均交叉熵(以 2 为底)为 _____。

答案: 2

解析: 交叉熵依次为 1, 2, 3, 平均值为 $(1 + 2 + 3)/3 = 2$ 。

53. 若某一步预测中, 正确 token 的预测概率 $p = 1/2$, 则该步以 2 为底的交叉熵损失为 _____。

答案: 1

解析: 交叉熵 $= -\log_2(0.5) = 1$ 。

54. 在批处理对齐中, 若一个 Batch 包含 3 个句子, 长度分别为 4、2、5。为了构建整齐的张量输入, 将所有句子补齐到该 Batch 中的最大长度, 总共需要填充 _____ 个 [PAD] 符号。

答案: 4

解析: 最大长度为 5。三句需填充的数量分别为 $(5-4)+(5-2)+(5-5) = 1 + 3 + 0 = 4$ 个。

55. 假设词表大小 $V = 10000$, 模型通过 Softmax 对当前时间步预测概率最高的单词为 “the” 且概率 $P(\text{“the”}) = 0.7$, 则词表中剩余的 9999 个单词的预测概率之和是 _____。

答案: 0.3

解析: Softmax 函数保证了所有类别的概率之和为 1, 剩余概率和 $= 1 - 0.7 = 0.3$ 。

56. 假设词表大小 $V = 2000$, 采用词嵌入 (Word Embedding) 技术将独热编码向量降维至 $d = 50$, 则词嵌入向量的维度是独热编码向量维度的 _____ (即压缩倍数为 40)。

答案: $1/40$

解析：压缩倍数 = $2000/50 = 40$ ，维度占比为 $50/2000 = 1/40$ 。

57. 循环神经网络 (RNN) 的一个核心特性是参数共享。若输入序列包含 8 个单词 (Token)，在模型的前向传播过程中，共享的输入权重矩阵 U 被使用了 _____ 次。

答案： 8

解析：序列长度为 8 即有 8 个时间步，每个时间步都复用一次相同的权重矩阵 U 。

58. 在双向循环神经网络中，如果单方向的隐藏状态向量维度 $h = 256$ ，那么在每一个时间步，将两个方向的隐藏状态拼接 (Concatenate) 后，得到的最终隐藏状态向量的维度是 _____。

答案： 512

解析：拼接后的维度 = $h_{forward} + h_{backward} = 256 + 256 = 512$ 。

59. 在 Next Token Prediction 任务中，如果模型对下一个真实词元的预测概率 P 达到了 1.0，利用简化交叉熵损失公式 $L = -\log(P)$ ，计算此时的损失值是 _____。

答案： 0

解析： $L = -\log(1.0) = 0$ ，表示完全没有误差。

60. 在 LSTM 中，假设某一关键时刻遗忘门 $f_t = 1$ ，输入门 $i_t = 0$ 。若上一时刻的细胞状态 $C_{t-1} = 5$ ，则更新后的细胞状态 $C_t =$ _____。

答案： 5

解析：代入公式： $C_t = 1 \cdot 5 + 0 \cdot \hat{C}_t = 5$ ，完美体现了 LSTM 记忆无损传递的能力。