

一、选择题

Transformer 核心优势与注意力机制

1. Transformer 相比基于 RNN 的模型，一个核心结构性优势是

- A. 使用了更复杂的损失函数
- B. 引入了注意力机制以捕获全局信息
- C. 依赖更大的词表规模
- D. 必须使用更深的网络层数

答案： B

解答： Transformer 的核心优势在于注意力机制，使模型能够直接建立任意位置之间的依赖关系，从而更好地捕捉全局语义信息。

2. 下列哪一项最准确描述了” 缩放点积注意力” 的计算？

- A. 先算 QK^T ，再按列做归一化后与 V 相乘
- B. 先算 $\text{softmax}(QK^T/\sqrt{d_k})$ ，再与 V 相乘
- C. 先算 $\text{softmax}(QV^T)$ ，再与 K 相乘
- D. 先把 Q, K, V 拼接后做一次线性变换

答案： B

解答：缩放点积注意力为 $\text{Attention}(Q, K, V) = \text{softmax}(QK^T/\sqrt{d_k})V$ 。

3. 在注意力机制中，引入 Key、Query、Value 的主要目的在于

- A. 降低模型参数数量
- B. 将输入统一映射到相同维度
- C. 通过不同线性变换提取不同信息
- D. 避免使用非线性激活函数

答案： C

解答： Key、Query、Value 通过不同的线性变换得到，使模型可以从不同角度对输入信息进行建模，从而计算关联关系。

4. 注意力机制中使用 softmax 的主要作用是

- A. 增加非线性表达能力
- B. 放大较大的注意力值
- C. 将关联强度归一化为概率分布
- D. 减少浮点数计算误差

答案： C

解答： softmax 将原始关联分数转换为非负、和为 1 的权重，便于进行加权求和

5. 在自注意力中，第 i 个位置对第 j 个位置的注意力权重表示

- A. 位置 i 与位置 j 的欧氏距离
- B. 位置 i 输出对位置 j 信息的关注程度
- C. 位置 j 对位置 i 的损失贡献
- D. 两个位置的嵌入向量是否相同

答案： B

解答： 注意力权重描述的是当前位置在生成表示时，对其他位置信息的依赖程度。

6. 在自注意力中，注意力权重矩阵的第 t 行表示：

- A. 第 t 个 key 对所有 query 的贡献
- B. 第 t 个 query 对所有 key 的注意力分布
- C. 第 t 个 value 的维度
- D. 第 t 个 token 的词表概率

答案： B

解答： 每一行对应一个 query 位置，对所有 key 的权重。

7. 注意力机制计算公式为 $\text{Attention}(Q, K, V) = \text{softmax}(\frac{QK^T}{\sqrt{d_k}})V$ ，其中 d_k 代表：

- A. 词表大小
- B. 序列长度
- C. Key 向量的维度

- D. Batch Size

答案： C

解答： d_k 是 Query 和 Key 的维度，用于缩放点积。

8. 计算注意力得分时，将 QK^T 的结果除以 $\sqrt{d_k}$ 的”缩放 (Scaled)”操作是为了：

- A. 降低计算复杂度，支持更长的序列
- B. 防止点积数值过大导致 Softmax 梯度趋于平缓
- C. 将输出向量强制约束在 0 到 1 区间
- D. 增加模型的非线性表达能力

答案： B

解答： 维度过高时点积可能很大，导致 Softmax 进入饱和区出现梯度消失，除以 $\sqrt{d_k}$ 可以缓解。

9. 若实现注意力时忘记除以 $\sqrt{d_k}$ ，可能出现的现象是：

- A. 参数量显著增加
- B. 注意力权重变得极其稀疏（趋于 One-hot）
- C. 只能理解短句
- D. 位置编码丢失

答案： B

解答： 点积过大使 Softmax 饱和，导致权重集中在单一位置。

10. 若输入序列长度为 L ，Embedding 维度为 D ，则 Self-Attention 产生的时间复杂度（忽略头数影响）主要与哪项成正比？

- A. $L \times D^2$
- B. $L^2 \times D$
- C. $L^2 \times D^2$
- D. L

答案： B

解答：计算 QK^T 需要 $O(L^2D)$ ，计算 $A \times V$ 也需要 $O(L^2D)$ 。

位置编码

1. Transformer 使用位置编码的主要原因是

- A. 模型本身不包含序列顺序信息
- B. 位置编码可以减少参数量
- C. 位置编码代替了嵌入层
- D. 位置编码用于词表扩展

答案：A

解答：注意力机制本身是对集合操作，不区分顺序，因此需要显式加入位置信息。

2. 如果去掉位置编码但保留注意力机制，模型最直接的问题是

- A. 无法计算注意力权重
- B. 无法区分不同 token 的相对顺序
- C. 无法进行反向传播
- D. 无法使用 softmax

答案：B

解答：注意力机制本身对顺序不敏感，去掉位置编码会导致顺序信息丢失。

3. 关于位置编码，下列说法正确的是：

- A. 位置编码只需要加在 Q 上
- B. 位置编码必须是可训练的
- C. 位置编码用于向模型提供序列顺序信息
- D. 位置编码只在解码器中使用

答案：C

解答：自注意力本身不显式编码顺序，位置编码把顺序信息注入到表示中。

4. RoPE（旋转位置编码）的核心数学性质是 $R_i R_j^T = ?$

- A. R_{i+j}
- B. $R_{i \times j}$
- C. R_{i-j}
- D. I

答案： C

解答： RoPE 构造旋转矩阵满足相对位置性质，即内积只与相对距离 $i - j$ 有关。

Mask 机制与解码

1. 在解码阶段引入 Mask 的主要目的是

- A. 提高模型的泛化能力
- B. 减少注意力计算复杂度
- C. 防止模型看到未来信息
- D. 防止梯度消失

答案： C

解答： Mask 使当前位置只能关注自身及之前的内容，保证生成过程符合自回归假设。

2. 在因果掩码（causal mask）中，被掩码的位置通常在打分矩阵中被替换为：

- A. 0
- B. $-\infty$
- C. 1
- D. $+\infty$

答案： B

解答： 将被屏蔽位置的 logits 设为 $-\infty$ （或足够小），softmax 后该位置概率为 0。

3. 关于 Mask 的作用，下列说法正确的是：

- A. Mask 会改变 V 的维度
- B. Mask 通过屏蔽某些位置防止其被注意到
- C. Mask 只用于 FFN
- D. Mask 会让 softmax 的每行和不为 1

答案： B

解答： Mask 通过将某些 logits 设为极小值来屏蔽注意力。

4. 训练解码器时若不使用 Mask，会导致：

- A. 无法预测任何字符
- B. 编码器特征无法传递
- C. 模型学会直接复制标签中的下一个词
- D. 层归一化失效

答案： C

解解： 模型会发现”作弊”路径，通过看右侧词来完美预测。

词嵌入与输出层

1. 嵌入层中词向量通常

- A. 由人工规则固定生成
- B. 在训练过程中保持不变
- C. 随机初始化并参与训练
- D. 只能是 one-hot 形式

答案： C

解答： 词向量一般随机初始化，并在训练过程中不断更新以适应任务。

2. 语言模型输出层通常将模型输出映射到词表维度，并通过哪种映射转化为概率分布。

- A. ReLU
- B. Sigmoid

- C. Softmax
- D. Tanh

答案： C

解答： Softmax 将投影结果转换为词表上的概率分布。

3. 使用交叉熵损失训练语言模型时，模型输出通常是：

- A. 一个标量分数
- B. 一个句子向量
- C. 词表大小维度的 logits
- D. 注意力权重矩阵

答案： C

解答：输出层把隐状态映射到词表大小得到 logits，再用 softmax 得到每个 token 的概率。

4. 如果模型隐状态维度为 d_{model} ，自注意力头数为 h ，query，key 向量维度为 d_k ，词表大小为 V ，输出投影层的线性映射通常把隐状态映射到：

- A. $\mathbb{R}^{d_{\text{model}}}$
- B. $\mathbb{R}^h$
- C. $\mathbb{R}^V$
- D. $\mathbb{R}^{d_k}$

答案： C

解答：输出层产生词表大小维度的 logits。

5. Transformer 输出部分的 Linear 层和 Softmax 层共同实现了：

- A. 高维向量还原为位置编码
- B. 将特征映射到词表空间并转化为概率分布
- C. 对特征进行最后的降维
- D. 情感二分类判断

答案： B

解答：Linear 映射维度，Softmax 转化为预测各词的概率。

6. 在 Next Token Prediction 中，如果词表大小为 50,000，模型输出的 Logits 向量维度是：

- A. 512
- B. 50,000
- C. 1024
- D. 1

答案：B

解答：输出层是对词表中每个词的打分，维度等于词表大小。

多头注意力机制

2. 多头注意力相比单头注意力，其优势最合理的解释是

- A. 单头注意力无法训练
- B. 多头注意力减少了计算复杂度
- C. 不同头可以学习不同关联模式
- D. 多头注意力不需要位置编码

答案：C

解答：多头注意力通过多个子空间并行建模不同类型的关系，提高表达能力。

3. 多头注意力中的 W_O 的主要作用是：

- A. 为每个头生成不同的 Q, K, V
- B. 把各头输出拼接后的向量映射回 d_{model} 维
- C. 对注意力权重做归一化
- D. 实现序列的右移操作

答案：B

解答：各头输出拼接后维度为 $h \cdot d_v$ ， W_O 将其投影回模型维度 d_{model} 。

4. 关于”多头注意力 (Multi-Head Attention) “，描述最准确的是：

- A. 通过增加网络层数提高特征提取能力
- B. 允许模型在不同的子空间中同时学习多样的语义信息
- C. 专门为多 GPU 并行训练设计的硬件算法
- D. 对同一组特征重复计算多次以降低泛化误差

答案： B

解答：不同的”头”关注点不同（如语法关系、指代关系），从而提供更丰富的特征。

5. 当注意力头数 h 增加但 d_{model} 不变时，常见做法是：

- A. 保持每个头维度不变并让总维度变大
- B. 减少每个头的维度以保持总维度 d_{model} 不变
- C. 让 d_{model} 自动变小
- D. 删除 W_O

答案： B

解答：通常令每头维度为 d_{model}/h ，以保持拼接后维度一致。

6. 假设 $d_{\text{model}} = 512$ ，使用 8 个注意力头，则每个头的维度 d_k 通常设为：

- A. 128
- B. 64
- C. 32
- D. 512

答案： B

解答： $512/8 = 64$ 。

前馈网络 (FFN)

1. 前馈全连接网络 (FNN) 在 Transformer 中的特点是

- A. 在整个序列上统一计算
- B. 不同位置共享同一结构
- C. 只对第一个 token 作用
- D. 用于计算注意力权重

答案： B

解答： FNN 对每个 token 独立作用，但结构和参数在所有位置之间共享。

2. Transformer 中的前馈神经网络 (FFN) 作用是：

- A. 在序列维度上进行跨词语的语义整合
- B. 在每个位置上独立进行非线性变换，增强特征表达
- C. 为模型提供序列中词语的先后顺序
- D. 对多头注意力的输出进行大幅降维

答案： B

解答： FFN 是逐位置 (Point-wise) 应用的，增加模型的非线性建模能力。

3. 在 Transformer 的 FFN 层中，通常包含几次线性变换 (Linear Projection)?

- A. 1 次
- B. 2 次
- C. 4 次
- D. 0 次

答案： B

解答： $x \rightarrow \text{Hidden}$ (1 次), $\text{Hidden} \rightarrow \text{Output}$ (1 次)。

残差连接

1. 残差连接在 Transformer 中的主要作用是

- A. 引入额外的非线性

- B. 增加网络深度
- C. 改变注意力计算方式
- D. 改善梯度传播

答案： D

解答： 残差连接有助于缓解梯度消失或爆炸，使深层网络更容易训练。

2. 残差连接 (Residual Connection) 的公式是：

- A. $y = f(x)$
- B. $y = f(x) + x$
- C. $y = f(x) \times x$
- D. $y = f(x + 1)$

答案： B

解答： ResNet 的核心思想，将输入直接加到输出上。

层归一化 (LayerNorm)

1. LayerNorm 的归一化操作是

- A. 在 batch 维度上进行
- B. 对每个 token 的特征维度进行
- C. 对所有 token 一起进行
- D. 只对输出层进行

答案： B

解答： LayerNorm 是逐 token 的归一化方式，对该 token 的特征维度进行标准化。

2. 使用 Pre-LayerNorm 结构的一个主要优势是

- A. 表达能力更强
- B. 训练过程更稳定
- C. 模型参数更少
- D. 推理速度更快

答案： B

解答： Pre-LayerNorm 有利于梯度稳定传播，通常训练更加稳定。

3. LayerNorm 与 BatchNorm 的主要差异是：

- A. 是否使用残差连接
- B. 归一化时统计量的计算维度不同
- C. 是否包含激活函数
- D. 是否需要位置编码

答案： B

解答： LayerNorm 在特征维统计；BatchNorm 在 batch 维统计。

4. Pre-LN 架构中，一个典型子层的形式是：

- A. $\text{LN}(x + \text{sublayer}(x))$
- B. $x + \text{sublayer}(\text{LN}(x))$
- C. $\text{sublayer}(x) + \text{sublayer}(x)$
- D. $\text{LN}(\text{sublayer}(\text{LN}(x)))$

答案： B

解答： Pre-LN 先 LN 再进入子层，最后与残差相加。

训练与解码

1. Next Token Prediction 框架的核心目标是

- A. 预测整个序列
- B. 判断文本情感类别
- C. 根据前文预测下一个 token
- D. 重构输入文本

答案： C

解答： 该框架通过建模条件概率来预测序列中下一个 token。

2. 贪婪解码的特点是

- A. 每一步随机采样
- B. 搜索所有可能序列
- C. 每一步选择当前概率最大的 token
- D. 需要额外温度参数

答案： C

解答：贪婪解码在每一步直接选择当前概率最高的 token，计算简单但可能不全局最优。

3. 在 Next Token Prediction 框架下，交叉熵损失的优化目标可以理解为

- A. 最大化预测 token 的概率
- B. 最小化词向量之间的距离
- C. 最小化注意力权重的方差
- D. 最大化序列长度

答案： A

解答：交叉熵损失鼓励模型对真实下一个 token 赋予更高概率。

4. 关于 Transformer 训练，说法正确的是：

- A. 必须串行输入单词到编码器
- B. 编码器可以并行处理整个序列
- C. 无法应用于图像分类
- D. 属于完全无监督学习

答案： B

解答：自注意力机制允许一次性计算整句。

5. Transformer 在训练中常用的损失函数是：

- A. 交叉熵损失 (Cross Entropy)
- B. 均方误差 (MSE)
- C. 对比损失
- D. 感知损失

答案： A

解答：对于词分类任务，交叉熵是标准选择。

6. 对 one-hot 标签的交叉熵损失 $-\log p_y$ ，若模型把真实类概率从 0.2 提升到 0.4，损失会：

- A. 变大
- B. 变小
- C. 不变
- D. 先变大再变小

答案： B

解答：真实类概率越大， $-\log p_y$ 越小。

其他

1. 将 logits 同时加上同一个常数 c ，softmax 输出会：

- A. 全部变为 0
- B. 全部变为 1
- C. 不变
- D. 只改变最大值位置

答案： C

解答：softmax 对整体平移不变。

2. 在 Encoder-Decoder 结构中，解码器的”跨注意力 (Cross-Attention)”其 Query 来自于：

- A. 编码器最后一层的输出
- B. 解码器上一子层的输出
- C. 输入序列的位置编码
- D. 预训练模型的静态词表

答案： B

解答：跨注意力用解码器的状态去“查询”编码器提供的上下文信息 (Key/Value)。

3. 关于 Transformer 编码器与解码器的注意力，下列说法正确的是：

- A. 编码器只包含因果自注意力
- B. 解码器的自注意力通常带因果掩码
- C. 编码器-解码器注意力使用同一序列生成 Q, K, V
- D. 解码器不需要 FFN

答案： B

解答：解码器为防止看见未来 token，会在自注意力中使用因果掩码。

4. Johnson-Lindenstrauss 引理主要讨论的是：

- A. 神经网络的收敛性
- B. 降维过程中的距离保持性
- C. 梯度的稳定性
- D. 卷积的有效性

答案： B

解答：该引理与 Embedding 降维和距离保持有关。

二、判断题

Transformer 核心优势与注意力机制

1. Transformer 能够直接建模序列中任意两个位置之间的关系，而不依赖递归结构。

答案： T

解答：注意力机制允许任意位置之间直接计算关联，因此不需要像 RNN 那样按时间步递归处理。

2. Transformer 的提出主要是为了解决 RNN 模型在处理长序列时存在的梯度消失和无法并行计算的问题。

答案： T

解答： Transformer 基于 Attention 机制，能够并行处理整个序列，且任意两个位置的距离为 1，有效解决了 RNN 的长依赖和串行问题。

3. 在 Self-Attention 机制中，Query、Key、Value 三个矩阵的输入来源必须完全不同。

答案： F

解答： Self-Attention 的特点正是 Q, K, V 均来自同一个输入源（通常是上一层的输出），故称“自”注意力。

4. 即使 Key-Value 对的数量发生变化，注意力机制的计算流程仍保持“计算关联—归一化—加权求和”的基本形式。

答案： T

解答： Key-Value 对数量可以变化，但注意力机制的核心计算结构不变。

5. 在 Attention 公式中，除以 $\sqrt{d_k}$ 是为了防止点积结果过大导致 Softmax 梯度消失。

答案： T

解答： 缩放点积注意力（Scaled Dot-Product Attention）的核心设计。

6. 计算自注意力时，输入序列的每一个词都会与自己计算相关性。

答案： T

解答： 自注意力计算包括当前位置与自身。

注意力权重、Mask 与解码

1. 在注意力机制中，注意力权重越大，说明当前 token 对对应位置的信息依赖越强。

答案： T

解答： 注意力权重刻画的是信息关联强度，权重越大，说明该位置信息越重要。

2. 在解码阶段加入 Mask，可以防止模型在预测时使用未来的信息。

答案： T

解答： Mask 限制注意力只能关注当前位置及之前的位置，从而保证生成过程的因果性。

3. 如果在解码阶段移除 Mask，模型在训练时仍可能得到看似合理的结果，但生成逻辑会受到破坏。

答案： T

解答： 去掉 Mask 会导致模型使用未来信息，从而违背生成任务的因果约束。

4. 在因果 (causal) 掩码下，第 t 个位置在计算注意力时可以使用第 $t+1$ 个位置的信息。

答案： F

解答： 因果掩码会屏蔽未来位置 ($t+1, t+2, \dots$)，保证第 t 个位置只能看见不超过 t 的位置。

5. 掩码操作是将未来位置的得分设为负无穷，而非直接设为 0。

答案： T

解答： 设为 $-\infty$ 才能使 $e^{-\infty} = 0$ ，设为 0 会导致概率不为 0。

6. 如果没有掩码，注意力权重矩阵的每一行之和不一定为 1。

答案： F

解答： 每一行经过 softmax 后必然和为 1（掩码只是把某些位置打分设为 $-\infty$ ，softmax 仍归一化）。

7. 贪婪解码每一步都选择当前概率最大的 token，因此一定能找到全局概率最大的序列。

答案： F

解答： 逐步局部最优不保证全局最优；有时需要 beam search 等策略探索更优序列。

8. 若 QK^T 的某一行对所有 key 的打分都相同，则该行 softmax 后得到均匀分布。

答案： T

解答： softmax 对相同输入返回相同概率，因此若打分都相等，权重为 $1/n$ (n 为 key 数量)。

位置编码

2. 如果不使用任何位置编码，仅靠自注意力层本身无法区分词序的先后。

答案： T

解答： 自注意力对输入的排列本质上是“置换等变”的；缺少额外的位置信息时，模型难以仅凭注意力判断顺序差异。

3. 旋转位置编码 (RoPE) 是通过在 Embedding 向量上直接相加绝对位置向量来实现的。

答案： F

解答： RoPE 是通过将位置信息融入旋转矩阵，对 Q 和 K 向量进行旋转操作（乘法），而非简单的相加。

4. 相对位置编码相比绝对位置编码，通常具有更好的长度外推 (Extrapolation) 能力。

答案： T

解答： 相对位置编码关注 token 间的距离，这使得模型更容易泛化到比训练时更长的序列。

5. RoPE 具有远程衰减的性质，即随着相对距离增加，注意力分数会有自然的衰减趋势。

答案： T

解答： RoPE 的高频分量使得长距离的点积期望值趋向于 0，具备一定的长距离衰减特性 (Long-term Decay)。

词嵌入、参数与初始化

1. Transformer 中的嵌入向量通常在训练开始时随机初始化，并通过训练不断更新。

答案： T

解答： 嵌入向量是可训练参数，会随着训练逐步学习到有意义的表示。

2. 在注意力机制中，不同输入 token 的 Key、Query、Value 一定是完全相同的向量。

答案： F

解答： Key、Query、Value 通过不同的线性变换从输入中获得，目的是提取不同类型的信息。

层归一化 (LayerNorm)

2. LayerNorm 的归一化操作是对每个 token 的特征维度进行。

答案： T

解答： LayerNorm 是逐 token 的归一化方式，对该 token 的特征维度进行标准化。

3. LayerNorm 通常是对一个 Batch 中的所有样本在同一维度上进行归一化。

答案： F

解答：这是 BatchNorm 的做法。LayerNorm 是对单个样本的所有特征维度进行归一化，独立于 Batch Size。

4. 在 Transformer 中，引入归一化模块有助于提升训练过程的稳定性。

答案： T

解答：归一化可以平衡各层输入分布，减少梯度不稳定带来的影响。

5. 使用 Pre-LayerNorm 结构的一个主要优势是训练过程更稳定。

答案： T

解答：Pre-LayerNorm 有利于梯度稳定传播，通常训练更加稳定。

6. Pre-LN 架构是指先做 LayerNorm 再进入子层，再做残差相加。

答案： T

解答：Pre-LN 的形式常写作 $x + \text{sublayer}(\text{LN}(x))$ 。

7. 层归一化有助于防止数值过大或过小导致训练困难。

答案： T

解答：LN 稳定了激活值的分布。

残差连接、前馈网络与并行性

1. 残差连接的引入有助于缓解深层网络中的训练困难问题。

答案： T

解答：残差连接改善了梯度传播，使得深层模型更容易训练。

2. 残差连接公式为 $y = x + f(x)$ ，目的是缓解梯度消失。

答案： T

解答：残差结构允许梯度在反向传播时直接流过。

3. 前馈全连接网络在 Transformer 中是对整个序列一次性联合计算的。

答案： F

解答：前馈网络是逐 token 作用的，但在不同 token 之间共享同一组参数。

4. 前馈网络（FFN）在 Transformer 中通常对序列的每个位置分别、共享参数地作用。

答案： T

解答：FFN 是 position-wise 的：对每个 token 表示独立通过同一组全连接层。

5. Transformer 的计算过程可以在序列维度上进行并行处理。

答案： T

解答：由于不依赖递归结构，Transformer 在训练和推理中具备良好的并行性。

多头注意力机制

1. 多头注意力的每个头都使用完全相同的线性映射参数。

答案： F

解答：不同注意力头对应不同的线性映射，使模型可以关注不同类型的关联信息。

2. 多头注意力机制（Multi-Head Attention）的输出结果是直接将各头的输出相加得到的。

答案： F

解答：是将各头的输出拼接（Concat）后，再经过一个线性变换 W^O 融合。

3. 多头注意力可以看作并行地不同子空间中计算若干组注意力，然后再拼接并线性映射。

答案： T

解答：每个头使用不同的线性映射得到不同的 Q, K, V 子空间；各头输出拼接后再经 W_O 投影。

4. 多头注意力相比单头注意力，其优势最合理的解释是不同头可以学习不同关联模式。

答案： T

解答：多头注意力通过多个子空间并行建模不同类型的关系，提高表达能力。

5. 多头注意力中，每个注意力头提取的信息是一模一样的。

答案： F

解答：不同头由不同参数初始化，学习到的特征空间不同。

6. 若 $d_{\text{model}} = 512$ 且 $h = 8$ ，常见设置是每个头的 $d_k = 64$ 。

答案： T

解答：典型多头注意力令 $d_k = d_v = d_{\text{model}}/h = 512/8 = 64$ 。

训练目标与损失函数

1. **Next Token Prediction** 的训练目标是根据已有序列预测下一个 token。

答案： T

解答：该框架通过利用上下文信息来预测下一位置的输出。

2. 在自回归语言模型中，训练时常用”右移一位”的输入来预测下一个 token。

答案： T

解答：即 Next Token Prediction：用前缀预测后续 token，标签对应下一位置的真实 token。

3. Next Token Prediction 任务属于无监督学习（或自监督学习），因为它不需要人工标注的标签。

答案： T

解答：这是大语言模型预训练的核心范式，数据自带标签（下一个词）。

4. 交叉熵损失只依赖于真实类别对应的预测概率 p_y ，形式为 $-\log p_y$ 。

答案： T

解答：对 one-hot 标签，交叉熵为 $\mathcal{L} = -\sum_i y_i \log p_i = -\log p_y$ 。

5. 均方误差（MSE）常用于分类任务的损失函数。

答案： F

解答：MSE 常用于回归任务；分类任务通常使用交叉熵损失（Cross Entropy）。

其他

1. 语言模型输出层通常将模型输出映射到词表维度，并转化为概率分布。

答案： T

解答：通过投影和 softmax 操作，模型输出被转化为对各个词的概率预测。

2. 贪婪解码在每一步都会选择当前概率最大的 token 作为输出。

答案： T

解答：这是贪婪解码的核心特点，计算效率高，但可能不是全局最优。

3. 对于同样的 **logits**, **softmax** 输出与 **logits** 的整体平移无关 (加同一常数不变)。

答案：T

解答： $\text{softmax}(z)$ 与 $\text{softmax}(z + c)$ 相同，因为分子分母都乘以 e^c 可约掉。

4. **Softmax** 函数的输出值之和恒等于 1。

答案：T

解答：**Softmax** 保证输出符合概率分布特征。

5. 在自注意力计算中，若两个词点积为 0，**Softmax** 后其权重也为 0。

答案：F

解答： $e^0 = 1$ ，经 **Softmax** 后仍会有非零权重。

6. **Transformer** 架构由于其通用性，目前也被广泛用于图像分类。

答案：T

解答：如 Vision Transformer (ViT) 应用于图像领域。

7. **Johnson-Lindenstrauss** 引理表明，将高维数据随机投影到低维空间后，点之间的欧氏距离会发生剧烈变化，无法保持原结构。

答案：F

解答：引理恰恰表明距离可以“近似保持”，这是 **Embedding** 降维有效的理论基础之一。

三、填空与计算题

注意力计算（点积、缩放、加权求和）

1. 给定 $Q = [1, 1]$, $K = [2, 0]$, 计算点积注意力分数 $Q \cdot K =$ _____。

答案： 2

解答： $1 \times 2 + 1 \times 0 = 2$ 。

2. 设 $Q = (2, -1, 0, 1)$, $K = (1, 3, -2, 0)$, 且 $d_k = 4$ 。计算缩放点积 $s = \frac{QK^\top}{\sqrt{d_k}}$ 的值：_____。

答案： $-\frac{1}{2}$

解答：点积 $QK^\top = 2 \cdot 1 + (-1) \cdot 3 + 0 \cdot (-2) + 1 \cdot 0 = -1$, 再除以 $\sqrt{4} = 2$, 得 $s = -\frac{1}{2}$ 。

3. 若注意力分布 $\alpha = (\frac{4}{7}, \frac{2}{7}, \frac{1}{7})$, 且 $V_1 = (1, 0), V_2 = (0, 3), V_3 = (2, 1)$ 。请问注意力输出的第二个分量 $o_2 =$ _____。

答案： 1

解答： $o_2 = \frac{4}{7} \cdot 0 + \frac{2}{7} \cdot 3 + \frac{1}{7} \cdot 1 = \frac{6}{7} + \frac{1}{7} = 1$ 。

4. 注意力权重向量为 $[0.7, 0.3]$, 对应的 Value 向量组为 $[1, 2]$ 和 $[3, 4]$, 对其进行加权求和处理, 得到的输出向量是_____。

答案： $[1.6, 2.6]$

解答：加权求和为权重与对应 Value 向量逐元素相乘后相加, 计算过程： $0.7 \times [1, 2] + 0.3 \times [3, 4] = [0.7 + 0.9, 1.4 + 1.2] = [1.6, 2.6]$ 。

5. 注意力原始关联强度为 40, Key 向量维度为 25, 对其进行缩放处理后, 得到的缩放后关联强度为_____。

答案： 8

解答：缩放处理为原始关联强度除以 Key 维度的平方根, 计算过程： $\sqrt{25} = 5, 40 \div 5 = 8$ 。

6. Query 矩阵维度为 4×32 , Key 矩阵维度为 4×32 , 对二者进行关联强度计算 (忽略缩放), 得到的关联强度矩阵维度为 _____ (格式: $a \times b$)。

答案: 4×4

解答: 关联强度计算为 Query 矩阵与 Key 矩阵转置相乘, 矩阵乘法维度规则为“前矩阵行数 $\times$ 后矩阵列数”, Key 转置后维度为 32×4 , 因此结果维度为 4×4 。

7. Attention 矩阵计算:

$$Q = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}, K = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \end{bmatrix}, d_k = 4. \text{ 计算 } \text{Softmax}(QK^T/\sqrt{d_k}) = \underline{\hspace{2cm}}$$

(保留两位小数, $e = 2.72, e^{0.5} \approx 1.65, e^0 = 1$)。

答案: $\begin{pmatrix} 0.50 & 0.50 \\ 0.38 & 0.62 \end{pmatrix}$

解答:

$$1) K^T = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}.$$

$$2) QK^T/\sqrt{d_k} = \begin{bmatrix} 0.5 & 0.5 \\ 0 & 0.5 \end{bmatrix}.$$

$$3) \text{ 第一行 } [1, 1] \text{ Softmax: } e^{0.5}/(e^{0.5} + e^{0.5}) = 0.5, 0.5.$$

$$4) \text{ 第二行 } [0, 1] \text{ Softmax: } e^0/(e^0 + e^{0.5}) = 1/(1 + 1.65) \approx 0.38, \\ e^{0.5}/(1 + 1.65) \approx 0.62.$$

softmax 归一化

1. 给定注意力分数 $s = [1, 2]$, 使用 $\text{softmax}(s_i) = \frac{e^{s_i}}{e^1 + e^2}$ 计算 $\text{softmax}(s) = \underline{\hspace{2cm}}$ (保留两位小数, $e \approx 2.7, e^2 \approx 7.4$)。

答案: $[0.27, 0.73]$

解答：

$$e^1 \approx 2.7, \quad e^2 \approx 7.4, \text{softmax}(s) \approx [0.27, 0.73]$$

2. 给定 logits $z = (\ln 3, 0, \ln 6)$ 。令 $z' = z - \ln 3$, $\text{softmax}(z)$ _____ $\text{softmax}(z')$ 。此时第三类概率 $p_3 = \text{softmax}(z')_3$ _____。

答案：=, $\frac{3}{5}$

解答：加减常数不影响 softmax 结果； $z' = (0, -\ln 3, \ln 2)$ ，指数为 $(1, \frac{1}{3}, 2)$ ，归一化和为 $1 + \frac{1}{3} + 2 = \frac{10}{3}$ ，故 $p_3 = \frac{2}{10/3} = \frac{3}{5}$ 。

3. 给定向量 $x = [2, 2, 2, 2]$ ，对其进行 Softmax 操作。则输出向量的第 1 个元素的值为 _____。

答案：0.25

解答：所有元素相等，Softmax 分配均匀概率，即 1/4。

4. 给定 logits $z = (\ln 4, 0, \ln 3)$ ，令 $\alpha = \text{softmax}(z)$ 。设 $V_1 = (2, 0, 1)$, $V_2 = (0, 1, 0)$, $V_3 = (1, 1, 2)$ 。注意力输出 $o = \sum_i \alpha_i V_i =$ _____。

答案： $[\frac{11}{8}, \frac{1}{2}, \frac{5}{4}]$

解答：指数为 $(4, 1, 3)$ ，和为 8，权重 $(\frac{1}{2}, \frac{1}{8}, \frac{3}{8})$ 。 $o_1 = 1 + 0 + \frac{3}{8} = \frac{11}{8}$, $o_2 = 0 + \frac{1}{8} + \frac{3}{8} = \frac{1}{2}$, $o_3 = \frac{1}{2} + 0 + \frac{3}{4} = \frac{5}{4}$ 。

Mask 相关计算

1. 若当前位置 $t = 3$ （从 1 开始），query 对 4 个 key 的打分为 $s = (\ln 4, \ln 2, 0, \ln 8)$ 。使用因果 mask 后，做 softmax 得到对第二个 token 的注意力 $\alpha_2 =$ _____。

答案： $\frac{2}{7}$

解答：softmax 对 $(\ln 4, \ln 2, 0)$ 等价于对 $(4, 2, 1)$ 归一化： $\alpha_2 = \frac{2}{4+2+1} = \frac{2}{7}$ 。

2. 当前位置 $t = 2$, 对 3 个 key 的 logits 为 $z = (\ln 1, \ln 4, \ln 2)$, 因果 mask 后对可见项做 softmax 得权重 (α_1, α_2) 。若 $V_1 = 5$ 、 $V_2 = 1$ (标量 value), 则输出 $o = \alpha_1 V_1 + \alpha_2 V_2 =$ _____。

答案: $\frac{9}{5}$

解答: 可见 logits 为 $(0, \ln 4)$, 指数为 $(1, 4)$, 权重 $(\frac{1}{5}, \frac{4}{5})$ 。输出 $o = \frac{1}{5} \cdot 5 + \frac{4}{5} \cdot 1 = \frac{9}{5}$ 。

3. 若序列长度 $L = 10$, 使用 Mask 机制。在 Attention 矩阵中, 需要被 Mask 掉(设为负无穷)的元素个数通常是 _____ (不包含对角线)。

答案: 45

解答: 上三角矩阵 (不含对角线) 元素个数 $(10 \times 10 - 10)/2 = 45$ 。

层归一化 (LayerNorm) 计算

1. 给定 token 特征 $x = [2, 4]$, 使用 $\text{LayerNorm}(x) = \frac{x - \mu}{\sigma}$, 计算归一化结果为 _____。

答案: $[-1, 1]$

解答: $[(2 - 3)/1, (4 - 3)/1] = [-1, 1]$ 。

2. 考虑输入 $x = [1, 3]$, 请问其经过 LayerNorm 作用后的均值是多少?

解答: LayerNorm 会使结果均值为 0。

答案: 0。

3. 已知 LayerNorm 的输入向量 $x = [0, 10, 20]$ 。计算其均值 μ 为 _____。

答案: 10

解答: $(0 + 10 + 20)/3 = 10$ 。

4. 接上题，若不考虑 ϵ ，该向量 $x = [0, 10, 20]$ 的方差 σ^2 为_____。

答案：66.67 (或 $200/3$)

解答： $((0 - 10)^2 + (10 - 10)^2 + (20 - 10)^2)/3 = (100 + 0 + 100)/3 = 200/3 \approx 66.67$ 。

5. 向量 $x = [1, 3]$ ， $\gamma = 1, \beta = 0, \epsilon = 0$ 。计算 $\text{LayerNorm}(x) =$ _____。

答案： $[-1, 1]$ 。

解答：

1) 均值 $\mu = (1 + 3)/2 = 2$ 。

2) 方差 $\sigma^2 = ((1 - 2)^2 + (3 - 2)^2)/2 = (1 + 1)/2 = 1$ 。

3) 标准差 $\sigma = 1$ 。

4) 归一化 $(x - \mu)/\sigma$: $x_1 = (1 - 2)/1 = -1, x_2 = (3 - 2)/1 = 1$ 。

6. 给定 batch 的两条样本（每条 4 维）： $X = \begin{pmatrix} 0 & 0 & 2 & 2 \\ 1 & 1 & 3 & 3 \end{pmatrix}$ 。做 LayerNorm ，取 $\epsilon = 0$ 且不做仿射。第一行第 3 个分量标准化后为_____；做 BatchNorm ，取 $\epsilon = 0$ 且不做仿射。第一行第 3 个分量标准化后为_____。

答案：1, -1

解答：LayerNorm：第一行均值 1、标准差 1，因此该分量为 $(2 - 1)/1 = 1$ ；BatchNorm：第 3 列为 (2, 3)，均值 2.5，标准差 0.5，因此该分量为 $(2 - 2.5)/0.5 = -1$ 。

7. 已知向量 $[1, 3, 5, 7]$ ，其均值为 4，计算该向量的标准差（层归一化第二步），结果为_____。

答案： $\sqrt{5}$ (或 2.236)

解答：标准差为各元素与均值差值的平方和除以维度后开平方，计算

过程： $\sqrt{\frac{(1-4)^2+(3-4)^2+(5-4)^2+(7-4)^2}{4}} = \sqrt{\frac{9+1+1+9}{4}} = \sqrt{5} \approx 2.236$ 。

8. 层归一化完整计算中，已知向量 $[0, 2, 4, 6]$ ，完成“均值 $\rightarrow$ 标准差 $\rightarrow$ 归一化”三步计算（归一化公式： $x' = \frac{x-\mu}{\sigma}$ ），得到的归一化后向量（保留两位小数）是 _____。

答案： $[-1.16, -0.39, 0.39, 1.16]$

解答：1. 计算均值： $\frac{0+2+4+6}{4} = 3$ ；2. 计算标准差： $\sqrt{\frac{(0-3)^2+(2-3)^2+(4-3)^2+(6-3)^2}{4}} = \sqrt{\frac{9+1+1+9}{4}} = \sqrt{5} \approx 2.24$ ；3. 归一化： $\frac{0-3}{2.24} \approx -1.16$ ， $\frac{2-3}{2.24} \approx -0.39$ ， $\frac{4-3}{2.24} \approx 0.39$ ， $\frac{6-3}{2.24} \approx 1.16$ ，最终结果为 $[-1.16, -0.39, 0.39, 1.16]$ 。

9. 给定 $x = (1, 2, 2, 4)$ ，子层输出 $f(x) = (0, 1, 1, 1)$ 。先做残差相加 $u = x + f(x)$ ，再对 u 做 LayerNorm，取 $\epsilon = 0$ 且不做仿射。标准化后第 1 个分量为 _____。

答案： $-\sqrt{2}$

解答： $u = (1, 3, 3, 5)$ ，均值为 3，去均值为 $(-2, 0, 0, 2)$ ，方差为 $\frac{1}{4}(4 + 0 + 0 + 4) = 2$ ，标准差 $\sqrt{2}$ ，因此第 1 分量为 $-2/\sqrt{2} = -\sqrt{2}$ 。

多头注意力维度与拼接

1. 如自注意力模块的输入 token 向量维度为 512，经过注意力层输出维度等于 _____。

答案：512

解答：注意力层不会改变模型维度。

2. 若注意力机制的两个注意力头输出分别为 $[1, 0]$, $[0, 2]$ ，那么最终的输出结果是多少？ _____

答案： $[1, 0, 0, 2]$

3. 多头注意力中，嵌入总维度为 512，头数为 8，单个头的 Query 向量维度（与 Key、Value 维度一致）为 _____。

答案： 64

解答：单个头维度为嵌入总维度除以头数，计算过程： $512 \div 8 = 64$ 。

4. 若多头注意力模块的输出为 $h^{(1)} = (2, -1)$ 、 $h^{(2)} = (0, 3)$ ，拼接后得到 h ，令 $W_O = \begin{pmatrix} 1 & 0 & 2 & -1 \\ 0 & 1 & -1 & 1 \end{pmatrix}$ ， $b = (1, -2)$ 。计算 $y = W_O h + b$ 的第二个分量 $y_2 = \underline{\hspace{2cm}}$ 。

答案： 0

解答：第二行内积 $0 \cdot 2 + 1 \cdot (-1) + (-1) \cdot 0 + 1 \cdot 3 = 2$ ，加偏置 -2 得 $y_2 = 0$ 。

5. (多头注意力分割) 假设 $d_{\text{model}} = 12$ ， $h = 3$ ，权重矩阵 W^Q 形状 12×12 。则每个头的 W_i^Q 形状为 $\underline{\hspace{2cm}}$ 。

答案： 12×4 。

解答：

- 1) 输入维度 $d_{\text{model}} = 12$ 。
- 2) 单头维度 $d_k = 12/3 = 4$ 。
- 3) 每个头权重形状 $(12, 4)$ 。

参数数量计算

1. 设 $d_{\text{model}} = 48$ ，头数 $h = 3$ ，每头 $d_k = d_v = 16$ ，采用”每头独立矩阵”的实现：每头都有 $W_Q, W_K, W_V \in \mathbb{R}^{48 \times 16}$ ，且三者各自带 bias (长度 16)。输出投影 $W_O \in \mathbb{R}^{48 \times 48}$ 也带 bias (长度 48)。仅该多头注意力模块的可训练参数量为 $\underline{\hspace{2cm}}$ 。

答案： 9408

解答：每头 W_Q, W_K, W_V 参数数为 $3 \times (48 \cdot 16 + 16) = 3 \times 784 = 2352$ ；3 头共 7056。 W_O 为 $48 \cdot 48 + 48 = 2352$ 。总计 $7056 + 2352 = 9408$ 。

2. 该编码器层由三部分组成：第 11 题的注意力模块；FFN: $48 \rightarrow 192 \rightarrow 48$ (两层线性均带 bias)；以及 2 个 LayerNorm (每个 LayerNorm 具有 $\gamma, \beta \in \mathbb{R}^{48}$)。该编码器层总可训练参数量为 _____。

答案： 28272

解答： 注意力 9408。FFN： 第一层 $48 \cdot 192 + 192 = 9408$ ； 第二层 $192 \cdot 48 + 48 = 9264$ ； 合计 18672。两次 LayerNorm: $2 \times (2 \cdot 48) = 192$ 。总计 $9408 + 18672 + 192 = 28272$ 。

3. 构造分类模型：词表大小 $V = 5000$ ，可训练 token embedding 维 $d_{\text{model}} = 48$ ；堆叠第 12 题编码器层 $N = 3$ 层；位置编码为固定正弦 (不可训练)；分类头为线性层 $48 \rightarrow 12$ 且带 bias。该模型总可训练参数量为 _____。

答案： 325404

解答： embedding = $5000 \cdot 48 = 240000$ ； 编码器堆叠 = $3 \cdot 28272 = 84816$ ；分类头 = $48 \cdot 12 + 12 = 588$ 。总计 $240000 + 84816 + 588 = 325404$ 。

4. (Attention 参数量) 计算一个标准 Transformer Encoder 层的参数量。已知 $d_{\text{model}} = 512, d_{\text{ff}} = 2048$ 。包含 Multi-Head Attention (W^Q, W^K, W^V, W^O) 和 FFN (W_1, W_2)。忽略 Bias 和 LayerNorm。

解答：

6) Attention 部分： 4 个矩阵，大小均为 512×512 。

$$P_{\text{attn}} = 4 \times 512^2 = 4 \times 262144 = 1,048,576。$$

7) FFN 部分： $W_1(512 \times 2048)$ 和 $W_2(2048 \times 512)$ 。

$$P_{\text{ffn}} = 2 \times 512 \times 2048 = 2 \times 1,048,576 = 2,097,152。$$

8) 总和： $1,048,576 + 2,097,152 = 3,145,728$ 。

答案： 约 3.15 M。

5. 某线性层输入维度 1024，输出维度 512。该层的权重矩阵 W 包含的元素个数为 _____。

答案： 524,288

解答： $1024 \times 512 = 524,288$ 。

6. 一个包含 12 层的 Transformer 模型，每一层都保留了上一层的输入（残差连接）。信号从输入直接传递到最后一层经过了 _____ 条“无权重”路径（直连通路）。

答案： 1

解答： 只有一条路径是完全不经过任何 Layer 的变换直接通过所有残差连接加到最后的。

位置编码计算

1. 设 $d_{\text{model}} = 4$ ，位置 $p = 25\pi$ 。定义 $\text{PE}(p, 0) = \sin p$, $\text{PE}(p, 1) = \cos p$, $\text{PE}(p, 2) = \sin(\frac{p}{100})$, $\text{PE}(p, 3) = \cos(\frac{p}{100})$ 。则 $\text{PE}(p, 3) = \underline{\hspace{2cm}}$ 。

答案： $\frac{\sqrt{2}}{2}$

解答： $\frac{p}{100} = \frac{25\pi}{100} = \frac{\pi}{4}$ ，故 $\cos(\pi/4) = \sqrt{2}/2$ 。

2. (位置编码)：正弦位置编码 $\text{PE}(\text{pos}, 2i) = \sin(\text{pos}/10000^{2i/d})$ 。当 $\text{pos} = 0$ 时，任意维度的编码值是多少？

答案： 偶数维 0，奇数维 1。

解答：

1) $\sin(0) = 0$ 。

2) 偶数维度全为 0。

3) 奇数维度 $\cos(0) = 1$ 。

3. 某词的嵌入向量为 $[0.8, 1.5]$ ，对应的位置编码向量为 $[0.2, -0.5]$ ，二者采用常见融合方式处理后，得到的融合向量是 _____。

答案: $[1.0, 1.0]$

解答: 采用逐元素相加融合 (课程核心融合方式), 计算过程: $[0.8 + 0.2, 1.5 + (-0.5)] = [1.0, 1.0]$ 。

4. Key 向量维度为 64, 对注意力原始关联强度进行缩放处理时, 所用的缩放因子数值为 _____。

答案: 8

解答: 缩放因子为 Key 向量维度的平方根, 计算过程: $\sqrt{64} = 8$ 。

损失函数与交叉熵计算

1. 长度为 4 的序列, 各位置正确类别概率为 $(\frac{1}{2}, \frac{1}{8}, \frac{1}{4}, \frac{1}{16})$ 。平均交叉熵 $\bar{\mathcal{L}} = \frac{1}{4} \sum_{t=1}^4 -\ln p_t$ 用 $\ln 2$ 表示为: _____。困惑度定义为 $\text{PPL} = \exp(\bar{\mathcal{L}})$ 。写成根式最简形式: $\text{PPL} =$ _____。

答案: $\frac{5}{2} \ln 2, 4\sqrt{2}$

解答: $-\ln p_t = (\ln 2, 3 \ln 2, 2 \ln 2, 4 \ln 2)$, 求和 $10 \ln 2$, 平均 $\frac{10}{4} \ln 2 = \frac{5}{2} \ln 2$; $\exp(\frac{5}{2} \ln 2) = 2^{5/2} = 4\sqrt{2}$ 。

2. 设输入序列向量为 $X^{\text{in}} = (x_1, x_2)^\top$, 对应的真实输出为 $X^{\text{out}} = (x_2, x_3)^\top$, 模型预测输出为 $\hat{X}^{\text{out}} = (\hat{x}_2, \hat{x}_3)^\top$ 。在 Next Token Prediction 任务中, 设 $d = 3$, 真实输出向量为 $x_2 = (0, 1, 0)$, $x_3 = (0, 0, 1)$, 模型预测为 $\hat{x}_2 = (0.1, 0.8, 0.1)$, $\hat{x}_3 = (0.2, 0.3, 0.5)$ 。根据损失函数计算该样本的平均交叉熵损失值 (保留两位小数), 结果为 _____。

答案: 0.46

解答: 当 $i = 2$ 时, 真实输出向量为 $(0, 1, 0)$, 只有第二个分量对损失有贡献, 此时对应的对数概率为 $\log 0.8 \approx -0.2231$ 。当 $i = 3$ 时, 真实输出向量为 $(0, 0, 1)$, 只有第三个分量对损失有贡献, 对应的对数概率为 $\log 0.5 \approx -0.6931$ 。将两步的结果代入平均损失函数可得 $\mathcal{L} = -\frac{1}{2}(-0.2231 - 0.6931) = \frac{0.9162}{2} \approx 0.4581 \approx 0.46$ 。因此, 该样本的平均交叉熵损失为 0.46 (其中对数以 e 为底)。

其他计算

1. 假设输入 **Batch Size** $B = 32$, 序列长度 $L = 100$, 隐藏层维度 $D = 768$ 。则输入张量的形状(Shape)为 _____。

答案: $(32, 100, 768)$

解答: 标准 NLP 输入格式 (B, L, D) 。

2. (**RoPE 旋转验证**) : 已知二维向量 $x = [1, \sqrt{3}]^T$ 。在 **RoPE** 中, 位置 m 的旋转角 $\theta_m = \frac{\pi}{3}$ (**60 度**)。请计算旋转后的向量 $x' =$ _____。

答案: $x' = [-1, \sqrt{3}]^T$ 。

解答:

$$\text{旋转矩阵 } R = \begin{pmatrix} \cos 60^\circ & -\sin 60^\circ \\ \sin 60^\circ & \cos 60^\circ \end{pmatrix} = \begin{pmatrix} 1/2 & -\sqrt{3}/2 \\ \sqrt{3}/2 & 1/2 \end{pmatrix}。$$

计算 $x' = Rx$:

$$x' = \begin{pmatrix} 1/2 & -\sqrt{3}/2 \\ \sqrt{3}/2 & 1/2 \end{pmatrix} \begin{pmatrix} 1 \\ \sqrt{3} \end{pmatrix} = \begin{pmatrix} 1/2 - 3/2 \\ \sqrt{3}/2 + \sqrt{3}/2 \end{pmatrix} = \begin{pmatrix} -1 \\ \sqrt{3} \end{pmatrix}$$

3. 在 **RoPE** 中, 若旋转角度 $\theta = \pi$ (**180 度**), 向量 $[1, 0]$ 旋转后的坐标为 _____。

答案: $[-1, 0]$

解答: 旋转 180 度即取反。