

人工智能导论小测：神经网络训练现象（参数凝聚与解的平坦性）

一、选择题

1. 关于”平坦极小值”与”尖锐极小值”，下列说法正确的是：

- A. 尖锐极小值的泛化能力通常优于平坦极小值
- B. 平坦极小值对参数的微小扰动更不敏感
- C. 大批量训练更容易找到平坦极小值
- D. 小学习率更容易找到平坦极小值

答案： B

解析：平坦意味着参数变化时 Loss 变化小，即鲁棒性好，泛化好。LB 和小 LR 倾向于尖锐解。

2. 对于一维输入 x 和参数 w, b ，ReLU 神经元 $\sigma(wx + b)$ 的转折点发生在：

- A. $x = 0$
- B. $x = w/b$
- C. $x = -b/w$
- D. $x = b$

答案： C

解析：由 $wx + b = 0$ 可解得 $x = -b/w$ 。

3. 根据”稳定边缘”理论，梯度下降过程中 Hessian 矩阵的最大特征值 λ_{max} 与学习率 η 的关系趋向于：

- A. $\lambda_{max} \approx 1/\eta$
- B. $\lambda_{max} \approx 2/\eta$
- C. $\lambda_{max} \ll 1/\eta$
- D. $\lambda_{max} \approx \eta$

答案： B

解析：训练收敛到的最小值点的 λ_{max} 通常与 $2/\eta$ 近似相等。

4. 下列哪项操作通常不利于找到平坦的解？

- A. 使用小批量训练
- B. 使用较大的（合理的）学习率
- C. 使用 Dropout
- D. 使用极大的批量训练

答案： D

解析：研究总结指出，LB 倾向于尖锐解，而其他选项均有助于找到平坦解。

5. 在两层神经网络参数凝聚现象的极坐标可视化中（横轴为方向，纵轴为幅度），角度 $\hat{w}_k$ 代表什么？

- A. 神经元权重的幅度
- B. 神经元权重的方向
- C. 神经元的偏置值
- D. 神经元的梯度

答案： B

解析：定义 $\tan(\hat{w}_k) = b_k/w_k$ ，表示向量 (w_k, b_k) 的方向。

6. 在观察”参数凝聚”现象的实验中，对比”大初始化”与”小初始化”条件下参数在训练前后的变化，下列描述符合实验观察的是：

- A. 在大初始化下，参数在训练前后变化非常剧烈
- B. 在小初始化下，参数在训练前后几乎没有变化
- C. 在小初始化下，参数在训练前后位置变化显著，并聚集到少数方向
- D. 无论初始化大小，参数变化幅度都基本一致

答案： C

解析：大初始化下，训练前后的参数分布（青色与红色点）几乎重叠，变化不大；而小初始化下，参数从初始的随机分布显著移动并凝聚到

特定的少数方向，变化很大。

7. 如果两个神经元的权重方向 $b_1/w_1, b_2/w_2$ 相同（或非常接近），在 ReLU 网络中它们可以：

- A. 相互抵消
- B. 导致梯度爆炸
- C. 等效合并为一个神经元
- D. 导致无法计算

答案： C

解析：当权重方向相同时，线性组合系数可以直接相加，从而等效为一个神经元。

8. 为什么在实际训练中，尽管大网络会发生凝聚（等效于小网络），我们仍然偏好使用大网络？

- A. 大网络计算量更小
- B. 大网络更容易训练
- C. 大网络占内存更小
- D. 大网络不会过拟合

答案： B

解析：凝聚的大网络比小网络更容易训练，因为参数更多，可使损失函数下降的方向更多。

9. 对于二次损失函数 $L = \frac{1}{2}\lambda\theta^2$ ，梯度下降不发散（不爆炸）的条件是：

- A. $\eta > 2/\lambda$
- B. $\eta < 2/\lambda$
- C. $\eta = \lambda$
- D. $\eta = 2/\lambda$

答案： B

解析：根据迭代公式推导，稳定性条件为 $|\theta_{t+1}| < |\theta_t| \Rightarrow \eta < 2/\lambda$ 。

10. 在 ResNet18 训练末期观察到卷积核之间出现极高的余弦相似度（即凝聚现象），这主要揭示了深度神经网络在”过参数化”条件下具有什么特性？

- A. 严重的过拟合风险
- B. 有效模型复杂度的降低
- C. 梯度消失导致的训练停滞
- D. 算力资源的无效浪费

答案： B

解析：多个卷积核凝聚到同一方向，网络自动将其有效参数量降低到了一个更小的规模，体现了自适应的复杂度控制。

11. 在”小初始化”条件下，随着训练进行，有效神经元的数量通常如何变化？

- A. 保持不变
- B. 随机波动
- C. 从很多逐渐减少
- D. 从很少逐渐增加以拟合数据

答案： D

解析：逐步增加有效神经元数目从而拟合数据。

12. 下列关于 Hessian 矩阵特征值的描述，正确的是：

- A. 特征值越大，对应方向的曲率越小（越平坦）
- B. 特征值越大，对应方向的曲率越大（越尖锐）
- C. 特征值与曲率无关
- D. 特征值必须为负数

答案： B

解析：Hessian 矩阵描述二阶导数（曲率），特征值 λ 越大，开口越陡峭。

13. 对比”大初始化”与”小初始化”两种情形，参数在训练过程中的”移动模式”有何本质区别？

- A. 大初始化下参数移动距离远，小初始化下移动距离近
- B. 小初始化下参数仅调整幅度，方向保持不变
- C. 小初始化下参数会显著改变方向以提取特征，而大初始化下参数基本停留在初始位置附近
- D. 两者没有本质区别，最终都收敛到相同的解

答案： C

解析：小初始化导致参数“凝聚”并显著改变方向去拟合数据（特征学习）；大初始化下参数变化很小，行为像线性模型。

14. 公式 $f(x) = \sum_{k=1}^m a_k \sigma(w_k x + b_k)$ 描述的是哪种网络结构？

- A. 卷积神经网络
- B. 循环神经网络
- C. 两层全连接神经网络
- D. Transformer

答案： C

解析：这是典型的单隐藏层感知机/全连接网络的数学表达。

15. 在训练中使用学习率 η 与最终收敛点的“平坦度”存在密切联系。请问，较大的学习率倾向于让模型收敛到什么样的区域？

- A. Hessian 矩阵最大特征值 λ_{max} 较大的尖锐区域
- B. Hessian 矩阵最大特征值 λ_{max} 较小的平坦区域
- C. 损失值 Loss 最大的区域
- D. 梯度范数最大的区域

答案： B

解析：较大的学习率在尖锐区域（ λ_{max} 大）是不稳定的（会发生震荡或跳出），因此模型会被“推”向平坦区域（ λ_{max} 小），直到满足稳定性条件。

16. 在训练初期使用较大的学习率或“预热”策略，除了加速收敛外，对最终解的性质通常有什么积极影响？

- A. 使得最终解的 Loss 值更接近 0

- B. 帮助模型”跳出”尖锐的局部极小值，从而收敛到更平坦、泛化能力更好的解
- C. 消除梯度消失的问题
- D. 使得最终解的参数稀疏化

答案： B

解析：较大的学习率不允许模型停留在曲率过大（尖锐）的区域（因为那里是不稳定的），因此迫使模型寻找更平坦的区域进行收敛。

17. 在使用 ReLU 激活函数时， $\max(0, x - 1) + \max(0, 3(x - 1))$ 可以等效为：

- A. $4 \max(0, x - 1)$
- B. $3 \max(0, x - 1)$
- C. $\max(0, 4x - 1)$
- D. 无法合并

答案： A

解析： $\max(0, 3(x - 1)) = 3 \max(0, x - 1)$ （当 $k > 0$ ），所以 $1 + 3 = 4$ 倍的 $\max(0, x - 1)$ 。

18. 下列关于批量大小与泛化差距关系的描述，符合实验现象的是：

- A. Batch Size 越大，泛化差距越小
- B. Batch Size 越小，泛化差距越小
- C. Batch Size 与泛化差距无关
- D. 只有 Full Batch 才能消除泛化差距

答案： B

解析：实验数据显示，SB（小批量）的测试集准确率高于 LB（大批量），即 SB 的泛化差距更小。

19. 设 m 是网络宽度，在常见的神经网络初始化方法中，Xavier 初始化的标准差量级大约为：

- A. $O(1)$ ，与网络宽度无关

- B. $O(1/\sqrt{m})$, 与网络宽度的平方根成反比
- C. $O(m)$, 与网络宽度成正比
- D. $O(1/m)$, 与网络宽度成反比

答案： B

解析： Xavier 的尺度参数 $\text{Scale} \sim 1/\sqrt{m}$, 随着宽度变大, 初始化尺度变小。

20. ReLU 激活函数 $\sigma(x) = \max(0, wx + b)$ 的转折点位置为：

- A. $x = 0$
- B. $x = b/w$
- C. $x = -b/w$
- D. $x = w/b$

答案： C

解析： ReLU 函数在 $wx + b = 0$ 处转折, 因此转折点为 $x = -b/w$ 。

21. 以下关于大初始化训练的神经网络的描述, 正确的是：

- A. 输出函数光滑, 转折点集中
- B. 参数训练前后变化很大
- C. 输出函数有很多随机分布的转折点
- D. 容易发生参数凝聚现象

答案： C

解析： 大初始化下网络输出”表现出很多转折, 且有点随机”, 呈现锯齿状。

22. 凝聚现象主要发生在以下哪种初始化条件下：

- A. 大初始化
- B. 中等初始化
- C. 小初始化
- D. 零初始化

答案： C

解析： 凝聚现象： 小初始化下, 同层神经元会有趋同的偏好。

23. 在小初始化训练过程中，有效神经元的数目主要取决于：

- A. 初始化的随机性
- B. 网络的宽度
- C. 训练数据的特性
- D. 学习率的大小

答案： C

解析：小初始化下”有效神经元取决于数据”。

24. 两个 ReLU 神经元在什么条件下可以等效为一个神经元：

- A. 输出权重相同
- B. 转折点相同
- C. 转折点相同且输入权重同号
- D. 输入权重相同

答案： C

解析： w 同号时，转折点相同的两个 ReLU 函数可以等效成一个 ReLU 函数。

25. 神经网络的有效参数量是指：

- A. 网络的实际参数总数
- B. 非零参数的数量
- C. 训练后等效小网络的参数量
- D. 训练后发生显著变化的参数数量

答案： C

解析：神经网络的有效参数量是等效小网络的参数量。

26. 以下哪项不是凝聚的大网络相比直接训练小网络的优势：

- A. 表达能力更强
- B. 更容易训练
- C. 损失函数下降方向更多
- D. 参数更多

答案： A

解析：凝聚的大网络和等效小网络”表达的函数一样”，表达能力相同而非更强。

27. 关于将神经网络参数全部初始化为 0 的说法，正确的是：

- A. 这是一种有效的避免过拟合的方法
- B. 会导致梯度恒为零，无法训练
- C. 可以加快训练速度
- D. 会导致参数凝聚到一个方向

答案： B

解析：将所有参数初始化为 0 会导致梯度一直是零，无法训练。

28. 在训练神经网络时，训练末期卷积核之间的余弦相似度接近多少表明发生了凝聚：

- A. 接近 0
- B. 接近 0.5
- C. 接近 1
- D. 接近-0.5

答案： C

解析：训练末期权重余弦相似度将近 1，这些卷积核很类似。

29. 稳定边缘现象中,神经网络训练收敛时 Hessian 矩阵最大特征值 λ_{max} 与学习率 η 的关系约为：

- A. $\lambda_{max} \approx \eta$
- B. $\lambda_{max} \approx 1/\eta$
- C. $\lambda_{max} \approx 2/\eta$
- D. $\lambda_{max} \approx \eta/2$

答案： C

解析：训练收敛到的最小值点的 $\lambda_{max} \sim 2/\eta$ ，处于稳定边缘。

30. 根据二次函数梯度下降的稳定性条件，可推导出学习率需满足：

- A. $\eta < 1/\lambda$
- B. $\eta < 2/\lambda$
- C. $\eta < 3/\lambda$
- D. $\eta < 4/\lambda$

答案： B

解析：由 $|1 - \eta\lambda| < 1$ 得 $-1 < 1 - \eta\lambda < 1$ ，推出 $\eta < 2/\lambda$ 。

31. 以下哪项技巧不能提升解的平坦性：

- A. 使用小批量训练
- B. 在合理范围内增大学习率
- C. 使用 Dropout
- D. 使用大批量训练

答案： D

解析：小批次、大学习率、Dropout 都能提升平坦性，而大批量训练会导致尖锐解。

32. 在小初始化的训练过程中，神经元的运动轨迹表现为：

- A. 参数保持不变
- B. 随机游走
- C. 先用少量有效神经元，逐步增加有效神经元数目
- D. 所有神经元同时激活

答案： C

解析：训练过程，先用一个有效神经元，误差仍然大，逐步增加有效神经元数目。

33. 假设在一维输入的两层 ReLU 网络中，有两个神经元的参数分别为 $(w_1 = 2, b_1 = -4, a_1 = 3)$ 和 $(w_2 = 4, b_2 = -8, a_2 = 5)$ 。关于这两个神经元，以下说法正确的是：

- A. 它们的转折点不同，因此不能等效

- B. 它们的转折点相同但输入权重异号，因此不能等效
- C. 它们可以等效为一个参数为 $(w = 2, b = -4, a = 13)$ 的神经元
- D. 它们可以等效为一个参数为 $(w = 2, b = -4, a = 8)$ 的神经元

答案： C

解析：两个神经元的转折点分别为 $x_1 = -(-4)/2 = 2$ 和 $x_2 = -(-8)/4 = 2$ ，转折点相同。它们的方向 θ 也相同 ($\tan \theta_1 = b_1/w_1 = -2$, $\tan \theta_2 = b_2/w_2 = -2$)，且输入权重同号，因此可以等效为一个神经元，保持 w, b 不变（或等比例缩放），输出权重相加得 $a = 3 + 5 * 2 = 13$ 。

34. 在稳定边缘现象的背景下，如果我们观察到某个神经网络训练收敛时 Hessian 矩阵的最大特征值 $\lambda_{max} = 1000$ ，那么该训练过程使用的学习率最可能接近：

- A. 0.0005
- B. 0.002
- C. 0.5
- D. 2.0

答案： B

解析：根据稳定边缘现象， $\lambda_{max} \approx 2/\eta$ ，因此 $\eta \approx 2/\lambda_{max} = 2/1000 = 0.002$ 。

35. 考虑小初始化训练的神经网络，以下哪个说法最准确地解释了为什么过参数化网络不容易过拟合：

- A. 过参数化网络的正则化项更大，限制了模型复杂度
- B. 由于凝聚现象，网络等效于参数量较小的网络，模型复杂度更低
- C. 过参数化网络训练时学习率自动减小，避免了过拟合
- D. 过参数化网络的初始化尺度更小，因此输出更接近零

答案： B

解析：神经网络具有低频偏好，且偏向会等效于小网络，这解释了为什么过参数化网络不会过拟合。凝聚现象使得大网络的有效参数量远小于实际参数量，防止了过拟合。

36. 假设我们在训练神经网络时观察到以下现象：(1) 训练初期损失下降很慢；(2) 同层卷积核之间相似性很高。最可能的原因是：

- A. 学习率设置过大
- B. 初始化尺度设置过小
- C. 使用了过大的批量大小
- D. 网络宽度不足

答案： B

解析：初始化过小会导致：(1) 梯度接近零，训练变慢；(2) 参数变化大，凝聚现象明显。

37. 在小初始化下，神经元在极坐标图中的运动轨迹通常呈现：

- A. 随机布朗运动
- B. 围绕原点旋转
- C. 从原点附近向特定方向生长
- D. 收缩至原点

答案： C

解析：参数轨迹图显示神经元从中心（原点附近）向外（特定角度）延伸。

38. 大初始化下，神经网络的输出通常会呈现什么特征？

- A. 光滑连续，转折点少
- B. 锯齿状，转折点多且随机
- C. 分段线性，但转折点固定
- D. 无规律波动，无法预测

答案： B

解析：大初始化时，神经网络输出有更多转折点，呈现锯齿状特性。

39. 平坦解相比于尖锐解的主要优势是：

- A. 训练速度更快
- B. 对噪声更鲁棒，泛化更好
- C. 更容易出现过拟合

- D. 输出函数更锯齿

答案： B

解析： 平坦解对参数扰动不敏感，在测试集上表现更稳定，泛化能力更强。

40. 以下哪种说法正确描述了”凝聚现象”与”等效小网络”的关系？

- A. 凝聚后的大网络与等效小网络表达的函数相同
- B. 凝聚后的大网络表达能力更强
- C. 等效小网络无法表达大网络能表达的函数
- D. 两者在训练速度上没有差异

答案： A

解析： 凝聚后的大网络在函数表达上等效于一个小网络，但训练过程更易优化。

41. 关于 Dropout 与解的平坦性，正确的说法是：

- A. Dropout 会使解更尖锐
- B. Dropout 会使解更平坦
- C. Dropout 不影响解的平坦性
- D. Dropout 只影响训练速度

答案： B

解析： Dropout 作为一种正则化方法，有助于找到更平坦的解，提升泛化能力。

42. 小批量训练相比大批量训练，更容易找到平坦解的原因是：

- A. 梯度更准确
- B. 噪声更多，有助于跳出尖锐极小值
- C. 计算更快
- D. 参数更新更少

答案： B

解析： 小批量训练引入的梯度噪声有助于逃离尖锐极小值，从而找到更平坦

的解。

43. 为什么大批量训练更容易找到尖锐解?

- A. 因为大批量训练时，梯度估计更准确，容易收敛到尖锐的最小值点
- B. 因为大批量训练时，学习率需要更小，导致收敛到尖锐的最小值点
- C. 因为大批量训练时，网络更容易过拟合
- D. 因为大批量训练时，训练速度更快

答案： A

解析：大批量训练时，梯度估计更准确，容易收敛到尖锐的最小值点。

44. 在神经网络训练中，为什么小初始化下，神经元的参数会凝聚到少数方向?

- A. 因为小初始化使神经元的梯度方向相似
- B. 因为小初始化使神经元的激活函数转折点相同
- C. 因为小初始化使神经元的权重在训练过程中趋于一致
- D. 因为小初始化使网络的损失函数更平滑

答案： B

解析：小初始化使神经元的激活函数转折点更接近，导致同方向的神经元在训练中趋同。

45. 小批量训练相比大批量训练，有什么优势?

- A. 训练速度更快
- B. 更可能找到平坦解
- C. 训练过程更稳定
- D. 以上都是

答案： B

解析：小批量训练更可能找到平坦解，泛化能力更好。

46. 为什么神经网络的训练通常不会将所有参数初始化为 0?

- A. 因为初始化为 0 会导致梯度为零，无法训练

- B. 因为初始化为 0 会使网络输出为 0，无法拟合数据
- C. 因为初始化为 0 会使得网络训练速度过慢
- D. 因为初始化为 0 会导致网络过拟合

答案： A

解析： 参数初始化为 0 会导致梯度为零，无法进行训练。

47. 神经网络训练中，“稳定边缘现象”指的是什么？

- A. 梯度下降算法在训练过程中突然加速
- B. 网络训练收敛到的最小值点的 Hessian 最大特征值处于稳定边缘
- C. 损失函数在训练过程中突然下降
- D. 神经网络参数在训练过程中突然发散

答案： B

解析： 稳定边缘现象指神经网络训练收敛到的最小值点的 Hessian 最大特征值处于稳定边缘。

48. 在 ReLU 激活函数中，转折点指的是什么？

- A. 激活函数的导数为零的点
- B. 激活函数从线性变为非线性的点
- C. 激活函数的最大值点
- D. 激活函数的最小值点

答案： B

解析： ReLU 函数的转折点是指函数从线性变为非线性的点。

49. 如果神经网络的参数初始化太小，会出现什么问题？

- A. 网络无法训练，因为梯度为零
- B. 网络训练速度过快，无法收敛
- C. 网络输出过于光滑，无法拟合复杂数据
- D. 网络输出有太多转折点，导致过拟合

答案： A

解析：参数初始化太小会导致梯度为零，无法进行训练。

50. 为什么过参数化的神经网络不会过拟合数据？

- A. 因为参数太多，无法拟合任何数据
- B. 因为神经网络具有低频偏好，且偏向会等效于小网络
- C. 因为过参数化网络的训练速度更快
- D. 因为过参数化网络的初始化更好

答案： B

解析：过参数化神经网络具有低频偏好，训练后会等效于小网络，因此不会过拟合。

51. 在神经网络训练中，为什么小初始化的网络更容易训练？

- A. 因为参数更多，可以更快地拟合数据
- B. 因为参数更多，损失函数下降的方向更多
- C. 因为小初始化避免了过拟合
- D. 因为小初始化使网络输出更光滑

答案： B

解析：小初始化的网络参数更多，损失函数下降的方向更多，因此更容易训练。

52. 凝聚现象的发生有助于解释：

- A. 为什么大网络容易过拟合
- B. 为什么过参数化网络仍能良好泛化
- C. 为什么小网络训练更快
- D. 为什么需要大量数据

答案： B

解析：凝聚现象使过参数化大网络在训练后等效于小网络，从而避免过拟合，保持良好的泛化能力。

53. 在神经网络中讨论“解的平坦性”，主要关注的是：

- A. 最小损失值的绝对大小
- B. 参数是否为零
- C. 最优解附近损失变化的敏感程度
- D. 训练数据的规模大小

答案： C

解析：平坦性描述的是在最优解附近，参数发生小扰动时损失函数变化是否缓慢。

54. 与尖锐最小值相比，平坦最小值通常意味着：

- A. 更快的训练速度
- B. 对参数扰动更不敏感
- C. 更高的模型复杂度
- D. 更小的训练误差

答案： B

解析：平坦解对应较宽的低损失区域，对参数扰动具有更强的鲁棒性。

55. 如果在多个参数方向上，损失函数在最优点附近变化都较为平缓，则可以推断该解：

- A. 一定是全局最优解
- B. 可能是平坦的极小值
- C. 无法通过梯度方法获得
- D. 一定对应较大的测试误差

答案： B

解析：多方向上的缓慢变化是平坦极小值的重要特征。

56. 关于”参数凝聚”现象，以下哪种初始化策略最容易导致同层神经元在训练后出现趋同的偏好？

- A. 将参数初始化为全 0
- B. 极大的随机初始化
- C. 小初始化

- D. Xavier 初始化

答案： C

解析：在小初始化条件下，同层的神经元在训练过程中会表现出趋同的偏好，即许多神经元的权重方向会聚集在一起（凝聚），最终等效于一个较小的网络。

57. 在训练过程中，对参数进行小幅扰动而损失几乎不变，这更可能说明当前解：

- A. 尚未收敛
- B. 学习率过小
- C. 具有较好的平坦性
- D. 梯度计算存在误差

答案： C

解析：对扰动不敏感是平坦解的重要特征。

58. 神经网络发生”参数凝聚”后，关于其有效参数量的描述，以下哪项最准确？

- A. 有效参数量等于名义参数量
- B. 有效参数量取决于等效小网络的参数量
- C. 有效参数量会随着训练次数无限增加
- D. 有效参数量主要由偏置项决定

答案： B

解析：由于参数凝聚，大量神经元聚集在少数几个方向上，功能上等效于一个参数更少的小网络。因此，其实际的有效复杂度（有效参数量）取决于这个等效小网络，而非原始的庞大参数量。

59. 从几何角度理解，平坦解更接近于损失函数形状中的：

- A. 陡峭尖峰
- B. 狭窄谷底
- C. 宽阔盆地

- D. 不连续阶梯

答案： C

解析：平坦解对应较宽的低损失区域。

60. 假设我们使用梯度下降训练网络，若将学习率 η 增大一倍，在稳定边缘理论下，收敛点的 Hessian 矩阵最大特征值理论上将如何变化？

- A. 增大一倍
- B. 减小一半
- C. 保持不变
- D. 变为原来的四分之一

答案： B

解析：根据公式 $\rho(H) \approx 2/\eta$ ，学习率 η 与特征值 $\rho(H)$ 成反比。若学习率增大一倍，收敛点的曲率（尖锐程度）理论上将减小一半，即收敛到相对更平坦的区域（或者若超出边界则发散）。

61. 关于大网络（发生凝聚）与等效小网络的训练难度对比，以下说法正确的是：

- A. 两者训练难度完全相同
- B. 等效小网络总是更容易训练
- C. 大网络因为参数多，提供了更多的下降方向，更容易训练
- D. 大网络因为计算量大，所以更难训练

答案： C

解析：理论和实验发现，大网络虽然最终凝聚，但在训练过程中参数更多，提供了更多的下降方向，使得损失函数更容易下降。因此，大网络比等效的小网络更容易训练。

62. 根据频率原则与凝聚现象的关联，神经网络在拟合数据时通常优先学习：

- A. 高频细节成分
- B. 低频平滑成分

- C. 随机噪声成分
- D. 边缘异常成分

答案： B

解析：结合凝聚现象（小初始化导致光滑输出），神经网络通常表现出“低频偏好”，即优先学习数据中的低频（平滑）部分，这与网络倾向于寻找平坦解和发生参数凝聚是一致的。

63. 在讨论平坦性时，引入参数扰动的主要目的是：

- A. 加快模型收敛
- B. 检验模型是否欠拟合
- C. 观察损失对参数变化的敏感性
- D. 改变模型结构

答案： C

解析：通过扰动参数，可以评估解附近损失变化的幅度。

64. 下列哪一描述最能体现“多解结构”的含义？

- A. 损失函数只有一个最优点
- B. 不同参数组合对应不同输出
- C. 多组参数可实现近似相同的模型性能
- D. 参数必须满足严格约束条件

答案： C

解析：多解结构意味着多组参数在性能上近似等价。

65. 使用 ReLU 激活函数的两层神经网络训练，若初始化尺度过大，以下哪项现象最可能发生？

- A. 一条接近水平的直线
- B. 输出函数呈现低频平滑形态
- C. 网络输出呈现高频锯齿状波动
- D. 参数凝聚现象显著

答案： C

解析：初始化过大时，ReLU 转折点分布随机，输出呈现高频锯齿状。

66. 下列哪种初始化方法中，参数初始化尺度随网络宽度 m 增加而减小？

- A. 固定初始化
- B. Xavier 初始化
- C. 全零初始化
- D. 随机大常数初始化

答案：B

解析：Xavier 初始化的尺度与 $1/\sqrt{m}$ 相关，随宽度增大而减小。

67. 在参数凝聚现象通常导致神经网络训练后：

- A. 所有神经元独立工作
- B. 多个神经元功能重复
- C. 网络表达能力下降
- D. 梯度爆炸

答案：B

解析：凝聚意味着多个神经元参数趋同，功能重复，可等效为少数神经元。

68. 对于 ReLU 函数 $\sigma(wx + b)$ ，若 $w > 0$ 且 $b < 0$ ，则转折点位于：

- A. 正半轴
- B. 负半轴
- C. 原点
- D. 不存在

答案：A

解析：转折点 $x = -b/w$ ，由 $w > 0, b < 0$ 得 $x > 0$ 。

69. 在损失函数的景观分析中，平坦极小值通常与较好的泛化性能相关联。
以下哪一项不是平坦极小值提升泛化能力的理论解释？

- A. 平坦极小值对应参数空间的较大区域，使得参数的小扰动不会引起损失显著变化

- B. 平坦极小值通常位于损失曲面的低曲率区域，梯度下降过程更稳定
- C. 平坦极小值往往与较小的梯度范数相关，说明优化过程更接近全局最优
- D. 平坦极小值对应的 Hessian 矩阵特征值较大，说明该区域对噪声不敏感

答案： D

解析： Hessian 特征值大表示曲率大、区域尖锐，对参数扰动敏感，不利于泛化。平坦极小值的特征值应较小。

70. 在”稳定边缘”现象中，若训练过程中学习率 η 增大，则收敛点的 Hessian 最大特征值 $\lambda_{\max}$ 通常会如何变化？这种现象对模型的泛化性能有何影响？

- A. $\lambda_{\max}$ 增大，模型趋向尖锐解，泛化能力下降
- B. $\lambda_{\max}$ 减小，模型趋向平坦解，泛化能力提升
- C. $\lambda_{\max}$ 不变，泛化能力不受影响
- D. $\lambda_{\max}$ 先增后减，泛化能力不确定

答案： B

解析： 根据稳定边缘理论， $\lambda_{\max} \approx 2/\eta$ ，学习率增大则 $\lambda_{\max}$ 减小，即趋向平坦区域，通常泛化更好。

71. 在神经网络训练中，若采用接近零的小随机初始化，使用 ReLU 激活函数，最可能导致：

- A. 梯度爆炸，训练震荡
- B. 多数神经元输出为零，梯度消失，训练缓慢
- C. 参数迅速凝聚到少数方向，训练速度加快
- D. 模型在参数空间中探索更充分，避免局部极小值

答案： B

解析： 极小初始化会使 ReLU 神经元的输入 $w^T x + b$ 很小，若为负则输出恒为零，梯度为零，无法更新。此时大部分神经元可能处于”死亡”状态，梯度消失，训练极慢甚至停滞。

72. 考虑一个两层 ReLU 网络，若训练后某层神经元的参数方向 $\hat{w}_k$ 高度集中，而幅度 A_k 分布分散，这说明：

- A. 网络未发生凝聚
- B. 神经元功能完全相同
- C. 神经元方向一致但贡献不同
- D. 网络过拟合严重

答案：C

解析：方向一致说明凝聚，幅度不同表示各神经元对输出的贡献权重不同。

73. 从优化与泛化的角度，下列哪项关于平坦极小值的说法是准确的？

- A. 平坦极小值处的梯度较小，因此随机梯度下降更容易稳定收敛
- B. 平坦极小值的平坦性可直接由 Hessian 矩阵的行列式大小判断，行列式越小越平坦
- C. 平坦极小值对参数扰动不敏感，这被认为是其泛化能力较好的可能原因之一
- D. 使用大批量训练总是能帮助模型收敛到更平坦的极小值

答案：C

解析：平坦极小值对参数扰动鲁棒，可缓冲测试分布偏移，这是解释其泛化能力的主流假设之一。

74. 在两层 ReLU 神经网络中，若要观察到明显的“凝聚现象”（即同层神经元参数方向趋同），初始化的标准差 σ 与网络宽度 m 通常呈现什么样的关系？

- A. σ 应随 m 增大而显著增大
- B. σ 应随 m 增大而保持不变
- C. σ 应随 m 增大而减小
- D. σ 的大小与 m 无关

答案：C

解析：凝聚现象主要出现在“小初始化”条件下。随着网络宽度 m 增加，初始化尺度通常需要相应减小（如 $\sim 1/\sqrt{m}$ ）。

75. 对于 ReLU 激活函数 $\sigma(x) = \max(0, x)$ ，若两个神经元 k_1, k_2 的参数满足 $(w_1, b_1) = \alpha(w_2, b_2)$ 且 $\alpha > 0$ ，则这两个神经元在功能上：

- A. 相互正交，提取不同特征
- B. 互为相反数，相互抵消
- C. 可以等效合并为一个神经元
- D. 会导致网络输出无穷大

答案： C

解析：由于 ReLU 的正齐次性 $\sigma(\alpha z) = \alpha \sigma(z)$ （当 $\alpha > 0$ ），相同方向的参数意味着激活模式完全一致，因此可以将它们合并。

76. 在探究”凝聚现象”的实验中，研究者通常使用极坐标图来可视化参数的变化。在该坐标系下，数据点聚集在少数几个角度方向上意味着什么？

- A. 大部分神经元失效了（权重为 0）
- B. 神经网络发生了严重的梯度消失
- C. 许多神经元提取了相同的特征，网络变得”稀疏”或低秩
- D. 训练发散，参数跑到了无穷远

答案： C

解析：凝聚到少数几个方向意味着大量神经元在该方向上功能重复，可以用极少数的”有效神经元”来代表整个层，体现了网络的低秩性。

77. 相比于直接训练一个参数量很少的”小网络”，训练一个发生”凝聚现象”的”过参数化大网络”通常更容易。其主要原因是什么？

- A. 大网络可以使用更小的显存
- B. 大网络拥有更多的参数，提供了更多让损失函数下降的方向
- C. 大网络不需要计算梯度
- D. 大网络的初始损失值一定更低

答案： B

解析：大网络高维的参数空间提供了更多的逃逸路径和下降方向，使得梯度下降算法更容易找到好的解，避免陷入较差的局部极小值。

78. 在神经网络训练过程中, 如果我们将所有参数都初始化为严格的 0, 会有什么后果?

- A. 能够完美复现”小初始化”带来的凝聚现象
- B. 训练速度最快, 因为起点是原点
- C. 丧失对称性破坏, 导致神经元无法分化学习
- D. 能够自动找到平坦极小值

答案: C

解析: 全 0 初始化会导致所有神经元对于输入的响应完全相同, 计算出的梯度也相同, 网络无法打破对称性, 无法学习不同的特征。

79. 下列关于”平坦极小值”的描述, 错误的是:

- A. 它的 Hessian 矩阵的最大特征值通常较小
- B. 它对应着损失函数曲面宽阔的谷底
- C. 它对参数的随机扰动具有较强的鲁棒性
- D. 它通常对应着训练误差极低但测试误差极高的情况

答案: D

解析: 平坦极小值通常与良好的泛化能力相关, 即训练误差低且测试误差也低。D 选项描述的是过拟合（泛化差）的特征。

80. 在使用梯度下降优化二次函数 $L(\theta) = \frac{1}{2}\lambda\theta^2$ 时, 若学习率 η 满足 $1/\lambda < \eta < 2/\lambda$, 参数 θ 的变化趋势是:

- A. 单调指数衰减趋向于 0
- B. 保持不变
- C. 在 0 附近震荡收敛
- D. 震荡发散, 趋向无穷大

答案: C

解析: 迭代公式为 $\theta_{t+1} = (1 - \eta\lambda)\theta_t$ 。当 $1/\lambda < \eta < 2/\lambda$ 时, $-1 < 1 - \eta\lambda < 0$, 系数的绝对值小于 1 但为负数, 因此参数会交替改变符号（震荡）, 但幅度逐渐减小并收敛。

二、判断题

1. 在神经网络参数初始化时，较小的初始化尺度通常会导致“参数凝聚”现象，即同层神经元表现出趋同的偏好。

答案：T

解析：在小初始化下，同层神经元会有趋同的偏好，即凝聚现象；而大初始化下则容易出现锯齿状、随机的输出。

2. 随着神经网络宽度的增加，为了保持输出的稳定性，初始化尺度通常应该变大。

答案：F

解析：常见的初始化中，尺度参数 β 通常与宽度 m 成反比（如 $m^{-1/2}$ ），即随着宽度变大，初始化尺度应变小。

3. “参数凝聚”现象意味着在大网络训练后的状态下，网络可以等效为一个更小的网络。

答案：T

解析：凝聚现象中相同方向的神经元群可以等效成一个神经元，这表明大网络的有效参数量可能等效于一个小网络。

4. 在损失函数景观中，“尖锐极小值”通常比“平坦极小值”具有更好的泛化能力。

答案：F

解析：训练集和测试集通常都有噪音，平坦的解更鲁棒，泛化能力更好。

5. 在梯度下降训练中，使用大批量进行训练通常倾向于收敛到平坦极小值。

答案：F

解析：研究表明，大批量训练倾向于收敛到尖锐极小值，而小批量倾向于平坦极小值。

6. 较大的学习率有助于模型逃离尖锐的极小值，从而找到更平坦的解。

答案：T

解析：合理的大学习率有助于模型跳出尖锐的局部极小值，从而找到更平坦的解。

7. 对于 ReLU 激活函数 $\sigma(x) = \max(0, x)$ ，其转折点的位置仅由输入数据 x 决定，与参数 w, b 无关。

答案：F

解析：ReLU 函数的转折点满足 $w x + b = 0$ ，即 $x = -b/w$ ，完全由参数决定。

8. “稳定边缘”现象是指在神经网络训练中梯度下降算法通常运行在稳定性条件的边缘，即 $\lambda_{max} \approx 2/\eta$ 。

答案：T

解析：实验观察表明，训练收敛到的最小值点的 Hessian 最大特征值 λ_{max} 与 $2/\eta$ 近似相等，处于稳定边缘。

9. 既然大网络会发生凝聚现象等效于小网络，那么直接训练一个小网络通常比训练发生凝聚的大网络更容易。

答案：F

解析：凝聚的大网络比小网络更容易训练，因为损失函数下降的方向更多。

10. 在小初始化下，神经网络的初始化非常随机，因此训练后的有效神经元方向分布也总是随机均匀的。

答案：F

解析：在小初始化下，尽管初始是随机的，但训练后的参数会“凝聚”到少数几个特定的方向。

11. Hessian 矩阵的特征值分布可以反映损失函数在极小值点附近的曲率。

答案: T

解析: Hessian 矩阵的特征值 (如 λ_{max}) 反映了函数的平坦性/曲率。

12. 在 ResNet18 的训练中, 卷积核之间不会出现类似的凝聚现象。

答案: F

解析: 对 ResNet18 某层卷积核的余弦相似度分析显示, 训练末期出现了明显的块状高相似度区域, 即凝聚现象。

13. 梯度下降算法的稳定性条件对于二次函数 $L = \frac{1}{2}\lambda\theta^2$ 是 $\eta < 2/\lambda$ 。

答案: T

解析: 对于二次函数 $L = \frac{1}{2}\lambda\theta^2$, 推导可得稳定性条件为 $\eta < 2/\lambda$ 。

14. Dropout 技术主要用于加速训练, 对解的平坦性没有影响。

答案: F

解析: 提升解的平坦性的技巧中包含了 Dropout 算法。

15. 小初始化通常会导致网络输出呈现分片线性的锯齿状。

答案: F

解析: 小初始化时输出通常是光滑的; 而大初始化时才会有锯齿。

16. “参数凝聚”现象表明, 经过训练后发生凝聚的大网络, 其功能可以等效于一个规模较小的网络。

答案: T

解析: 凝聚后的网络等价于小网络, 即同方向的神经元线性组合后可合并为一个有效神经元。

17. 尽管发生凝聚的大网络等效于小网络, 但由于参数冗余, 大网络通常比同等效能的小网络更难训练。

答案：F

解析：凝聚的大网络比小网络更容易训练，因为参数更多，提供了更多使损失函数下降的方向。

18. 只有全连接网络才会出现参数凝聚现象，卷积神经网络中不存在。

答案：F

解析：课程中对 ResNet18 的实验表明，其卷积核在训练后同样会出现明显的凝聚现象。

19. 神经网络的初始化尺度参数通常设置为与网络宽度无关的常数。

答案：F

解析：常见初始化的尺度参数通常为 $O(1/\sqrt{m})$ ，其中 m 是网络宽度或输入维度，因此初始化尺度会随着宽度增大而变小。

20. ReLU 激活函数的转折点位置由参数 w 和 b 决定，具体为 $x = -w/b$ 。

答案：F

解析：ReLU 函数在 $w x + b = 0$ 处发生转折，因此转折点位置为 $x = -b/w$ 。

21. 在大初始化下训练的神经网络，其输出函数通常表现出较多随机分布的转折点。

答案：T

解析：大初始化使得不同神经元的参数差异较大，导致 ReLU 转折点分布随机，输出函数呈现锯齿状。

22. 凝聚现象是指在小初始化下，同层神经元的参数会趋向于相同的方向。

答案：T

解析：这是凝聚现象的定义，小初始化下神经元会有趋同的偏好，参数会凝聚到少数几个方向。

23. 两个转折点相同且输出权重同号的 ReLU 神经元可以等效为一个 ReLU 神经元。

答案：T

解析：当 w 同号且转折点相同时，两个 ReLU 函数的响应区域相同，可以合并为一个等效神经元。

24. 在小初始化条件下，训练后的神经网络参数与初始参数相比变化很小。

答案：F

解析：小初始化下参数训练前后差别很大，而大初始化下参数变化较小。

25. 将所有神经网络参数初始化为 0 是一种有效的训练策略。

答案：F

解析：参数全部初始化为 0 会导致梯度恒为零，网络无法训练。需要随机初始化打破对称性。

26. 在损失函数的平坦最小值点处，参数的小扰动对损失值影响较小。

答案：T

解析：这是平坦解的定义特征，在平坦区域参数变化对损失函数影响小，因此更鲁棒。

27. Hessian 矩阵的最大特征值越大，说明损失景观在该点越尖锐。

答案：T

解析：Hessian 矩阵的特征值反映函数的曲率，最大特征值越大表示某方向曲率越大，即越尖锐。

28. 稳定边缘现象是指神经网络训练收敛时，Hessian 矩阵的最大特征值约为 $2/\eta$ 。

答案：T

解析：这是稳定边缘现象的核心观察，训练收敛到稳定性条件的边界。

29. 过参数化的神经网络容易过拟合，因此实际应用中应尽量减少参数数量。

答案：F

解析：虽然直觉上过参数化易过拟合，但由于凝聚现象和低频偏好，过参数化网络实际上不易过拟合，且更容易训练。

30. 在梯度下降的稳定性条件中，学习率 η 需要满足 $\eta < 2/\lambda$ ，其中 λ 是 Hessian 矩阵的最大特征值。

答案：T

解析：这是梯度下降稳定性的经典条件，保证迭代过程不会发散。

31. 凝聚的大网络与等效的小网络具有相同的表达能力，因此直接训练小网络会更高效。

答案：F

解析：虽然表达能力相同，但凝聚的大网络比小网络更容易训练，因为参数更多，损失函数下降的方向更多。

32. 在小初始化下训练，有效神经元的数目主要由初始化决定，与数据无关。

答案：F

解析：小初始化下“有效神经元取决于数据”，而非初始化。

33. 神经网络的初始化尺度越小越好，因为小初始化可以避免过拟合。

答案：F

解析：虽然小初始化有助于凝聚和避免过拟合，但初始化太小会导致梯度接近零，训练变慢甚至无法训练。

34. 卷积神经网络初始化时的卷积核之间就已经表现出高度的相似性。

答案：F

解析：在 ResNet18 等网络的初始化阶段几乎不存在卷积核凝聚，凝聚是在训练过程中逐渐出现的现象。

35. Hessian 矩阵的最大特征值越大，意味着损失函数在该点附近的景观越平坦。

答案：F

解析：Hessian 矩阵的特征值反映了函数的曲率。特征值越大，曲率越大，意味着极小值点越尖锐，而非越平坦。

36. 在参数凝聚现象中，若干个具有相同方向的神经元在数学上可以简化合并为更少量的有效神经元。

答案：T

解析：具有相同方向的 ReLU 神经元可以通过系数相加的方式进行线性组合，从而在功能上等效于一个神经元。

37. 使用极大的初始化尺度通常会使神经网络在未经训练时的输出函数表现得非常平滑。

答案：F

解析：大初始化会导致神经元参数差异巨大，使得 ReLU 的转折点分布杂乱，网络输出表现出剧烈的震荡和锯齿状，而非平滑。

38. 对于单个 ReLU 神经元 $f(x) = \sigma(wx + b)$ ，其非线性转折仅发生在输入 x 等于 0 的位置。

答案：F

解析：ReLU 的转折点发生在 $w x + b = 0$ 处，即 $x = -b/w$ ，位置取决于偏置和权重的比值，不一定在 0 点。

39. 尽管凝聚后的过参数化大网络在功能上等效于一个小网络，但在训练过程中，大网络通常比对应的小网络更容易优化。

答案：T

解析：大网络拥有更高维的参数空间，提供了更多让损失函数下降的方向，因此比参数受限的小网络更容易训练。

40. 根据梯度下降的稳定性理论，如果学习率 η 大于 $2/\lambda_{max}$ ，参数更新将呈现单调收敛的趋势。

答案：F

解析：当 $\eta > 2/\lambda_{max}$ 时，迭代过程会变得不稳定，导致参数震荡甚至发散，而不是单调收敛。

41. 平坦极小值之所以优于尖锐极小值，主要原因是其对训练集和测试集之间的数据分布偏移具有更强的鲁棒性。

答案：T

解析：在平坦极小值处，参数的微小变动（或数据分布的微小变动）不会引起损失函数的剧烈变化，因此泛化性能更好。

42. 使用较小的批量进行训练会引入更多噪声，这倾向于将模型推向更尖锐的极小值。

答案：F

解析：小批量带来的随机噪声有助于模型“跳出”狭窄的尖锐极小值，从而有更大概率落入宽阔的平坦极小值区域。

43. 相比于 $\beta \sim 1/\sqrt{m}$ 的初始化尺度，若将初始化尺度设置为 $\beta \sim 1/m$ ，网络的初始输出函数会变得更加光滑。

答案：T

解析：随着初始化尺度变小（如从 $1/\sqrt{m}$ 减小到 $1/m$ ），网络输出的锯齿状特征减少，趋向于光滑函数。

44. 在训练过程中使用 Dropout 技术会阻碍模型找到平坦的极小值解。

答案：F

解析：Dropout 强迫模型不依赖特定神经元，这种正则化效应倾向于引导模型收敛到更平坦、鲁棒性更好的解。

45. 在小初始化条件下的训练过程中，用于拟合数据的“有效神经元”数量通常是随着训练进行逐步增加的。

答案：T

解析：动力学分析显示，网络倾向于先用少量的有效神经元拟合主要趋势，随后逐步分裂出更多方向的神经元以拟合细节。

46. 过参数化的神经网络由于参数量远大于数据量，因此必然会遭受严重的过拟合问题。

答案：F

解析：神经网络具有“低频偏好”和参数凝聚等特性，这使得它们在过参数化的情况下往往能学习到简单的规律，而不一定过拟合。

47. 梯度下降算法在二次函数上的稳定性取决于该函数二阶导数（即曲率）的大小。

答案：T

解析：稳定性条件 $\eta < 2/\lambda$ 直接取决于 Hessian 矩阵的特征值 λ ，即函数的曲率。

48. 两个 ReLU 神经元只有在它们的转折点位置相同且符号允许的情况下，才能在数学上合并为一个等效的 ReLU 神经元。

答案：T

解析：只有当两个神经元的激活区域和非激活区域完全一致（即转折点和方向相同）时，它们的输出才可以线性叠加合并。

49. 当模型训练处于“稳定边缘”状态时，损失函数会表现出单调递减的平滑曲线。

答案：F

解析：在稳定边缘，学习率较大，导致损失函数在下降过程中伴随着非单调的震荡现象。

50. 在大初始化条件下，模型参数在训练过程中会发生显著的移动以进行特征学习。

答案：F

解析：大初始化通常对应“懒惰学习”，参数在训练前后变化很小；小初始化才对应显著的参数位移和特征学习。

51. 若两个权重向量的余弦相似度为 -1 ，说明它们完全正交，提取了互不相关的特征。

答案：F

解析：余弦相似度为 -1 意味着两个向量方向相反（共线），它们高度相关（线性相关），而非正交。

52. 平坦极小值对参数的小扰动更敏感，因此容易过拟合。

答案：F

解析：平坦极小值对参数扰动不敏感，更鲁棒，泛化能力更强。

53. 小初始化下，训练初期网络倾向于使用大量有效神经元。

答案：F

解析：小初始化下，训练初期通常先用少量有效神经元，逐步增加。

54. 相比尖锐极小值，平坦极小值处的梯度范数通常更小。

答案：F

解析：在极小值点，梯度理论上都为零（或数值计算下接近零），因此平坦与尖锐极小值的梯度范数没有系统性差异。二者的本质区别在于曲率（Hessian 特征值）而非梯度。

55. 在两层全连接网络中，若 ReLU 神经元的权重向量方向相同（即转折点位置相同），则它们在功能上可以等效为一个神经元。

答案：T

解析：当两个 ReLU 神经元的权重方向相同时（即转折点位置相同），它们的线性叠加在数学上等价于一个具有更大幅度的 ReLU 神经元。这是参数凝聚现象的数学基础。

56. 小初始化通常会导致神经网络在训练结束后出现明显的参数凝聚现象。

答案：T

解析：在小初始化条件下，同层的神经元在训练过程中会表现出趋同的偏好，即许多神经元的权重方向会聚集在一起（凝聚），最终等效于一个较小的网络。

57. 如果多组参数配置能够得到近似相同的损失值，则说明模型的参数空间中存在多解结构。

答案：T

解析：多解结构的核心特征就是不同参数组合在性能上近似等价。

58. 解的平坦性主要刻画的是最优解处损失值的大小。

答案：F

解析：平坦性关注的是最优解附近损失函数对参数扰动的敏感程度，而非损失值本身。

59. 在小初始化下，神经网络的训练轨迹通常是从使用少量有效神经元开始，随着误差减小逐步增加有效神经元数目。

答案：T

解析：在小初始化（凝聚）情况下，训练过程倾向于先用一个有效神经元拟合，若误差仍大，再逐步增加有效神经元的数量，这是一种“稀疏”的训练动态。

60. 如果将神经网络的所有参数初始化为 0，网络将更容易发生参数凝聚，从而获得更好的泛化性能。

答案：F

解析：将所有参数初始化为 0 会导致梯度对称，网络无法通过梯度下降进行有效训练（梯度为 0）。虽然小初始化有助于凝聚，但初始化为 0 是无效的。

61. 如果两个神经元的参数完全不同，则它们不可能实现相同的函数映射。

答案：F

解析：在非线性模型中，不同参数组合仍可能对应近似相同的输入输出关系。

62. Hessian 矩阵的最大特征值越大，说明该局部极小点附近的损失景观越平坦。

答案：F

解析：Hessian 矩阵的特征值反映了曲率。特征值越大，曲率越大，说明该点越“尖锐”；特征值越小，曲率越小，说明该点越“平坦”。

63. 参数凝聚一定会导致模型输出退化为简单形式。

答案：F

解析：凝聚并不必然降低模型表达能力，输出形式可能基本保持不变。

64. 若模型参数对扰动极为敏感，则该解更可能是尖锐的而非平坦的。

答案：T

解析：对扰动敏感通常对应损失曲面陡峭的区域。

65. 凝聚后的大网络与等效小网络在训练难度上没有区别。

答案：F

解析：大网络由于参数多，损失函数下降的方向更多，通常更容易训练。

66. 小批量训练引入的噪声有助于模型逃离尖锐极小值。

答案：T

解析：小批量带来的梯度噪声有助于探索更平坦的区域。

67. 凝聚现象是欠拟合的表现。

答案：F

解析：凝聚现象是网络自组织为小网络的过程，有助于泛化。

68. 平坦解在训练集上的损失一定高于尖锐解。

答案：F

解析：平坦解在训练集上的损失可能接近或略高于尖锐解，但在测试集上表现更好。

69. 神经网络的有效参数量是指网络中实际被使用的参数数量。

答案：F

解析：有效参数量是指等效小网络的参数量，不是实际被使用的参数数量。

70. 在 ReLU 激活函数中，转折点是指函数值为 0 的点。

答案：F

解析：ReLU 的转折点是指函数从线性变为非线性的点，即 $x=0$ ，不是函数值为 0 的点。

三、填空与计算题

1. 在一维 ReLU 神经网络中，若某神经元的参数为 $w = 4, b = -12$ ，则该神经元激活函数的转折点位于 $x = \underline{\hspace{2cm}}$ 。

答案：

3

解析：ReLU 的转折点满足 $w x + b = 0$ ，即 $4x - 12 = 0$ ，解得 $x = 3$ 。

2. 已知某神经网络损失函数在极小值点处的 Hessian 矩阵最大特征值为 $\lambda_{max} = 800$ 。若使用梯度下降训练且处于“稳定边缘”状态，则此时的学习率 η 约为 $\underline{\hspace{2cm}}$ 。

答案：

0.0025 或 $\frac{1}{400}$

解析：根据稳定边缘现象，训练收敛时满足 $\lambda_{max} \approx 2/\eta$ ，故 $\eta \approx 2/800 = 1/400 = 0.0025$ 。

3. 有两个 ReLU 神经元 $\sigma_1(x) = 3 \max(0, 2x - 6)$ 和 $\sigma_2(x) = 5 \max(0, 2x - 6)$ 。判断它们 _____ (填“能”或“不能”) 合并为一个等效的 ReLU 神经元。

答案：能

解析：神经元 1 的转折点为 $x = 6/2 = 3$ ，方向符号为正 ($w_1 = 2 > 0$)；神经元 2 的转折点为 $x = 6/2 = 3$ ，方向符号为正 ($w_2 = 2 > 0$)。两者转折点相同且方向一致 (w 相同， b 相同)，输出权重同号 ($a_1 = 3 > 0, a_2 = 5 > 0$)，可以合并。

4. 考虑二次损失函数 $L(\theta) = 5\theta^2$ 。为了保证梯度下降过程不发散，学习率 η 必须小于 _____。

答案：

$$0.2 \text{ 或 } \frac{1}{5}$$

解析：稳定性条件为 $\eta < 2/\lambda$ 。这里 $L(\theta) = 5\theta^2$ ，二阶导数 $\lambda = \frac{d^2 L}{d\theta^2} = 10$ 。故 $\eta < 2/10 = 0.2$ 。

5. Hessian 矩阵的 _____ 可以用来刻画损失函数在某点附近的平坦程度。

答案：特征值（或最大特征值）

解析：Hessian 矩阵的特征值反映函数的平坦性。

6. 考虑梯度下降更新 $\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t)$ 。对于二次损失 $L(\theta) = \frac{1}{2} \sum_{i=1}^d \lambda_i \theta_i^2$ ，若最大特征值 $\lambda_{max} = 100$ ，最小特征值 $\lambda_{min} = 1$ ，要保证所有方向都稳定收敛，学习率需满足 $\eta < \underline{\hspace{2cm}}$ 。

答案：

$$0.02 \text{ 或 } \frac{2}{100} \text{ 或 } \frac{1}{50}$$

解析：最严格的稳定性条件由最大特征值决定： $\eta < 2/\lambda_{max} = 2/100 = 0.02$ 。

7. 在研究初始化对凝聚的影响时, 若参数初始化方差 $\sigma^2 \propto m^{-\alpha}$ 。为了观察到明显的凝聚现象, 通常需要指数 α _____ 1 (填” > “或” < “)。

答案: >

解析: 小初始化下凝聚现象显著, 小初始化对应 α 较大 (如 1.75), 即 $\alpha > 1$ (标准初始化通常 $\alpha = 1$, 对应 $\sigma \sim 1/\sqrt{m}$)。

8. 若学习率 $\eta = 0.01$, 训练处于稳定边缘。此时, 若我们想要使得收敛到的解更平坦 (即 λ_{max} 更小), 在不改变 Batch Size 的情况下, 应该尝试 _____ (填” 增大” 或” 减小”) 学习率。

答案: 增大

解析: 根据 $\lambda_{max} \approx 2/\eta$, 增大 η 会使得稳定边缘对应的 λ_{max} 变小, 即解的曲率变小, 更平坦。

9. 若某网络在初始化 ($\text{scale} \sim 1/\sqrt{m}$) 下训练, 参数从初始值 θ_0 到最终值 θ^* 的相对变化量 $\|\theta^* - \theta_0\|/\|\theta_0\|$ 通常会 _____ 于初始化 ($\text{scale} \sim 1/m$) 下的情况 (填” 大” 或” 小”)。

答案: 小

解析: 大初始化下”参数训练前后差别不大”, 而小初始化下”参数训练前后差别很大”。

10. 若某优化过程在稳定边缘附近震荡, 即 λ_{max} 在 $2/\eta$ 附近波动, 这时若将学习率从 η 减半至 $\eta/2$, 则新的稳定边缘对应的 λ_{max} 理论值将变为原来的 _____ 倍。

答案: 2

解析: 稳定边缘条件 $\lambda_{max} \approx 2/\eta$, 当学习率减半为 $\eta/2$ 时, 新的 $\lambda_{max} \approx 2/(\eta/2) = 4/\eta$, 是原来 $2/\eta$ 的 2 倍。

11. 若初始化尺度过大, 神经元的特征分布在训练前后变化 _____ (填” 很大” 或” 很小”), 这就是所谓的懒惰训练或线性区域。

答案: 很小

解析：大初始化下训练前后特征分布（红点与青点）几乎重叠，“参数训练前后差别不大”，变化很小。

12. 考虑一个单层 **ReLU** 神经网络 $f(x) = \sum_{i=1}^3 a_i \max(0, w_i x + b_i)$ 。三个神经元的参数配置如下：神经元 1: $(w_1 = 2, b_1 = -4, a_1 = 0.3)$ ；神经元 2: $(w_2 = 2, b_2 = -4, a_2 = 0.2)$ ；神经元 3: $(w_3 = -2, b_3 = 4, a_3 = 0.6)$ 。根据参数凝聚理论及 **ReLU** 的齐次性，该网络在功能上等效于一个包含 _____ 个有效神经元的小网络；若将神经元 1 和 2 合并为一个等效神经元并保持 $w = 2, b = -4$ ，则其等效幅度 a_{eq} 为 _____。

答案：

2; 0.5

解析： 1. 分析转折点与方向：

- 神经元 1：转折点 $x = -b_1/w_1 = 4/2 = 2$, $w_1 = 2 > 0$ （激活区间 $x > 2$ ）
- 神经元 2：转折点 $x = -b_2/w_2 = 4/2 = 2$, $w_2 = 2 > 0$ （激活区间 $x > 2$ ）
- 神经元 3：转折点 $x = -b_3/w_3 = -4/(-2) = 2$, $w_3 = -2 < 0$ （激活区间 $x < 2$ ）

虽然三个转折点相同，但神经元 1 和 2 的激活方向相同（ w 同号），神经元 3 激活方向相反，因此 1 和 2 凝聚，3 独立。**有效神经元数量为 2。**

2. 合并神经元 1 和 2: $a_{eq} = a_1 + a_2 = 0.3 + 0.2 = 0.5$ 。

3. 假设某神经网络在损失函数极小值点附近的 **Hessian** 矩阵为 $H = \begin{pmatrix} 5 & 2 \\ 2 & 5 \end{pmatrix}$ 。该极小值点附近损失景观的“最大曲率”（即最大特征值 λ_{max} ）为 _____；为了保证梯度下降在该方向上不发散，学习率 η 的理论上限是 _____。

答案：

7; $\frac{2}{7}$ 或 0.286

解析： 1. 计算特征值：求解特征方程 $\det(H - \lambda I) = 0$ 。

$$\det \begin{pmatrix} 5 - \lambda & 2 \\ 2 & 5 - \lambda \end{pmatrix} = (5 - \lambda)^2 - 4 = \lambda^2 - 10\lambda + 21 = 0$$

解得： $\lambda = \frac{10 \pm \sqrt{100 - 84}}{2} = \frac{10 \pm 4}{2}$ ，即 $\lambda_1 = 7, \lambda_2 = 3$ 。

2. 最大曲率： $\lambda_{max} = 7$ 。

3. 学习率上限：根据稳定性条件 $\eta < 2/\lambda_{max} = 2/7 \approx 0.286$ 。

4. 为了保持深层 ReLU 网络在初始化时各层激活值的方差一致，权重的方差需设为 $\text{Var}(w) = 2/m$ ，其中 m 是层的宽度。现有一个宽度为 $m = 256$ 的网络，其初始化权重的标准差为 σ_1 。若将网络宽度增加到 $m = 1024$ ，为了维持相同的激活方差性质，新的初始化权重标准差 σ_2 应当是 σ_1 的 _____ 倍。

答案：

$$\frac{1}{2} \text{ 或 } 0.5$$

解析： 1. He Initialization 的标准差公式： $\sigma = \sqrt{2/m}$ 。

2. 计算比例：

- 当 $m = 256$ 时， $\sigma_1 = \sqrt{2/256} = \sqrt{1/128}$
- 当 $m = 1024$ 时， $\sigma_2 = \sqrt{2/1024} = \sqrt{1/512}$
- 比例： $\sigma_2/\sigma_1 = \sqrt{(1/512)/(1/128)} = \sqrt{128/512} = \sqrt{1/4} = 1/2$

3. 直观理解：神经元数量增加了 4 倍，为了让加权后的方差保持不变，每个单独权重的方差需要减小 4 倍，因此标准差减小为原来的 1/2。

4. 给定梯度下降更新公式 $\theta_{t+1} = (1 - \eta\lambda)\theta_t$ ，若要保证迭代不发散，学习率 η 必须满足的条件是 $\eta < \underline{\hspace{2cm}}$ 。

答案：

$$\frac{2}{\lambda}$$

解析：需满足 $|1 - \eta\lambda| < 1$ ，解得 $-1 < 1 - \eta\lambda < 1$ ，即 $0 < \eta\lambda < 2$ ，故 $\eta < 2/\lambda$ 。

16. 描述梯度下降稳定边缘的经验公式表明, Hessian 矩阵的最大特征值 λ_{max} 大约等于 _____。

答案:

$$\frac{2}{\eta}$$

解析: 训练收敛到的最小值点的 $\lambda_{max} \sim 2/\eta$ 。

17. 对于两层全连接网络 $f(x) = \sum_{k=1}^m a_k \sigma(w_k x + b_k)$, 其中 σ 为 ReLU 函数。该神经元的转折点位于 $x =$ _____。

答案:

$$-\frac{b_k}{w_k}$$

解析: 令 $w_k x + b_k = 0$, 解得 $x = -b_k/w_k$ 。

18. 两个 ReLU 神经元 $ReLU(x - 1)$ 和 $ReLU(x - 3)$ 的叠加 _____ (填”能”或”不能”) 等效为一个 ReLU 神经元。

答案: 不能

解析: 转折点不同的两个 ReLU 函数叠加会产生两个转折点, 不能等效。

19. 设 $y = ax^2$, 若 $a = 5$, 则其开口比 $a = 1$ 时更 _____ (填”平坦”或”尖锐”)。

答案: 尖锐

解析: 二次项系数越大, 函数图像越陡峭 (尖锐)。

20. 尽管发生”参数凝聚”后大网络等效于小网络, 但实验表明, 直接训练该等效的小网络通常比训练原大网络更 _____ (填”难”或”易”)。

答案: 难

解析: 大网络下降方向多, 更容易训练; 直接训练小网络反而容易陷入局部极优或难以优化。

21. 深度学习中的 _____ 现象是指小初始化下，同层神经元会有趋同的偏好。

答案：凝聚

解析：这是该领域的一个核心概念。

22. 当 λ_{max} 很大时,说明损失函数在对应方向上的曲率很 _____。

答案：大

解析：特征值代表曲率大小。

23. 神经网络的有效参数量可以理解为等效 _____ 网络的参数量。

答案：小

解析：相关理论对此有详细解释。

24. 常见的 Xavier 初始化中,方差通常与 m (宽度)成 _____ (填”正”或”反”)比。

答案：反

解析： $\beta \sim 1/\sqrt{m}$ ，即方差与 m 成反比。

25. 泛化差距 = _____ 表现 - 测试集表现。

答案：训练集

解析：泛化差距通常定义为训练表现与测试表现之差。

26. 若 $k > 0$ ，则 $\sigma(k(wx + b)) = k \times$ _____，这是 ReLU 的齐次性质。

答案：

$$\sigma(wx + b)$$

解析： $\max(0, kz) = k \max(0, z)$ 当 $k > 0$ 。

27. 根据“稳定边缘”理论，若想让模型收敛到更平坦（即 Hessian 最大特征值更小）的解，应当适当 _____（填“增大”或“减小”）训练时的学习率。

答案：增大

解析：由 $\lambda_{max} \approx 2/\eta$ 可知，学习率 η 越大，收敛点的 λ_{max} 越小，即解越平坦。

28. “万有逼近定理”暗示了 _____ 隐藏层的神经网络在一定条件下可逼近任意连续函数。

答案：单

解析：万有逼近定理通常基于单隐层网络阐述。

29. 损失景观中，Hessian 矩阵小特征值解对应损失函数曲面的 _____ 区域。

答案：平坦

解析：平坦解所在区域损失变化缓慢，对参数扰动不敏感。

30. 在稳定边缘现象中，Hessian 矩阵的最大特征值与 _____ 有关。

答案：学习率

解析：稳定边缘现象中，Hessian 矩阵的最大特征值与学习率有关。

31. 有两个 ReLU 神经元：(4,4) 和 (3,3)，它们的余弦相似度为 _____，_____（发生/没发生）凝聚。

答案：1；发生

解析：两个神经元的参数向量方向相同，余弦相似度为 1，说明发生了凝聚现象。

32. 神经网络训练中，A 批量大小为 32，B 批量大小为 1024，对应梯度噪声方差分别为 0.1 和 0.001。若当前损失景观在某个尖锐极小值点

处的 Hessian 矩阵最大特征值为 10，则 _____ 更可能逃离该极小值。

答案：A

解析：梯度噪声越大，批量越小，越有可能帮助参数跳出尖锐极小值。批量 32 对应噪声方差 0.1，比批量 1024 的噪声方差 0.001 大得多，因此更可能逃离尖锐极小值。

33. 有三个神经元： $\sigma_A(x) = 2\text{ReLU}(2x + 1)$ ， $\sigma_B(x) = 6\text{ReLU}(4x + 2)$ ， $\sigma_C(x) = \text{ReLU}(6x + 5)$ ，则它们可以等效成 _____ 个神经元，其中 _____ 可以合并成一个神经元。

答案：2；A 和 B

解析：神经元 A 和 B 的转折点一样，权重方向一致，可以等效合并成一个神经元。

34. 有两个神经元 A： $2\text{ReLU}(x + 1)$ ，B： $\text{ReLU}(3x + 3)$ ，则其等效于一个神经元 _____。

答案： $5\text{ReLU}(x + 1)$

解析：神经元 A 和 B 的转折点一样，权重方向一致，可以等效合并成一个神经元。

35. 训练两神经元权重，不使用 Dropout 时 $w_1 = [3, 1]$ ， $w_2 = [1, 3]$ ；使用 Dropout ($p = 0.85$) 时， $w_1 = [4, 4]$ ， $w_2 = [2, 2]$ 。则不使用 Dropout 时两参数夹角为 _____，使用 Dropout 时两参数夹角为 _____，进而说明使用 Dropout 有 _____ 影响。

答案： 53.13° ； 0° ；促进凝聚效应

解析：根据余弦相似度公式计算，Dropout 使参数完全凝聚，有效参数量减少。

36. 考虑三层神经网络：输入维度 2，第一隐藏层 100 神经元，第二隐藏层 50 神经元，输出 1。训练后：第一层参数凝聚至 3 个方向，第二

层凝聚至 2 个方向。则该大神经网络等效于 _____ 个参数数量的小神经网络。

答案：20

解析：考虑偏置，第一层权重 $2 \times 3 = 6$ + 偏置 $3 = 9$ ；第二层权重 $3 \times 2 = 6$ + 偏置 $2 = 8$ ；输出层权重 $2 \times 1 = 2$ + 偏置 $1 = 3$ ；总计 $9 + 8 + 3 = 20$ 。

37. 对于一个两层的 ReLU 神经网络，隐藏层有两个神经元，参数如下：输入权重 $w_1 = 0.5, w_2 = -0.5$ ，输出权重 $v_1 = 2, v_2 = 1$ ，所有偏置为 0。给定输入 $x = 2$ ，则计算网络输出 $y =$ _____。

答案：2

解析：第一个神经元： $z_1 = w_1 \times x = 0.5 \times 2 = 1$ ， $\text{ReLU}(1) = 1$ ，第二个神经元： $z_2 = w_2 \times x = -0.5 \times 2 = -1$ ， $\text{ReLU}(-1) = 0$ ，输出 $y = v_1 \times \text{ReLU}(z_1) + v_2 \times \text{ReLU}(z_2) = 2 \times 1 + 1 \times 0 = 2$ 。

38. 在凝聚现象中，当训练过程进行时，神经元会从初始的 _____ 状态逐渐凝聚到少数方向。

答案：随机

解析：在凝聚现象中，神经元从初始的随机状态逐渐凝聚到少数方向。

39. 初始化标准差 σ 越小 ($\sigma \rightarrow 0^+$)，训练后参数凝聚的方向数 k 通常越 _____，有效参数数量越低。

答案：少

解析：小初始强化神经元间协同演化，使更多神经元收敛至相同方向， $k \propto 1/|\ln \sigma|$ 。

40. 对于输入为标量的单隐藏层 ReLU 网络，若隐藏层有 n 个神经元且所有转折点互异，则输出函数 $f(x)$ 的分段线性区间数为 _____。

答案： $n + 1$

解析： n 个互异转折点将定义域划分为 $n + 1$ 个区间，每段内函数为线性。

41. 相比于 L1、L2 范数等添加正则项的显示正则化，神经网络的凝聚现象本质是一种 _____ 正则化，使模型隐式偏好低频、平滑的函数解。

答案：隐式

解析：无需显式添加正则项，过参数化 + 小初始化 + 梯度下降共同诱导出结构化稀疏性。

42. Hessian 矩阵在某方向的特征值大小直接反映损失景观在该方向的 _____，值越小表示该方向越平坦。

答案：曲率

解析：曲率是二阶导数量化，平坦解对应低曲率区域，对参数扰动不敏感。

43. 在神经网络训练中，当使用较小的初始化尺度时，同层神经元的权重往往会趋向于相同的方向，这种现象被称为 _____。

答案：参数凝聚（或神经元凝聚）

解析：小初始化会导致网络在训练过程中出现参数凝聚现象，即大量神经元在权重空间中聚集，功能上趋同。

44. 在损失景观中，_____（平坦或尖锐）解通常被认为对数据噪音更鲁棒，泛化性能更好。

答案：平坦（或宽）

解析：平坦解意味着在参数微小扰动下损失函数变化不大，因此对训练数据中的噪音不敏感，泛化能力优于尖锐解。

45. 神经网络的泛化性能与其有效参数量密切相关，有效参数量越 _____（大或小），模型越不容易过拟合。

答案：小

解析：凝聚现象降低了有效参数量，使得模型的实际复杂度降低，从而在拥有大量名义参数的情况下仍能保持良好的泛化能力。

46. 对于一维 ReLU 神经元 $\text{ReLU}(wx + b)$ ，其转折点的位置由权重 w 和偏置 b 共同决定，具体公式为 $x = \underline{\hspace{2cm}}$ 。

答案： $-b/w$

解析：转折点发生在 $wx + b = 0$ 时，解得 $x = -b/w$ 。

47. 在稳定边缘现象中，梯度下降收敛时，Hessian 矩阵最大特征值 $\rho(H)$ 与学习率 η 之间满足 $\rho(H) \approx \underline{\hspace{2cm}}$ 。

答案： $2/\eta$

解析：实验表明，训练最终收敛的点处于稳定性边界，即 $\rho(H) \approx 2/\eta$ 。这意味着学习率限制了能找到的解的尖锐程度。

48. 根据稳定边缘理论，如果学习率 η 增大，收敛点的 Hessian 最大特征值 $\rho(H)$ 理论上将 $\underline{\hspace{2cm}}$ （增大或减小）。

答案：减小

解析：由公式 $\rho(H) \approx 2/\eta$ 可知，学习率与特征值成反比。学习率增大，收敛点的曲率（尖锐程度）理论上将减小，即收敛到相对更平坦的区域。

49. 在 ResNet18 的训练过程中，卷积核权重的余弦相似度随训练轮数增加而逐渐 $\underline{\hspace{2cm}}$ （增大或减小）。

答案：增大

解析：实验观察到，卷积核在训练初期差异较大，但随着训练进行，它们的权重方向逐渐对齐，相似度增大，发生凝聚。

50. 如果一个局部极小点的 Hessian 矩阵特征值很大，说明该点附近的损失面非常 $\underline{\hspace{2cm}}$ （尖锐或平坦），泛化性能通常较差。

答案：尖锐

解析：大的 Hessian 特征值代表高曲率，即损失面在该点附近非常陡峭（尖锐），微小的参数变化就会导致损失剧增，导致泛化性差。