

大模型介绍

题型：判断题（各 85 + 5(备选) 题）、单选题（85 + 1(备选) 题）、填空题（30 + 25(备选) 题）。

一、选择题

1. 以下哪一项符合“许多模态的数据也类似语言进行词元化”？

- A. 把图片/音频等连续信号切分成离散单元，再送入模型处理
- B. 所有模态都必须使用因果掩码
- C. 所有模态都必须用卷积网络编码
- D. 多模态不需要嵌入（embedding）层

答案：A

解析：核心是“离散化/词元化”，便于像处理文本 token 一样处理其他模态。

2. 在 Transformer 中，编码器与解码器的主要区别在于：

- A. 是否使用注意力机制
- B. 是否使用因果掩码
- C. 是否使用词嵌入
- D. 是否使用残差连接

答案：B

解析：解码器使用因果掩码（causal mask），使其只能关注当前位置及之前的 token，以保证生成过程的因果性；编码器则可以看到整个输入序列的所有 token。

3. BART（2019）与 T5（2019）主要采用哪种结构？

- A. Encoder-Only
- B. Decoder-Only
- C. Encoder-Decoder

- D. Seq2Seq

答案： C

解析： BART/T5 是典型的 Encoder-Decoder Transformer。

4. GPT 系列模型采用哪种架构？

- A. Encoder-Only
- B. Decoder-Only
- C. Encoder-Decoder
- D. Seq2Seq

答案： B

解析： GPT 系列模型仅使用 Transformer 的解码器部分，通过自回归方式（下一个 token 预测）进行训练。

5. 微调（Fine-tuning）通常使用哪种学习方式？

- A. 无监督学习
- B. 强化学习
- C. 监督学习
- D. 自监督学习

答案： C

解析： 微调通常使用带有标签的特定任务数据，以有监督学习的方式更新模型参数，使其适应特定任务。

6. LoRA（Low-Rank Adaptation）主要用于：

- A. 加速预训练
- B. 减少微调参数
- C. 提升推理速度
- D. 增强数据增强

答案： B

解析： LoRA 通过为模型权重引入低秩分解的适配矩阵，只训练这些

少量的适配参数，从而大幅减少微调时的参数量和计算开销。

7. **Scaling Law** 描述的是模型性能与哪项因素之间的幂律关系？

- A. 参数量
- B. 数据量
- C. 计算量
- D. 以上都是

答案： D

解析： Scaling Law（缩放定律）指出，在一定范围内，模型性能（测试损失）与模型参数量、训练数据量、计算量之间分别存在幂律关系。

8. “涌现能力 (Emergent abilities)” 的典型描述是：

- A. 模型规模越大，幻觉一定越少
- B. 模型规模越大，生成速度一定越快
- C. 随规模增大，某些任务表现从接近随机跃迁到显著高于随机
- D. 只有小模型才会出现涌现现象

答案： C

解析： PPT 对应“从接近随机到显著提升”的能力跃迁现象

9. PPT “提示词工程” 例子中，“先给出若干示例再提问同一类问题” 的做法最接近：

- A. Few-shot prompting
- B. Zero-shot prompting
- C. RAG
- D. Knowledge Distillation

答案： A

解析： 先给示例属于 few-shot 提示，常显著提高正确率。

10. 大模型的偏见更准确指：

- A. 训练时梯度必然发散

- B. 只能回答负面内容
- C. 在生成/判断时表现出系统性倾向，导致公平性风险
- D. 大模型生成含有貌似事实的虚假或误导性信息

答案： C

解析： 偏见是系统性倾向问题，关联公平性与伦理风险。

11. **RAG (Retrieval Augmented Generation)** 的核心思想是：

- A. 只用生成模型，不允许外部知识
- B. 只做检索，不进行生成
- C. 用强化学习提升推理能力
- D. 先检索外部相关信息，再结合生成模型输出答案

答案： D

解析： RAG= 检索 + 生成，用外部信息提升相关性与正确性。

12. **Clip** 模型属于哪种类型的模型？

- A. 语言模型
- B. 生成模型
- C. 单模态
- D. 多模态

答案： D

解析： Clip 模型同时处理图像和文本，通过对比学习将两种模态的表示对齐，是典型的多模态模型。

13. 以下哪项不属于大模型的评估基准？

- A. MMLU
- B. GSM8K
- C. ImageNet
- D. HumanEval

答案： C

解析：ImageNet 是计算机视觉领域的经典图像分类数据集。MMLU（语言理解）、GSM8K（数学推理）、HumanEval（代码生成）才是专门评估大语言模型能力的基准。

14. “凝聚现象”指的是在小初始化下：

- A. 神经元参数趋同
- B. 模型过拟合
- C. 模型欠拟合
- D. 梯度大小趋同

答案： A

解析：凝聚现象是指在小参数初始化的条件下，神经网络中同一层的不同神经元会学习到非常相似或趋同的参数，从而降低了模型的表达能力，使其近似于一个更小的网络。

15. 以下哪种模型不适合做 Next Token Prediction 训练？

- A. Encoder-Only
- B. Decoder-Only
- C. Encoder-Decoder
- D. 所有都适合

答案： A

解析：Next Token Prediction 是自回归生成任务，要求模型只能看到当前及之前的 token。Encoder-Only 架构（如 BERT）设计为看到整个输入上下文，更适合完形填空类任务，而非严格的自回归生成。

16. 多模态模型 Clip 的训练方式主要是：

- A. 监督学习
- B. 对比学习
- C. 强化学习
- D. 自监督学习

答案： B

解析：Clip 模型通过对比学习进行训练，目标是让匹配的（图像，文本）对的相似度尽可能高，不匹配的对的相似度尽可能低。

17. “对齐”指的是让大模型的输出与什么相一致？

- A. 数据分布
- B. 训练目标
- C. 人类价值观
- D. 测试集

答案： C

解析：对齐（Alignment）主要指通过人类反馈强化学习等技术，使大模型的输出和行为符合人类的安全性、有用性、诚实性等价值观。

18. 以下哪项不是提示词工程的目标？

- A. 减少模型参数量
- B. 提升模型生成质量
- C. 引导模型推理
- D. 适应不同任务

答案： A

解析：提示词工程旨在通过设计更好的输入提示来激发模型的潜力，提升输出质量，并不直接改变模型的参数量。参数量是模型固有的属性。

19. 在推理任务中，MMLU 主要用于评估模型的：

- A. 图像分类能力
- B. 小学数学应用题多步计算能力
- C. 代码生成通过单元测试的能力
- D. 多学科知识覆盖与语言理解/推理能力

答案： D

解析： MMLU 涵盖 STEM、人文、社科等 57 个学科的多项选择题，旨在综合评估模型的知识广度和语言理解能力。

20. GSM8K 数据集主要用于评估模型的：

- A. 语言理解能力
- B. 数学推理能力
- C. 代码生成能力
- D. 图像生成能力

答案： B

解析： GSM8K 包含数千个小学数学应用题，需要多步算术推理才能解决，专门用于测试模型的数学推理能力。

21. HumanEval 数据集主要用于评估模型的：

- A. 数学推理能力
- B. 代码生成能力
- C. 多模态理解能力
- D. 图像理解能力

答案： B

解析： HumanEval 包含一系列编程问题，要求模型根据函数签名和描述生成正确的代码，是评估代码生成能力的标准基准。

22. “锚函数”实验主要用于研究模型的：

- A. 记忆能力
- B. 生成能力
- C. 压缩能力
- D. 推理能力

答案： D

解析：“锚函数”实验通过设计具有内在规律（如对称性、复合关系）的数据集，来研究模型是简单地记忆数据，还是学会了底层规律并进行泛化推理。

23. MCP (Model Context Protocol) 在 PPT 中的定位是：

- A. 开放标准：统一大模型与外部数据源/工具之间的通信协议
- B. 一种新的 Transformer 注意力机制
- C. 一种参数高效微调方法

- D. 一类用于评测推理能力的基准数据集

答案： A

解析： MCP 解决“数据孤岛/工具对接不统一”的问题。

24. “缩放定律”指出模型性能随规模增长呈现：

- A. 线性增长
- B. 指数增长
- C. 幂律增长
- D. 对数增长

答案： C

解析： 缩放定律的核心发现是模型性能随规模（参数量、数据量、计算量）呈幂律（Power-law）提升，而非线性或指数关系。

25. 关于大模型（Foundation Model）的特征，下列说法错误的是：

- A. 参数规模通常很大（例如 100 亿以上）
- B. 主要是在小规模标注数据集上进行训练的
- C. 能够通过学习适应各种不同的下游任务
- D. 在当前的行业语境下，通常默认指代“大语言模型（LLM）”

答案： B

解析： 大模型是经过“大规模数据训练”的，而非小规模数据集。

26. 在使用 Encoder-Decoder 架构执行“翻译任务”的训练中，模型对处理“原文”和生成“译文”两个阶段的词语可见范围有不同要求。下列描述正确的是：

- A. 处理原文阶段应只能看到前文，生成译文阶段能看到原文及译文全文
- B. 处理原文阶段能看到原文全文，生成译文阶段也应能看到译文全文
- C. 处理原文阶段能看到原文全文，生成译文阶段只能看到当前已生成的译文词语
- D. 两个阶段为了逻辑统一，都应只能看到当前词及之前的词

答案： C

解析：处理原文（编码）时，上下文都是已知的，应全向关注；生成译文（解码）时，后面的词尚未生成，必须掩码处理以模拟真实的自回归预测过程。

27. 关于“初始化与凝聚”带来的机制理解，下列哪条路径能正确描述模型获得“推理解上泛化能力”的过程？

- A. 很大初始化 -> 完全不凝聚 -> 非常大复杂度 -> 轻易拟合记住数据
- B. 稍大初始化 -> 轻微凝聚 -> 稍大复杂度 -> 在对称解上泛化
- C. 小初始化 -> 凝聚 -> 尽量低复杂度 -> 只学基元函数
- D. 小初始化 -> 不凝聚 -> 复杂度极高 -> 逻辑推导

答案： C

解析：小初始化引发凝聚，迫使模型保持极低复杂度，从而只学习最本质的基元函数，最终在逻辑推导上实现泛化。

28. BERT 模型主要采用了 Transformer 的哪一层结构？

- A. Encoder 层
- B. Decoder 层
- C. 全局 Pooling 层
- D. 仅有线性层

答案： A

解析：BERT 完全采用 Transformer 中的 Encoder 层。

29. 下列哪一系列模型不属于采用了 Decoder-only 结构的大模型？

- A. GPT 系列
- B. Llama 系列
- C. DeepSeek 系列
- D. BERT 模型

答案： D

解析：GPT、Llama、DeepSeek 为 Decoder-only，而 BERT 是 Encoder-only。

30. 解码器 (Decoder) 为了保证因果相关性, 在 Attention 矩阵中进行了什么操作?

- A. 全局 Softmax
- B. 上三角部分掩码
- C. 下三角部分掩码
- D. 随机丢弃 Token

答案: B

解析: Decoder 通过 causal mask 确保模型只能关注到前边的信息。

31. CLIP 模型的核心原理是:

- A. 仅对文本进行预训练
- B. 将文本和图片分别进行编码并对齐
- C. 仅对图片进行生成训练
- D. 使用强化学习对齐人类偏好

答案: B

解析: CLIP 是通过文本和图片编码对齐, 匹配相似度高。

32. 在 LoRA 微调技术中, 为了降低可训练参数量, 对权重更新部分采用了:

- A. 全量权重矩阵 W 直接更新
- B. 低秩分解矩阵 A 和 B (秩 $r < d$)
- C. 仅更新偏置项
- D. 知识蒸馏

答案: B

解析: LORA 更新为 $h = Wx + BAx$, 通过低秩矩阵 A, B 减少更新参数。

33. OpenAI 在 2020 年提出的 Scaling Law 指出模型测试损失与以下哪个因素无关?

- A. 计算量
- B. 参数规模

- C. 数据量
- D. 提示词长度

答案： D

解析： 缩放定律公式涉及算力、数据、参数，不包含提示词长度。

34. 模型仅通过任务描述和少量示例即可执行新任务，无需调整权重的能力称为：

- A. Fine-tuning
- B. In-context learning
- C. Chain of Thought
- D. Supervised Learning

答案： B

解析： In-context learning 是大模型展现出的重要能力。

35. 通过引导模型生成中间推理步骤来显著提高复杂任务表现的方法是：

- A. Chain of Thought
- B. In-context learning
- C. Prompt Tuning
- D. Zero-shot learning

答案： A

解析： 思维链是通过推理步骤提高复杂任务表现。

36. 知识蒸馏的主要目的是：

- A. 让小模型变大
- B. 让小模型也可以完成大模型所做的事
- C. 提高预训练的成本
- D. 增加模型的层数

答案： B

解析： 蒸馏是为了让小模型继承大模型能力，提高效率。

37. 在 DeepSeek-R1 的强化学习过程中，观察到模型生成的文本长度如何变化？

- A. 逐渐缩短 B. 保持不变 C. 逐渐增长 D. 随机波动

答案： C

解析： 在 DeepSeek-R1 的强化学习过程中，文本长度随着推理能力增强而逐渐增长。

38. 在大模型的预训练（Pretrain）过程中，最核心且常用的训练框架是：

- A. Masked Language Modeling
- B. Next Token Prediction
- C. Contrastive Learning
- D. Supervised Fine Tuning

答案： B

解析： 在大模型的预训练(Pretrain)过程中,预训练的 Next Token Prediction 框架最为常用。

39. BERT 预训练中“随机 mask 句子中一些词让模型预测”最对应哪类任务：

- A. Next Token Prediction
- B. 强化学习对齐
- C. 对比学习
- D. 完形填空

答案： D

解析： BERT 是典型 MLM（完形填空式）预训练。。

40. 凝聚现象（Condensation）通常发生在下列哪种模型初始化配置下？

- A. 很大初始化
- B. 小初始化
- C. 随机初始化且秩很大
- D. 不进行任何初始化

答案： B

解析： 在小初始化下凝聚现象会发生。

41. 在小初始化下，同层神经元会有趋同偏好，这种现象本质上是：

- A. 对模型的复杂度控制
- B. 增加了模型参数量
- C. 导致模型无法收敛
- D. 导致模型死记硬背

答案： A

解析： 小初始化带来的凝聚本质上是对模型的复杂度控制。

42. 下列哪个模型是在 DeepSeek-V3 基础上通过强化学习逐渐增强推理能力的例子？

- A. BERT
- B. GPT-2
- C. DeepSeek-R1-Zero
- D. Word2Vec

答案： C

解析： DeepSeek-R1-Zero 是在 DeepSeek-V3 基础上通过强化学习逐渐增强推理能力的模型。

43. 在神经网络学习“锚函数”的实验中，损失函数（Loss）通常在何处计算？

- A. 每一个隐含层神经元
- B. 输入层
- C. 输出层与目标值之间
- D. 随机选择一层

答案： C

解析： 损失值在输出层与目标值对比处计算。

44. 幻觉 (Hallucination) 是指大模型生成了：

- A. 含有貌似事实的虚假或误导性信息
- B. 非常高深的专业知识
- C. 用户无法理解的代码
- D. 完全随机的乱码

答案： A

解析： 幻觉 (Hallucination) 是指大模型生成了含有貌似事实的虚假或误导性信息。

45. “锚函数 (anchor function)” 设定里，“损失值仅在此处计算” 指的是：

- A. 只在指定锚点 token 的预测与目标之间计算 loss
- B. 对序列中每个 token 都计算 loss
- C. 只在输入层计算 loss
- D. 只在中间隐层计算 loss

答案： A

解析： 锚函数实验的关键就是把监督信号集中在锚点位置，用来研究泛化/记忆机制。。

46. 关于 DeepSeek-R1-Zero 模型出现的“自我反思 (self-reflection)”现象，下列描述最准确的是：

- A. 必须依靠人工标注数据进行监督微调才能产生
- B. 必须引入外部知识库进行检索才能产生
- C. 在纯粹的强化学习过程中，模型自发学会了在推理中修正错误
- D. 只有在参数量超过 1000 亿时才会出现

答案： C

解析： Deepseek-R1-Zero 模型在强化学习过程中会自发出现自我反思的情况，无需特定监督。

47. 当前大模型在逻辑推理中容易出现什么问题？

- A. . 计算速度过慢
- B. 无法理解中文
- C. 在多步推理中容易犯错（如由段数推导次数），需要引导
- D. 只能做选择题

答案： C

解析： 模型在处理逻辑陷阱时可能需要引导或容易出错。

48. 根据 PPT 对 Attention 计算的描述，编码器与解码器的差异更准确的是：

- A. 编码器不用 softmax，解码器用 softmax
- B. 解码器先做 causal mask 再按行 softmax；编码器直接按行 softmax
- C. 编码器必须做下三角 mask；解码器必须做上三角 mask
- D. 二者都必须随机 mask 一半 token

答案： B

解析： Decoder 上三角 mask 后再 softmax；Encoder 直接 softmax

49. 2017 年之前，Seq2Seq 翻译模型中的 encoder/decoder 通常采用：

- A. LSTM
- B. Transformer
- C. Diffusion Model
- D. GNN

答案： A

解析： PPT：2017 年前 Seq2Seq 多为 LSTM。

50. Word2Vec 中，Skip-gram 与 CBOW 的差别更准确的是：

- A. Skip-gram 用上下文预测中心词；CBOW 用中心词预测上下文

- B. Skip-gram 用中心词预测上下文；CBOW 用上下文预测中心词
- C. 两者都只预测句子长度
- D. 两者都只能用于图像任务

答案： B

解析： Skip-gram： 中心 (→) 上下文；CBOW： 上下文 (→) 中心。

51. ViT (Vision Transformer) 的基本做法是：

- A. 把图片切成小块并当作 token 送入 Transformer Encoder
- B. 把图片转成音频 token 再输入模型
- C. 用 Decoder-only 生成每个像素
- D. 只用 CNN 不使用 Transformer

答案： A

解析： ViT 将图片切块，像处理词元一样处理 patch token。。

52. Next Token Prediction 训练中，“期望输出”与输入序列的关系更接近：

- A. 输出与输入完全相同
- B. 输出是输入序列整体右移一位
- C. 输出是随机 mask 后的输入
- D. 输出只包含句子长度

答案： B

解析： NTP 的监督信号是“预测下一个 token”。

53. “Sora” 模型属于以下哪种应用领域？

- A. 文生文本
- B. 文生音频
- C. 文生视频
- D. 蛋白质结构预测：

答案： C

解析：由 Sora 生成的“棕熊吃刺身”视频案例。。

54. “全量微调”与“LoRA 微调”的对比中，LoRA 主要训练的是：

- A. 预训练权重 W 的全量参数
- B. 额外引入的低秩适配参数
- C. 词表本身
- D. 仅训练 loss 函数不训练参数

答案：B

解析：LoRA 通过低秩增量参数表示更新，减少可训练参数与显存/计算开销。

55. DeepSeek-R1-Zero 在强化学习后训练中，会自发出现：

- A. 图文对齐能力
- B. 自我反思
- C. 将 Transformer 替换为 LSTM
- D. 必然消除所有幻觉

答案：B

解析：PPT 第 24 页明确写到“自发出现自我反思”。

56. “提示词工程”最关键的作用是：

- A. 改变模型权重并永久记住新知识
- B. 通过设计输入方式影响模型输出质量
- C. 替代所有训练过程
- D. 保证模型不会产生任何错误

答案：B

解析：提示词工程通过组织输入信息、约束格式等，影响模型推理路径与输出质量。

57. “给出少量示例再提问”提升表现，更接近：

- A. in-context learning

- B. 权重蒸馏
- C. 参数剪枝
- D. 梯度累计

答案： A

解析：给示例属于上下文学习，通过输入中的示范让模型临时执行新任务，无需更新权重。

58. 知识蒸馏更典型的“教师—学生”目标是：

- A. 让学生模型模仿教师模型的输出行为，以获得压缩后的能力
- B. 让教师模型学习学生模型的随机初始化
- C. 让学生模型只学习训练数据 ID，不学习规律
- D. 让学生模型直接变成更大参数量

答案： A

解析：蒸馏让小模型也能完成大模型做的事。

59. CLIP 训练方式的关键点更合理的是：

- A. 仅用图像分类标签监督
- B. 只训练解码器不训练编码器
- C. 分别编码文本与图像，并通过对比学习对齐
- D. 只优化生成图像的像素误差

答案： C

解析：CLIP 用对比学习最大化匹配图文对的相似度、最小化不匹配对的相似度。

60. 人工评估” 的重要性在于：

- A. 机器无法自动评分
- B. 只有人类评分才能从逻辑性、合理性等多维度衡量推理质量，而不仅是看最终答案
- C. 人工评估速度最快
- D. 只有人工才能看懂代码

答案： B

解析： PPT 第 64 页指出人工评估由专家进行，衡量准确性、逻辑性、合理性等多维度。

61. 关于“大模型幻觉”的理解，较合理的是：

- A. 模型随机输出乱码，与训练无关
- B. 只要增加参数规模就一定消失
- C. 只在图像生成中出现
- D. 模型输出看似合理但可能含虚假信息

答案： D

解析： 幻觉指语言表面合理但事实不可靠，不能简单认为靠增大规模必然消失。

62. “Scaling law（幂律关系）”更合理的含义是：

- A. 模型越大，训练越快且损失必为零
- B. 在一定范围内，损失随参数/数据/算力呈幂律下降趋势
- C. 损失与参数规模严格线性关系
- D. 只要算力翻倍，损失立刻减半且对所有任务都成立

答案： B

解析： 幂律关系强调“在一定范围内的经验规律”，并非无条件成立，也不一定线性。

63. “涌现能力（emergent abilities）”更接近以下哪种现象？

- A. 参数增加后，部分任务从近似随机跃迁到明显优于随机
- B. 参数增加后，模型性能平滑缓慢提高
- C. 训练轮数越多，模型一定产生幻觉
- D. 只要改提示词，所有能力都会出现

答案： A

解析： 涌现指跨过某规模阈值后，某些能力阶段性“突然出现”，表现为跃迁式提升。

64. 要评估“推理质量”而不只看最终答案对错，更合适的方法是：

- A. 人工评估推理过程的逻辑性与合理性
- B. 只看训练集 loss 是否下降
- C. 只统计生成文本长度
- D. 只比较模型参数量大小

答案： A

解析：推理质量不仅是结果对错，还包括逻辑连贯性、合理性、可解释性等，需要过程维度评估。

65. 当模型对外部事实容易出错时，更直接的工程缓解策略是：

- A. 增加 dropout 并减少上下文
- B. 把所有输出限制为固定模板
- C. 关闭注意力机制
- D. 使用 RAG 引入可检索的相关证据

答案： D

解析：事实性错误常由缺证据或记忆不可靠导致，RAG 用检索证据增强上下文是直接缓解方式。

66. 关于“大模型/基础模型”的理解，较准确的是：

- A. 参数规模小但结构复杂
- B. 只用于翻译且必须监督训练
- C. 参数规模大并经大规模训练，可迁移到多类任务
- D. 只要能生成文本就属于基础模型

答案： C

解析：基础模型通常以大规模参数与大规模数据训练为特征，并可通过迁移适配多种任务。

67. 多模态词元化更接近以下哪种含义：

- A. 将图像全部转换为英文句子
- B. 将数据压缩为一个标量

- C. 只保留标签丢弃内容
- D. 将多模态数据转换为序列形式以统一建模

答案： D

解析：词元化的目的在于把不同模态转为模型可处理的序列表示，便于统一的注意力建模。

68. PPT 给出的 AI Agent 更接近以下哪种组合？

- A. LLM（大脑）+ 规划 + 记忆 + 工具调用
- B. 仅有 LLM 即可称为 Agent
- C. 仅有检索模块（RAG）即可称为 Agent
- D. 仅有对比学习即可称为 Agent

答案： A

解析： PPT 第 31 页给出 Agent=LLM+ 规划 + 记忆 + 工具调用。

69. 下列哪项更符合 Encoder-only 的典型用途：

- A. 逐 token 文本生成
- B. 文本分类与理解
- C. 自回归续写
- D. 语音合成

答案： B

解析： Encoder-only 往往可利用双向上下文，适合理解与分类等判别式任务。

70. 在 Decoder-only 的自回归生成中，因果掩码的作用是：

- A. 允许看到未来 token
- B. 只保留句子中间 token
- C. 禁止看到未来 token
- D. 只随机丢弃 token

答案： C

解析：因果掩码保证生成遵循从左到右的因果关系，防止利用未来信息。

71. 在大模型发展历史中，2017 年 Vaswani 等人发表的里程碑式论文是：

- A. 《Attention is all you need》
- B. 《ImageNet Classification with Deep Convolutional Neural Networks》
- C. 《Deep Residual Learning for Image Recognition》
- D. 《BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding》

答案：A

解析：PPT。

72. “文生图 (Text-to-Image)” 应用的代表工具包括：

- A. Stable Diffusion、Midjourney
- B. MMLU、GSM8K
- C. BERT、Word2Vec
- D. MCP、RAG

答案：A

解析：Stable diffusion、Midjourney 用于文生图。

73. 微调 (Fine-tuning) 的典型目的更接近：

- A. 用海量通用数据学习基础能力
- B. 在更小的特定数据上适配特定任务
- C. 只修改输入数据不训练模型
- D. 只增加推理长度不训练

答案：B

解析：微调往往在相对小规模的数据上优化特定任务表现。

74. PPT 关于蒸馏结果的描述，正确的是：

- A. QwQ 在同参数量下优于由 DeepSeek-R1 蒸馏得到的模型
- B. 蒸馏会必然降低小模型效果
- C. 蒸馏只对图像模型有效
- D. 由 DeepSeek-R1 蒸馏得到的同参数量模型可优于 QwQ

答案： D

解析： 由 DeepSeek-R1 蒸馏得到的同参数量模型可优于 QwQ。

75. MCP (Model Context Protocol) 在 PPT 中的核心定位是：

- A. 统一大模型与外部数据源/工具之间通信的开放协议标准
- B. 一种新的注意力机制
- C. 一种评测推理能力的基准数据集
- D. 一种图像生成模型架构

答案： A

解析： Anthropic 提出的开放标准，解决数据孤岛与工具对接问题。

76. “偏见 (bias)” 与 “幻觉 (hallucination)” 更合理的区分是：

- A. 偏见 = 看似事实的错误信息；幻觉 = 系统性倾向
- B. 二者完全等价
- C. 偏见 = 系统性倾向与公平性风险；幻觉 = 貌似事实但虚假的信息
- D. 二者只存在于图像生成中

答案： C

解析： PPT。

77. 在 “锚函数” 实验的各种任务复杂度中，哪种关系被认为是最容易通过记忆 (Memorization) 而非推理来拟合的？

- A. 复合关系
- B. 随机映射
- C. 对称性
- D. 线性方程

答案： B

解析： PPT 第 89 页的机制理解图暗示，对于无规律或高复杂度的任务（如完全不凝聚），模型倾向于“记住数据”。

78. “涌现能力”最接近以下哪个现象：

- A. 性能随规模线性增长
- B. 规模达到某阈值后某些能力突然显著提升
- C. 模型训练必然失败
- D. 模型无法泛化

答案： B

解析： 涌现能力描述“非线性跃迁”，而非平滑线性变化。

79. 关于 Scaling law 的理解，较合理的是：

- A. 损失与参数量严格线性关系
- B. 在一定范围内损失随规模呈幂律下降趋势
- C. 增加数据必然使损失为 0
- D. 增加算力必然消除幻觉

答案： B

解析： Scaling law 体现经验性的幂律趋势，但不保证无限扩展效果。

80. 大模型“对齐”的核心关注点更接近：

- A. 让输出更像随机文本
- B. 让输出更符合人类偏好与安全约束
- C. 让模型只能回答一个领域
- D. 让模型参数变少

答案： B

解析： 对齐强调可用性与安全性，使输出更符合人类价值与约束。

81. 在训练-推理流程上，“预训练 → 微调”的作用链条更接近：

- A. 先学特定任务，再学通用能力
- B. 先学通用能力，再适配特定任务

- C. 只做推理，不做训练
- D. 只做数据清洗，不做建模

答案： B

解析：预训练提供通用表征能力，微调将其进一步适配到具体任务。

82. 下列哪项更容易触发“幻觉”风险：

- A. 用外部检索补充证据
- B. 对缺乏事实依据的问题强行给出确定答案
- C. 明确指出不确定并给出依据
- D. 引用可核验的上下文

答案： B

解析：幻觉常发生在模型缺乏支撑信息但仍输出确定答案的情形。

83. 对比学习中“匹配对拉近、非匹配对推远”体现的是：

- A. 回归思想
- B. 分类思想
- C. 度量学习思想
- D. 聚类思想

答案： C

解析：对比学习通过相似度约束优化表示空间，属于度量学习范式。

84. AI Agent 区别于普通聊天模型的关键能力之一是：

- A. 只能输出更长的回答
- B. 能进行任务分解与工具调用以完成闭环
- C. 只能回答选择题
- D. 只依赖随机采样

答案： B

解析：Agent 强调规划、执行、反馈与工具调用，从而完成复杂任务闭环。

85. 下列哪项最能体现“提示工程”的价值：

- A. 让模型输出更短
- B. 通过结构化要求与示例减少输出偏差
- C. 降低训练数据规模
- D. 让模型不需要训练

答案： B

解析： 结构化提示与示例能约束输出格式、提升推理稳定性与任务对齐度。

86. 对齐（Alignment）”的主要目标是：

- A. 用蒸馏把大模型压缩成小模型
- B. 用对比学习对齐图文表示
- C. 让模型在 ImageNet 上更高分
- D. 通过强化学习使输出更符合人类价值观

答案： D

解析： Alignment 强调安全、有用、诚实等价值观一致性。

二、判断题

1. 基础模型（Foundation model）的核心特征之一是参数量很大。

答案： T

解析： 我们通常所说的大模型参数量很大（例如 100 亿以上）。

2. BERT 模型采用 Decoder-Only 架构。

答案： F

解析： BERT 是 Encoder-Only 架构的典型代表。

3. GPT 系列模型采用 Encoder-Only 架构

答案： F

解析： GPT 系列是 Decoder-Only 架构的典型代表。

4. 预训练的目标是学习通用语言表示。

答案：T

解析：预训练的目标是在大规模数据上学习通用的语言表示和知识，为下游任务提供基础。

5. 微调通常使用无监督学习方式。

答案：F

解析：微调通常使用特定任务的带标签数据，属于监督学习范式。

6. LoRA 通过低秩适应减少微调参数量。

答案：T

解析：LoRA 的核心思想就是通过低秩适配来大幅减少需要微调的参数数量。

7. Scaling Law 仅描述参数量与性能的关系。

答案：F

解析：Scaling Law 描述了模型性能与参数量、数据量、计算量三者之间的幂律关系。

8. 上下文学习需要更新模型权重。

答案：F

解析：上下文学习的核心特点就是模型不更新权重，仅通过提示中的上下文信息进行学习。

9. 思维链（Chain-of-Thought）用于提升模型生成速度。

答案：F

解析：思维链的主要作用是提升复杂任务的推理准确性，而不是生成速度。

10. 大模型幻觉指模型生成虚假信息。

答案：T

解析：定义“幻觉”为“含有貌似事实的虚假或误导性资讯”。

11. 知识蒸馏用于训练大模型。

答案：F

解析：知识蒸馏是将大模型的知识迁移到小模型，而非用于训练大模型本身。

12. Clip 模型是单模态模型。

答案：F

解析：Clip 模型同时处理图像和文本，是多模态模型。

13. Next Token Prediction 任务使用交叉熵损失。

答案：T

解析：Next Token Prediction 本质上是分类任务，交叉熵是其标准损失函数。

14. MMLU 是用于评估编程能力的基准。

答案：F

解析：MMLU 评估多领域语言理解，编程能力主要由 HumanEval 等基准评估。

15. GSM8K 是数学推理数据集。

答案：T

解析：GSM8K 是专门的小学数学文字问题数据集。

16. HumanEval 是语言理解数据集。

答案：F

解析：HumanEval 评估编程（代码生成）能力，不是广义的语言理解。

17. 小初始化条件会引发凝聚现象。

答案：T

解析：课程明确指出小初始化导致凝聚。

18. Encoder-Only 架构适合做 Next Token Prediction。

答案：F

解析：Encoder-Only 架构（如 BERT）采用双向注意力，能看到整个序列，违背了 Next Token Prediction 要求的因果性，因此不适合直接用于该任务的训练。

19. 多模态模型 Clip 使用对比学习训练。

答案：T

解析：Clip 模型的训练依赖于图像-文本对的对比损失函数。

20. MCP 的提出目的之一是统一大模型与外部数据源、工具之间的通信协议，以缓解“数据孤岛”限制。

答案：T

解析：对应 PPT 对 MCP 的定义与动机描述。

21. 在提示词中先给出多个示例再提问（few-shot）通常比直接提问更容易得到正确答案。

答案：T

解析：PPT 用“妹妹年龄”例子展示了“给示例再问”显著改善结果。

22. 大模型的应用包括文本生成、代码生成等。

答案：T

解析：课堂案例指出这些典型应用。

23. 大模型不具备解决数学应用题的能力。

答案：F

解析：课堂案例给出了数学应用题的具体应用。

24. Stable Diffusion 是文生图模型。

答案：T

解析：课堂案例在文生图模型中将 Stable Diffusion 作为例子举出。

25. Sora 是文生视频模型。

答案：T

解析：Sora 生成视频案例作为课堂案例展示。

26. 知识蒸馏的主要目的之一是让更小、更便宜的模型尽量完成大模型（更贵）能做的事。

答案：T

解析：对应 PPT“目的：让小模型也可以完成大模型（贵）所做的事”。

27. 缩放定律指出模型规模越大性能一定越好。

答案：F

解析：缩放定律描述的是在一定范围内的趋势。当规模过大超出“计算最优”边界，或遇到其他瓶颈时，性能可能不再提升或提升甚微。

28. 锚函数实验用于研究模型记忆与推理机制。

答案：T

解析：正是通过锚函数实验来探究模型是记忆还是推理。

29. 初始化为零时模型容易训练。

答案：F

解析：零初始化会导致所有神经元具有相同的输出和梯度，破坏了对称性，使得网络无法正常学习。

30. 在现代大语言模型中，词向量通常实现为“可学习的嵌入向量”，并参与后续训练。

答案：T

解析：Word2Vec。

31. 编码器 (Encoder) 在计算 Attention 矩阵时，原文的每个词都能看到原文里的所有其它词。

答案：T

解析：处理原文时，每个词都能看到原文里的所有其它词，即全向关注。

32. Transformer 架构主要由编码器 (Encoder) 和解码器 (Decoder) 两个主要部分组成。

答案：T

解析：Transformer 模型包含这两个核心部分。

33. BERT 模型在训练过程中会随机 mask 句子中一些词让模型预测。

答案：T

解析：这是 BERT 作为 Encoder-only 模型的核心预训练策略。

34. 目前的主流大语言模型主要以生成内容为主，因此 Encoder-only 结构的模型占据了市场主导地位。

答案：F

解析：目前的生成式大模型主要采用的是 Decoder-only 结构。

35. ViT (Vision Transformer) 通过将图片切分为小块 (Patches)，交由 Transformer Encoder 处理。

答案：T

解析：这是 ViT 处理视觉数据的核心逻辑。

36. 预训练 (Pretrain) 在算力、硬件、集群规模等方面都有极高的增长需求，成本非常昂贵。

答案：T

解析：预训练很贵，且计算资源需求在不断增长。

37. 微调 (Fine tuning) 通常需要在比预训练阶段规模更大的数据集上进行训练，以达到更好的效果。

答案：F

解析：预训练使用大规模数据 (Large data)，而微调使用小规模特定数据 (Small data)。

38. 对齐 (Alignment) 的目标是通过强化学习的方法，让大模型的输出与人类价值观相符合。

答案：T

解析：对齐是为了构建与人类价值观一致的智能。

39. 在提示词工程 (Prompt Engineering) 中，不同的提示词对模型回答结果的影响非常小。

答案：F

解析：不同提示词对回答影响很大。

40. 知识蒸馏 (Knowledge Distillation) 中，Student 模型学习的唯一目标就是真实标签 (Hard Label)。

答案：F

解析：总损失由 L_{soft} (学习 Teacher 输出) 和 L_{hard} (学习真实标签) 两部分组成。

41. Scaling Law 指出，在一定范围内，给定模型规模下，数据量越大，模型的测试损失越低。

答案：T

解析：数据量 D 与测试损失 L 之间存在幂律下降关系。

42. DeepSeek-R1-Zero 模型在推理过程中会自动出现“自发反思 (自我反思)”的情况。

答案：T

解析：强化学习过程中模型会自发出现自我反思案例。

43. 大语言模型在预测时具有完全的客观性，不会产生任何性别或职业相关的偏见。

答案：F

解析：大模型在预测时会有一些自有的偏见（如对不同性别的职业倾向预测）。

44. 大语言模型预训练中的 **Next Token Prediction** 任务，是指在给定输入序列的情况下，预测序列中下一个出现的词元。

答案：T

解析：NTP 是生成式预训练（Pretrain）的核心框架。

45. 思维链（**Chain of Thought**）技术通过引导模型生成中间推理步骤，能显著提高模型在复杂任务中的表现。

答案：T

解析：思维链通过引导生成推理步骤而非直接给答案，提升了复杂逻辑能力。

46. 人工评估（**Human Evaluation**）模型推理能力时，通常只看结果是否正确，不考虑逻辑性和合理性。

答案：F

解析：人类评分可以从多个维度进行，如推理的准确性、逻辑性、合理性。

47. 很大的参数初始化会导致模型更容易“记住”数据（死记硬背），从而导致泛化性很差。

答案：T

解析：很大初始化导致完全不凝聚，模型轻易拟合记住数据，完全不泛化。

48. 凝聚现象意味着神经元在小初始化下趋同，使大网络在功能上等价于小网络。

答案：T

解析：经过训练达到参数凝聚状态后，大网络在表达上等效于小网络。

49. PPT 提到 Deepseek-R1-Zero 在强化学习后训练过程中，模型生成的文本长度会逐渐增长。

答案：T

解析：对应“强化学习后训练：增强模型推理能力”页的描述。

50. Decoder-Only 架构通常更适合做文本生成任务。

答案：T

解析：自回归生成需要“只看历史、不看未来”，Decoder-Only 天然使用因果掩码来逐 token 生成。

51. Encoder-Only 模型通常能同时利用当前位置前后的上下文信息。

答案：T

解析：Encoder 常用双向注意力机制，可同时看到左侧与右侧上下文，更适合理解类任务。

52. 在机器翻译中，生成译文时允许直接看到未来的译文 token。

答案：F

解析：自回归生成必须避免信息泄露，未来 token 尚未生成，若可见会破坏生成设定。

53. Skip-gram 的训练目标是用中心词预测上下文词。

答案：T

解析：Skip-gram：中心词 → 上下文；CBOW：上下文 → 中心词。

54. 预训练 (Pretrain) 与微调 (Fine-tuning) 的主要区别之一是：预训练面向通用能力、用大规模通用数据；微调用更小的任务/领域数据提升特定任务效果。

答案：T

解析：PPT 分别在“预训练”“微调”页强调了通用 vs 特定与数据规模差异。

55. 微调通常在特定任务数据上继续训练，从而提升该任务效果。

答案：T

解析：微调是在预训练基础上继续训练，以适配某个具体任务或领域。

56. LoRA 的更新通常比全参数微调需要更少的可训练参数。

答案：T

解析：LoRA 用低秩增量矩阵替代全量权重更新，因此训练参数显著减少。

57. 提示词工程等同于修改模型参数，因此会永久改变模型能力。

答案：F

解析：提示词工程改变的是输入上下文，不会永久修改模型权重。

58. 给出几个示例再提问，通常能提高同类问题的回答质量。

答案：T

解析：示例能提供“任务格式/规律”，属于 in-context learning，常提升稳定性与正确率。

59. 知识蒸馏只适用于图像模型，语言模型无法使用。

答案：F

解析：蒸馏同样广泛用于语言模型：用 teacher 的输出分布指导 student 学习。

60. CLIP 的一个关键思想是让图像表示与文本表示在同一空间对齐。

答案：T

解析：CLIP 用对比学习将图文映射到同一向量空间，匹配对更相似、非匹配更不相似。

61. RAG 通常包含 “检索相关内容 + 基于检索内容生成”。

答案：T

解析：RAG（检索增强生成）先检索证据再生成回答，以提升相关性与事实性。

62. MCP（模型上下文协议）是由 OpenAI 在 2024 年推出的开放标准。

答案：F

解析：MCP 是由 Anthropic 推出的

63. 大模型偏见指模型输出可能呈现系统性的倾向或不公平。

答案：T

解析：偏见可能来自训练数据分布与训练机制，导致输出对某类群体/观点偏向。

64. 推理任务只包含数学推理，不包括常识推理或因果推理。

答案：F

解析：推理包含多种类型，如逻辑、数学、常识、因果等，不仅限数学。

65. HumanEval 是用于评估编程能力的一类基准测试。

答案：T

解析：HumanEval 常要求模型补全函数或生成可运行代码，以评估编程能力。

66. 幂律关系意味着只要无限增大参数，测试损失必然严格降为 0。

答案：F

解析：幂律关系通常只在一定范围内近似成立，且受数据、任务、训练限制，不保证严格趋于 0。

67. 涌现能力更像“连续平滑提升”，而不是“阶段性出现”。

答案：F

解析：涌现通常表现为跨过规模阈值后，某些任务性能从接近随机跃迁到明显提升。

68. AI Agent（人工智能体）通常由 LLM（大脑）、规划、记忆和工具调用四个部分组成。

答案：T

解析：对应 PPT 关于 AI Agent 的公式定义

69. 对齐的目标可以理解为：让模型输出更符合人类价值与规范。

答案：T

解析：对齐强调输出行为与人类偏好、价值、政策规范一致，而非只追求性能指标。

70. 大模型通常具有较大的参数规模，并使用大规模数据进行预训练。

答案：T

解析：大模型的核心特征之一是参数量与训练数据规模显著增大，通过预训练获得通用表示能力。

71. Decoder-only 结构在生成任务中通常使用因果掩码，以避免看到未来 token。

答案：T

解析：因果掩码保证当前位置只能关注自己及之前的 token，防止“偷看未来信息”，符合自回归生成约束。

72. Encoder-only 结构的注意力机制通常可以同时利用前后文信息。

答案：T

解析：Encoder 侧重理解输入，Self-Attention 往往对全序列开放，因此能利用双向上下文。

73. Word2Vec 技术的主要作用是将自然语言中的词语转换为计算机可处理的向量，且这些向量在学习后具备语言含义。

答案：T

解析：对应 PPT 对 Word2Vec 功能的描述。。

74. CBOW 的训练目标是用上下文词预测中心词。

答案：T

解析：CBOW 先聚合上下文信息，再预测中心词，与 Skip-gram 的方向相反。

75. BERT 属于 Encoder-only 架构，并常用“遮盖预测”的训练方式。

答案：T

解析：BERT 通过随机遮盖输入中的部分 token，并预测被遮盖的 token 来学习双向表示。

76. GPT 类模型常采用 Decoder-only 架构，适合完成文本生成任务。

答案：T

解析：Decoder-only 配合因果掩码以自回归方式逐 token 生成，天然适配生成式任务。

77. 微调阶段，在问题-答案对上训练时，一般尽在答案的 token 上计算损失。

答案：T

解析：微调阶段的训练方式。

78. 大模型会在预测时表现出某些系统性偏好（偏见），这是大模型常见现象之一。

答案：T

解析：PPT“偏见”页明确指出“大模型会有自有偏见。。

79. LoRA 通过冻结原模型大部分参数，仅训练低秩增量参数实现高效适配。

答案：T

解析：LoRA 用低秩矩阵对权重更新进行近似，大幅降低训练成本与存储开销。

80. 提示词（Prompt）的写法不会影响模型输出，因此提示工程没有意义。

答案：F

解析：不同提示会改变模型对任务的理解方式与输出分布，加入示例、约束格式等通常能显著改善效果。

81. “幻觉”指模型输出在表面上合理，但事实层面可能错误或不可验证的内容。

答案：T

解析：幻觉的关键是“看起来像真的”，但缺乏事实依据或与真实信息不一致。

82. 模型的偏见只来自推理阶段的随机性，与训练数据无关。

答案：F

解析：偏见往往由训练数据分布、标注偏差与模型归纳偏置共同决定，并可在推理阶段表现出来。

83. RAG 是一种预训练技术，通过外部的文献辅助训练。

答案：F

解析：RAG 先检索相关材料，再将其作为上下文输入模型，提高回答相关性与可用性。

84. AI Agent 只需要语言模型本体即可，不需要规划能力或工具调用。

答案：F

解析：Agent 通常包含目标规划、任务分解、记忆与工具调用等模块，单靠语言模型很难稳定完成复杂任务闭环。

85. **Scaling law** 体现为：在一定范围内，模型规模/数据量/算力与损失可能呈幂律关系。

答案：T

解析：幂律趋势意味着扩大规模常带来可预测的性能改善，但不保证无限扩展下持续成立。

86. 上下文学习 (In-context learning) 通常不需要更新模型参数，仅依赖提示中的任务描述与示例。

答案：T

解析：ICL 的关键是“通过上下文完成适配”，模型权重不变，但行为可因提示变化而变化。

87. 思维链 (Chain of Thought) 提示主要通过引导中间推理步骤提升复杂任务表现。

答案：T

解析：显式生成中间推理步骤有助于降低直接猜测答案的概率，提高推理稳定性与可解释性。

88. “涌现能力”强调能力随着规模增加呈严格线性增长。

答案：F

解析：涌现能力更像“非线性跃迁”，即规模跨过某阈值后表现突然明显提升，而非线性平滑增长。

89. 对齐训练的目标之一是让模型能够适应不同问题的回答格式，方便在具体任务上评测模型性能。

答案：F

解析：对齐关注可用性与安全性，使模型在能力提升的同时减少风险输出并更贴近人类偏好。

90. Decoder 的自注意力会使用 causal mask (上三角掩码), 从而保证每个 token 只能关注自身及之前的信息

答案: T

解析: PPT 明确对比了 Encoder/Decoder 的 attention mask 机制。

三、填空与计算题

1. Transformer 由 _____ 和 _____ 两部分组成。

答案: 编码器 (Encoder)、解码器 (Decoder)

解析: Transformer 由编码器 (Encoder)、解码器 (Decoder) 这两部分组成。

2. 缩放定律描述模型性能与 _____、_____、_____ 之间的幂律关系。

答案: 参数量、数据量、计算量

解析: “Scaling law”与参数量、数据量、计算量三者均有关系。

3. LoRA 全称是 _____, 训练成本比全量微调 _____。

答案: Low-Rank Adaptation, 低

解析: LoRA 全称为 Low-Rank Adaptation, 中文为低秩自适应。

4. 在 Decoder-Only 架构中, 注意力使用 _____ mask, 使每个 token 只能关注到当前 token 及 _____。

答案: Causal (上三角); 之前的 token

解析: 课程中给出了定义。

5. Clip 模型是一种 _____ 模型, 使用 _____ 学习训练。

答案: 多模态、对比

解析： CLIP（Contrastive Language-Image Pre-training）是基于对比学习的语言-图像预训练模型。

6. 基础模型通常具有很大的参数规模，并在 _____ 数据上进行训练。

答案： 大规模

解析： 大规模数据是基础模型获得通用能力与泛化能力的重要来源。

7. 大语言模型常用的预训练目标是 Next Token _____。

答案： Prediction（预测）

解析： Next Token Prediction 指根据前文预测下一个 token，是常见预训练目标。

8. 在 Decoder-Only 中常用的 attention mask 是 _____ mask。

答案： causal（因果）

解析： 因果掩码用于屏蔽未来 token，保证自回归生成的正确训练/推断。

9. Encoder-Only 更常用于文本 _____ 类任务。

答案： 理解

解析： 双向上下文建模更适合分类、抽取、匹配等理解任务。

10. BERT 的训练中常随机 mask 一些词，并让模型去 _____ 这些词。

答案： 预测

解析： 这是 Masked Language Modeling（完形填空式预测）思想。

12. Word2Vec 的 Skip-gram 是用中心词预测 _____。

答案： 上下文

解析：Skip-gram 的方向是中心 $\rightarrow$ 上下文，用于学习词向量表示。

13. CLIP 的训练方式属于 _____ 学习，用于对齐图文表示。

答案：对比

解析：对比学习通过拉近匹配对、推远不匹配对来完成对齐。

14. 微调通常在预训练模型基础上，用特定数据继续进行 _____。

答案：训练

解析：微调即对预训练模型进行任务/领域适配的继续训练。

15. LoRA 的全称是 Low Rank _____。

答案：Adaptation

解析：Low Rank Adaptation 强调用低秩参数实现高效适配。

16. RAG 的全称是 Retrieval Augmented _____。

答案：Generation

解析：Retrieval Augmented Generation 即“检索增强生成”。

17. AI Agent 可以理解为 LLM + 规划 + 记忆 + _____。

答案：工具调用

解析：工具调用让 Agent 能执行外部动作并形成任务闭环。

18. MCP 的全称是 Model Context _____。

答案：Protocol

解析：MCP 即 Model Context Protocol，用于规范模型与外部工具/上下文交互。

19. LoRA 通过低秩矩阵 (BA) 对原始矩阵 (W) 更新其主要优势在于显著降低 _____ 成本。

答案：训练 / 存储 / 计算（任选其一）

20. 涌现能力现象指模型规模增大后某些任务表现从接近 _____ 水平跃升。

答案：随机

解析：常见现象是从接近随机猜测到明显优于随机。

21. 思维链提示的核心是引导模型生成中间 _____ 步骤。

答案：推理

解析：输出中间推理过程常提升复杂任务成功率与可控性。

22. “对齐”的目标可以概括为：让模型输出与人类 _____ 相一致。

答案：价值观

解析：对齐强调价值、偏好、安全规范一致性，而不是只追求更高准确率。

23. 幻觉指模型生成的回答包含貌似事实但 _____ 的信息。

答案：虚假 / 误导

解析：幻觉通常“语言像真话”，但事实不成立或证据不足，可能误导使用者。

24. 上下文学习的特点是：无需调整模型 _____ 也能适配新任务。

答案：权重

解析：in-context learning 不做梯度更新，靠输入示例完成临时适配。

25. 推理任务四大类型包括逻辑推理、数学推理、常识推理和 _____ 推理。

答案：因果

解析：因果推理强调因果链、干预与反事实推断。

26. 大模型也常被称为 _____ 模型。

答案：基础模型

解析：“基础模型”强调其可作为多任务、多应用的通用底座。

27. Word2Vec 的目标是将词映射成具有语义信息的 _____ 表示。

答案：向量

解析：词向量空间能表达语义相似性和类比关系。

28. Skip-gram 的输入是中心词，目标是预测其 _____。

答案：上下文

解析：Skip-gram 用中心词学习其周围词的分布信息。

29. CBOW 的输入是上下文词，目标是预测 _____。

答案：中心词

解析：CBOW 通过上下文聚合信息预测目标词。

30. 经典 Transformer 由 _____ 与解码器两部分组成。

答案：编码器

解析：Transformer 的基本结构是 Encoder + Decoder。

31. BERT 属于 _____-only 架构。

答案：Encoder

解析：BERT 仅使用 Encoder 堆叠进行表示学习。

32. GPT/Llama 类模型通常属于 _____-only 架构。

答案：Decoder

解析：Decoder-only 更适合自回归生成。

33. 自回归预训练的经典目标任务是 Next Token _____。

答案：Prediction

解析：通过预测下一个 token 的概率分布学习语言建模能力。

34. 监督式微调常用缩写是 _____。

答案：SFT

解析：SFT 表示在标注数据上对基础模型进行监督训练以适配任务。

35. CLIP 的训练思想属于 _____ 学习。

答案：对比

解析：CLIP 用对比目标约束跨模态表示空间对齐。

36. “思维链提示”强调输出 _____ 推理步骤。

答案：中间

解析：通过中间步骤把复杂任务拆解为可推导过程，提高稳定性。

37. Scaling law 常描述测试损失与规模之间存在 _____ 律关系。

答案：幂

解析：幂律意味着扩大规模带来可预测但非线性幅度的性能改善。

38. 对齐训练希望输出更符合人类 _____ 观与安全约束。

答案：价值

解析：对齐强调使输出更贴近人类偏好、规范与安全边界。

39. AI Agent 的关键能力之一是能调用外部 _____ 完成任务闭环。

答案：工具

解析：工具调用让模型从“会说”变为“能做”，可执行搜索、计算、写代码等操作。

40. 若输入序列长度为 6，则 Next Token Prediction 的监督目标序列长度为 _____。

答案：6

解析：Next Token Prediction 通常采用“右移一位”的监督方式，长度不变：
[|target|=|input|=6]

41. 若模型每次生成 1 个 token，生成 20 个 token 需要 20 次“下一 token 预测”，则预测次数为 _____。

答案：20

解析：逐 token 生成：[20 token 20 次预测]

42. 知识蒸馏：总损失 ($L = L_{\text{soft}} + (1 - \alpha)L_{\text{hard}}$)。若 ($\alpha = 0.7$, $L_{\text{soft}} = 10$, $L_{\text{hard}} = 4$)，则 ($L =$) _____。

答案：8.2

解析：[$L = 0.7 \times 10 + 0.3 \times 4 = 7 + 1.2 = 8.2$]

43. Scaling law：若损失近似满足 ($L = kN^{-0.5}$)。当参数规模 (N) 变为原来的 4 倍时，损失变为原来的 _____ 倍。

答案：(1/2)

解析： $\frac{L'}{L} = \frac{k(4N)^{-0.5}}{kN^{-0.5}} = 4^{-0.5} = \frac{1}{2}$

44. 因果掩码：序列长度为 5 时，注意力矩阵中“被屏蔽的严格上三角元素”个数为 _____。

答案：10

解析：严格上三角元素数： $\frac{5 \times 4}{2} = 10$

45. 交叉熵损失定义为

答案：1

解析： $\mathcal{L} = -\log_2(0.5) = 1$

46. 因果掩码下，第 4 个 token 最多能看到前面多少个 token (含自己)?

答案：4

解析：第 4 个位置只能关注 {1, 2, 3, 4}，因此为 4。

47. LoRA 更新形式为

答案： 11

解析： $h = 8 + 3 = 11$

48. Scaling law 的简化形式为

答案： 8

解析： $E_{\text{new}} = 0.8 \times 10 = 8$

49. RAG 检索到 4 条信息，每条 15 token，总 token 数是多少？

答案： 60

解析： $4 \times 15 = 60$

50. 若词表大小为 8，均匀分布下每个 token 概率为多少？

答案： $\frac{1}{8}$

解析： $p = \frac{1}{8} = 0.125$

51. 交叉熵损失（以 $\log_{10}$ 计算）

答案： 1

解析： $\mathcal{L} = -\log_{10}(0.1) = 1$

52. 序列长度 $n = 8$ ，自回归训练的预测次数为 $n - 1$ 。求预测次数。

答案： 7

解析： $n - 1 = 8 - 1 = 7$

53. 蒸馏损失写作

答案： 8

解析： $L = 0.6 \times 10 + 0.4 \times 5 = 6 + 2 = 8$

54. 因果注意力下序列长度为 5，可见关系数为

答案： 15

解析： $1 + 2 + 3 + 4 + 5 = 15$

55. 若一个序列包含 6 个 token，第 6 个 token 能看到多少个 token (含自己)?

答案： 6

解析： 因果掩码下第 6 个位置可见 $\{1, 2, 3, 4, 5, 6\}$ ，因此为 6。