

强化学习题库

一、选择题

1. 强化学习 (RL) 与其他机器学习范式 (如监督学习) 最本质的区别在于

- A. RL 需要使用深度神经网络
- B. RL 处理的是静态数据集
- C. RL 通过奖励反馈进行学习
- D. RL 不需要任何数据输入

答案: C

解答: 强化学习的核心特征是智能体与环境交互, 通过“奖励”信号来优化策略, 而非依赖标注数据。

2. 在强化学习中, 描述“智能体处于什么情况”的要素是

- A. 动作 (Action)
- B. 奖励 (Reward)
- C. 状态 (State)
- D. 策略 (Policy)

答案: C

解答: 状态 (State) 是对环境当前情况的描述, 是智能体决策的依据。

3. 马尔可夫决策过程 (MDP) 通常由五元组 (S, A, P, R, γ) 定义, 其中 γ 代表

- A. 学习率 (Learning Rate)
- B. 折扣因子 (Discount Factor)
- C. 探索概率 (Exploration Rate)
- D. 状态转移概率 (Transition Probability)

答案: B

解答: γ 是折扣因子, 用于衡量未来奖励相对于当前奖励的重要性。

4. 贝尔曼方程 (Bellman Equation) 主要用于描述

- A. 状态价值与动作价值之间的转换关系
- B. 当前与后继状态价值之间的递归关系
- C. 策略梯度与价值函数之间的关系
- D. 神经网络参数的更新规则

答案： B

解答： 贝尔曼方程揭示了动态规划中的递归结构，即当前状态的价值等于即时奖励加上衰减后的下一状态的价值。

5. 在 Q-Learning 算法中，Q 值 $Q(s, a)$ 代表的含义是

- A. 在状态 s 采取动作 a 后获得的即时奖励
- B. 在状态 s 采取动作 a 的概率
- C. 在状态 s 采取动作 a ，随后遵循当前策略能获得的期望回报
- D. 在状态 s 转移到下一个状态的概率

答案： C

解答： 动作价值函数 $Q(s, a)$ 定义为从状态 s 执行动作 a 开始，通过某种策略所能获得的期望累积回报。

6. ϵ -greedy 策略中的参数 ϵ 主要用于控制

- A. 学习的步长大小
- B. 对未来奖励的重视程度
- C. 探索 (Exploration) 的概率
- D. 神经网络的层数

答案： C

解答： ϵ 决定了智能体有多大的概率随机选择动作（探索）， $1 - \epsilon$ 的概率选择最优动作（利用）。

7. 下列哪项不是深度强化学习 (Deep RL) 面临的常见挑战？

- A. 样本效率低，需要大量数据
- B. 训练不稳定，容易发散

- C. 奖励函数设计困难 (Sparse Reward)
- D. 无法处理高维输入 (如图像)

答案: D

解答: 处理高维输入 (如图像) 正是 Deep RL (结合 CNN) 的优势所在, 不是挑战。A、B、C 均是当前 DRL 的痛点。

8. 如果一个强化学习任务的状态转移具有随机性, 那么

- A. 智能体无法学习到最优策略
- B. 即使动作相同, 下一状态也可能不同
- C. 需要使用监督学习来辅助
- D. 必须使用确定性策略

答案: B

解答: 状态转移概率 $P(S'|S, A)$ 描述了这种随机性, 即执行动作后环境的反馈是不确定的, 这是 MDP 的基本特性。

9. 蒙特卡洛 (MC) 方法更新价值函数通常依据的是

- A. 单步的即时奖励
- B. 对下一状态价值的估计 (Bootstrapping)
- C. 整个回合结束后的实际累积回报
- D. 随机生成的噪声数据

答案: C

解答: MC 方法基于完整采样的回报 G_t 来更新价值, 没有偏差但方差较大。

10. 下列关于 On-policy 和 Off-policy 的说法, 正确的是

- A. On-policy 允许使用其他人产生的经验数据进行学习
- B. Off-policy 必须使用当前策略产生的经验数据
- C. Q-Learning 是典型的 Off-policy 算法
- D. Sarsa 是典型的 Off-policy 算法

答案: C

解答：Off-policy（如 Q-Learning）可以利用行为策略（如随机策略）产生的数据来优化目标策略（贪婪策略）；On-policy（如 Sarsa）只能利用当前策略产生的数据。

11. 在强化学习中，“回合 (Episode)” 指的是

- A. 智能体从初始状态到终止状态的一次完整交互序列
- B. 神经网络的一次前向传播
- C. 训练过程中的一个 Batch
- D. 智能体采取的一个动作

答案：A

解答：Episode 定义为从开始到结束的一局游戏或一次完整任务流程。

12. 强化学习的最终目标是找到一个

- A. 最优价值函数
- B. 最优状态
- C. 最优策略
- D. 最大的单步奖励

答案：C

解答：无论通过价值函数还是策略梯度，RL 的落脚点都是找到一个能产生最大长期回报的最优策略 π^* 。

13. 在马尔可夫决策过程 (MDP) 中，折扣因子的作用是

- A. 消除状态转移的随机性
- B. 平衡即时奖励与未来长期奖励的权重
- C. 决定智能体探索环境的概率
- D. 计算神经网络的梯度下降步长

答案：B

解答： γ 越接近 1，智能体越重视未来奖励； $\gamma = 0$ 则只看重即时奖励。

14. 下列关于 **Episodic Task** (情节型任务) 与 **Continuing Task** (连续型任务) 的区别, 描述正确的是

- A. 连续型任务有明确的“游戏结束”画面
- B. 情节型任务没有终止状态, 可以无限进行
- C. 股票交易通常被建模为情节型任务
- D. 围棋对弈是典型的情节型任务, 有输赢终止状态

答案: D

解答: 情节型任务 (如围棋、马里奥过关) 有明确终点; 连续型任务 (如股票、服务器温控) 往往持续运行。

15. 关于蒙特卡洛 (MC) 方法, 以下说法错误的是

- A. 它需要已知环境的状态转移模型 P
- B. 它通过多次采样完整的 episode 来估计价值
- C. 它的估计通常是无偏的 (Unbiased)
- D. 它的方差 (Variance) 通常比较大

答案: A

解答: MC 方法是 Model-free 的, 不需要已知环境模型, 只需通过与环境交互采样即可。

16. 在 Q-learning 中, 目标值 (Target) 的计算部分是

- A. $R + \gamma Q(s', a')$
- B. $R + \gamma \max_{a'} Q(s', a')$
- C. $R + \gamma V(s)$
- D. G_t

答案: B

解答: Q-learning 使用下一状态可能的最大 Q 值来构造目标, 体现了 Off-policy 和最优性的追求。

17. 在强化学习中, “Return” (回报) G_t 通常指

- A. 单步奖励

- B. 累积奖励折扣和
- C. 累积奖励总和
- D. 累积奖励均值

答案： B

解答： Return 是从某时刻开始未来所有奖励的折扣和。

18. 关于 RLHF (Reinforcement Learning from Human Feedback), 下列说法正确的是

- A. 它完全不需要人工参与
- B. 它直接使用环境自带的奖励函数（如得分）
- C. 它通过训练一个奖励模型来模拟人类的偏好
- D. 它只能用于玩 Atari 游戏

答案： C

解答： RLHF（如 ChatGPT 使用）的关键是用人类标注数据训练奖励模型，再用该模型指导强化学习。

19. 完全可观测与部分可观测的本质区别是

- A. 是否有奖励
- B. 观察是否等同于真实状态
- C. 动作是否连续
- D. 是否有终止状态

答案： B

解析：可观测性讨论的是观测 o_t 是否包含足够信息以等同/恢复真实状态 s_t 。

20. 自动驾驶更接近哪类动作空间？

- A. 离散动作空间
- B. 连续动作空间
- C. 无动作空间
- D. 动作空间恒为 1

答案： B

解析： 方向盘转角、油门/刹车强度通常为连续可调量，典型为连续控制问题。

21. 连续型任务更像

- A. 关卡制平台游戏
- B. 一盘国际象棋
- C. 自动化股票交易
- D. 一次性问答

答案： C

解析： Continuing 任务通常无自然终止，需要长期持续决策（常用折扣回报或平均回报建模）。

22. 探索-利用权衡中，“探索不足”的潜在问题是

- A. 计算复杂度太低
- B. 可能遗漏关键高回报区域，难达最优
- C. 一定会发散
- D. 一定过拟合

答案： B

解析： 探索不足会导致策略停留在次优区域，无法发现更高回报动作/状态。

23. 马尔可夫性更准确的表述是

- A. s_{t+1} 与 s_t 独立
- B. 未来只依赖过去全部历史
- C. 给定当前状态，未来与更早历史无关
- D. 未来只依赖奖励

答案： C

解析： 马尔可夫假设：给定 s_t （以及 a_t ），转移到 s_{t+1} 的分布与更早历史无关。

24. “策略”更像是

- A. 环境的转移概率矩阵
- B. 在状态下选动作的规则/分布
- C. 奖励函数本身
- D. 观测函数

答案： B

解析：策略 $\pi(a | s)$ 定义在状态 s 下选择动作（或动作分布）的规则。

25. 价值函数的用途更接近

- A. 直接输出图像像素
- B. 判断某状态（或状态-动作）长期回报好坏
- C. 估计样本均值
- D. 计算梯度范数

答案： B

解析：价值函数 $V(s)$ 或 $Q(s, a)$ 衡量从该状态/动作出发的期望长期回报。

26. Bellman 方程的思想最贴近

- A. 把长期价值分解成“一步奖励 + 折扣后的未来价值”
- B. 只看即时奖励
- C. 只看终止奖励
- D. 只看状态频率

答案： A

解析：Bellman 递推将长期价值写成“一步期望奖励 + 折扣后的后继价值期望”。

27. 动态规划（DP）方法的主要限制之一是

- A. 不能精确计算
- B. 必须采样
- C. 往往需要已知转移模型 P

- D. 不能处理离散动作

答案： C

解析： DP（价值迭代/策略迭代）通常基于已知的 $P(s' | s, a)$ 与奖励模型做期望计算。

28. 蒙特卡洛（MC）方法的典型特点是

- A. 不采样
- B. 需要完整模型
- C. 直接采样估计回报，方差可能较大
- D. 一定是 Off-policy

答案： C

解析： MC 通过采样回报的经验平均来估计期望，通常无偏但方差较大，且常需等回合结束。

29. TD 学习相对 MC 的一个关键差异是

- A. TD 不使用任何采样
- B. TD 用“一步采样 + 自举估计未来”
- C. TD 必须知道模型
- D. TD 只能用于情节型任务

答案： B

解析： TD 的核心是 bootstrapping：用下一状态的估计价值替代完整回报，减少等待但引入偏差。

30. 下列哪项最符合 “On-policy” 的含义？

- A. 更新目标用的是与采样相同的策略
- B. 更新目标永远用 max
- C. 不需要探索
- D. 只适用于连续动作

答案： A

解析：On-policy 指评估/改进的目标策略与产生数据的行为策略一致（或等价）。

31. Q-learning 通常更“高风险但更优”的原因更可能是

- A. 它从不探索
- B. 它更新时偏向于假设未来采取最优动作（max），更激进
- C. 它把奖励设为 0
- D. 它只做随机策略

答案：B

解析：max 目标使其学习“贪心最优”价值；在存在风险/探索惩罚时可能更激进，表现为更高风险。

32. 深度 Q 学习（DQN）相对 Q-learning 的关键变化是

- A. 去掉了价值函数
- B. 用深度网络替代表格拟合 $Q(s, a)$
- C. 不需要奖励
- D. 把动作空间变连续

答案：B

解析：DQN 用神经网络做函数逼近以处理高维状态空间（如图像），而非表格存储 Q 。

33. “端到端强化学习”的更贴近含义是

- A. 人工设计特征后再做 RL
- B. 从原始观察直接输出动作/价值，通过学习完成表征与决策
- C. 只训练最后一层
- D. 只在小型表格环境有效

答案：B

解析：端到端强调从原始输入（如像素/传感器）到策略/价值的整体学习，无需手工特征工程。

34. 下列哪项最可能是强化学习落地场景？

- A. K-means 聚类
- B. 交通灯调度与控制
- C. 线性回归拟合
- D. PCA 降维

答案： B

解析：交通信号控制是典型的序列决策与控制问题，目标可设为通行效率、拥堵/等待时间等长期指标。

35. 在一个“扫地机器人”自动清扫房间的任务中，下列哪一项最适合被定义为“环境 (Environment)”？

- A. 扫地机器人的控制芯片
- B. 房间的布局、脏污程度以及家具的位置
- C. 机器人吸尘电机的吸力大小
- D. 机器人内部的电池电量管理系统

答案： B

解析：环境是智能体外部的所有事物的集合，智能体与其交互并受其状态变化的影响。房间布局、脏污情况等是机器人（智能体）感知的对象和交互的场所。A、C、D 均属于智能体自身的组成部分。

36. 下列关于“状态 (State)”和“观察 (Observation)”的描述，体现了“部分可观测 (Partially Observed)”情境的是：

- A. 在围棋比赛中，棋盘上所有棋子的位置对双方选手都是可见的
- B. 在自动驾驶中，车辆摄像头只能拍摄到前方视野内的物体，无法看到被遮挡的区域
- C. 在井字棋游戏中，玩家可以清楚地看到九个格子中哪几个已经被填满
- D. 在模拟钟摆实验中，系统能够实时读取钟摆的角度和角速度等所有物理量

答案： B

解析：部分可观测意味着智能体无法获取环境的完整信息，观察（Observation）只是状态（State）的一个子集。自动驾驶中视野受限符合这一特征。A、C、D 均为完全可观测环境。

37. 动态规划（DP）方法通常难以直接应用于实际复杂的强化学习问题，主要原因是：

- A. 动态规划算法计算速度太快，容易过拟合
- B. 动态规划需要环境的完整模型（如状态转移概率），这在实际中很难获知
- C. 动态规划只能处理连续动作空间，无法处理离散动作
- D. 动态规划无法保证找到最优解

答案： B

解析：动态规划是基于模型（Model-based）的方法，它利用 Bellman 方程进行全宽更新，前提是必须知道环境的状态转移概率 P 和奖励函数。在现实复杂场景中，这些通常是未知的。

38. 蒙特卡洛（MC）方法与时序差分（TD）方法的主要区别在于：

- A. MC 方法需要等到一个情节（Episode）结束后才能更新价值，而 TD 可以单步更新
- B. MC 方法是基于模型的，而 TD 方法是无模型的
- C. MC 方法估计的是偏差，TD 方法估计的是方差
- D. MC 方法只适用于连续型任务，TD 方法只适用于情节型任务

答案： A

解析：MC 方法利用完整轨迹的实际回报 G_t 来更新，因此必须等待情节结束。TD 方法利用 bootstrapping（自举）思想，用下一步的估计值来更新当前值，可以实现单步（在线）更新。

39. 在经典的“悬崖行走（Cliff Walking）”问题中，Sarsa 算法往往会学到一条远离悬崖的“安全路径”，而 Q-learning 会学到贴近悬崖的“最优路径”。造成这种差异的根本原因是：

- A. Sarsa 算法的计算量比 Q-learning 大，因此更保守

- B. Q-learning 忽略了悬崖的存在，只关注终点奖励
- C. Sarsa 在更新时考虑了下一步实际执行的动作（可能因探索掉入悬崖），因此会惩罚高风险状态
- D. Q-learning 的折扣因子通常设置得比 Sarsa 大

答案： C

解析： Sarsa 更新公式使用 $Q(s', a')$ ，其中 a' 是实际执行的下一步动作。如果正在使用 ϵ -greedy 探索，在悬崖边 a' 有概率跳入悬崖，导致巨大的负奖励反向传播，从而降低悬崖边状态的价值。Q-learning 更新用 $\max Q$ ，假设下一步绝对理智（不会乱跳），因此认为悬崖边也是高价值的。

40. 时序差分 (TD) 误差 $\delta = R + \gamma V(s') - V(s)$ 中的 $R + \gamma V(s')$ 部分通常被称为：

- A. 蒙特卡洛回报 (Monte Carlo Return)
- B. TD 目标 (TD Target)
- C. 策略梯度 (Policy Gradient)
- D. 优势函数 (Advantage Function)

答案： B

解析： 在 TD 算法中，我们用 $R + \gamma V(s')$ 作为一个更准确的估计值来更新当前的估计值 $V(s)$ 。这个更准确的估计值被称为 TD Target (TD 目标)。

41. 假设一个智能体在进行股票交易，这个任务通常被归类为：

- A. 情节型任务 (Episodic task)
- B. 连续型任务 (Continuing task)
- C. 分类任务
- D. 静态优化任务

答案： B

解析： 股票交易通常没有自然的、预定义的终止状态（如游戏通关），需要智能体持续进行决策交互，因此属于连续型任务。

42. 强化学习中的“探索 (Exploration)”与“利用 (Exploitation)”的平衡非常关键。下列哪个场景体现了“过度利用”？

- A. 智能体尝试所有可能的路径以寻找出口
- B. 智能体随机选择动作以跳出局部最优解
- C. 智能体每天都去同一家味道中等但已知的餐厅，从不尝试新餐厅
- D. 智能体根据预测结果去探索未知的迷宫区域

答案： C

解析：利用是指基于现有经验做出稳妥选择。如果只利用而不探索，可能会错过潜在的更高奖励（如更好吃的餐厅）。

43. 基于价值的方法 (Value-based) 训练智能体的主要逻辑是：

- A. 直接学习一个从状态到动作的最优概率映射
- B. 通过评价不同状态或动作的价值，间接指导智能体选择高价值动作
- C. 模仿专家的操作录像
- D. 仅在任务完全结束时给出一个总评价，中间不做评估

答案： B

解析：价值方法通过学习 $V(s)$ 或 $Q(s, a)$ 来评估“好坏”，进而引导智能体向高价值状态移动。

44. 动态规划 (DP) 解决强化学习问题时，最大的局限性在于：

- A. 无法收敛到最优解
- B. 计算结果不如随机采样精确
- C. 需要预先知道环境的完整转移概率模型 $P(s'|s, a)$
- D. 只能处理连续动作空间

答案： C

解析：DP 是 Model-based（基于模型）的方法，要求已知环境的数学模型，而实际复杂环境往往是已知的“黑盒”。

45. 蒙特卡洛 (MC) 方法评估价值函数的基本思想是：

- A. 通过多次完整的实验采样，计算回报的平均值来近似期望
- B. 利用 Bellman 方程在每一步进行自举更新
- C. 无需与环境交互，直接进行离线计算
- D. 仅通过第一步获得的即时奖励来评估状态

答案： A

解析： MC 强调“实践出真知”，通过大量的完整序列采样来统计平均收益。

46. 时序差分 (TD) 学习结合了 DP 和 MC 的优点，具体表现为：

- A. 它不需要环境模型，且可以每步更新（无需等待任务结束）
- B. 它必须等到情节结束后才能更新参数
- C. 它完全放弃了 Bellman 方程的递归思想
- D. 它只能处理完全可观测的环境

答案： A

解析： TD 无需模型（类似 MC），且利用自举（Bootstrapping）实现了单步或多步在线更新（类似 DP）。

47. 在 ϵ -greedy 策略中，设定 $\epsilon = 0.1$ 意味着：

- A. 有 10% 的概率选择当前最优动作，90% 随机探索
- B. 有 90% 的概率利用现有最优决策，10% 随机尝试新动作
- C. 智能体会连续执行 10 次动作后停止学习
- D. 只有在获得正奖励时才会进行探索

答案： B

解析： ϵ -greedy 的逻辑是以小概率 ϵ 进行探索，以大概率 $1 - \epsilon$ 进行利用。

48. 深度强化学习 (Deep RL) 相较于传统表格型 RL，其核心优势是：

- A. 不再需要奖励信号

- B. 使用神经网络作为函数拟合器，解决了高维状态空间的“维度灾难”
- C. 训练过程比表格法更加稳定
- D. 降低了对计算资源（如 GPU）的需求

答案： B

解析：对于像素级输入或无限状态空间，表格法无法存储，神经网络能通过拟合函数有效处理这些复杂特征。

49. 深度 Q 网络（DQN）在训练中将价值函数转化为了：

- A. 一个静态的 Excel 查找表
- B. 一系列手写的 if-else 规则
- C. 深度神经网络及其可学习的权重参数
- D. 仅包含即时奖励的线性组合

答案： C

解析：DQN 使用神经网络来近似 $Q(s, a; \theta)$ ，其中 θ 是网络的参数。

50. 在深度强化学习中，关于 CPU 和 GPU 的分工描述最合理的是：

- A. CPU 用于存储所有神经网络权重，GPU 负责与环境交互
- B. CPU 负责环境模拟与经验数据收集，GPU 负责神经网络的参数训练与反向传播
- C. 所有计算均由 GPU 完成，CPU 仅负责开机启动
- D. CPU 负责反向传播计算，GPU 负责处理 if-else 逻辑

答案： B

解析：环境交互（通常是串行逻辑）多在 CPU 上完成，而神经网络的大规模矩阵运算在 GPU 上更具效率。

51. 深度强化学习算法在实际应用中往往面临“过拟合”风险，这通常表现为：

- A. 智能体学得太慢，无法获得任何奖励

- B. 智能体对训练过的特定环境关卡表现极好，但在略微改变的新场景下表现极差
- C. 智能体的神经网络权重自动变为了零
- D. 智能体因为数据量太大而无法运行

答案： B

解析：过拟合意味着模型记住了训练数据的特定细节而非通用规律，导致泛化能力弱。

52. 在强化学习的实际落地中，网约车派单系统适合建模为强化学习的原因是：

- A. 派单是一个不需要考虑未来影响的简单分类任务
- B. 当前的派单决策会影响未来司机的地理分布，是一个多步决策问题
- C. 派单系统只需要统计历史订单，不需要实时反馈
- D. 只要有足够的标注数据，监督学习就能完美解决所有动态调度

答案： B

解析：派单会改变系统的状态（司机的空间分布），且需要最大化长期的总收益（而非单笔订单），符合 MDP 建模。

53. 关于强化学习在大型语言模型（如 ChatGPT）中的应用，下列说法正确的是：

- A. 强化学习取代了词向量技术，使模型能看懂文字
- B. 通过基于人类反馈的强化学习（RLHF），使模型输出更符合人类的偏好与价值观
- C. 强化学习仅用于缩短模型的响应时间
- D. 强化学习让模型不再需要任何预训练数据

答案： B

解析：RLHF 是目前大模型对齐（Alignment）的核心技术，通过奖励模型指导策略模型（大模型）输出更高质量的结果。

54. 在强化学习中，“奖励延迟 (delayed reward)”带来的主要困难更接近于

- A. 无法定义状态空间
- B. 很难把最终回报归因到早期动作
- C. 动作空间必须是连续的
- D. 必须已知转移概率矩阵

答案： B

解答：奖励可能在多步之后才出现，导致“哪些早期动作贡献了最终回报”不易判断，这属于信用分配问题。

55. 若 γ 取值更小（更接近 0），对策略偏好带来的影响更可能是

- A. 更强调长期收益
- B. 更强调短期收益
- C. 与收益权重无关
- D. 只能用于连续型任务

答案： B

解答： γ 越小，未来奖励折扣越强，目标更偏向即时或短期回报。

56. 在 ϵ -greedy 策略中，若 $\epsilon = 0$ ，则策略行为更接近

- A. 完全随机
- B. 完全贪婪
- C. 只在负奖励时探索
- D. 每一步都均匀采样所有动作

答案： B

解答： $\epsilon = 0$ 表示不进行随机探索，总是选择当前估计最优的动作。

57. 关于“终止状态 (terminal state)”的处理，更常见且合理的设定是

- A. 终止状态的价值固定为 0
- B. 终止状态的价值固定为 1
- C. 终止状态必须继续产生奖励

- D. 终止状态必须继续进行状态转移

答案： A

解答：终止后不再产生未来奖励，常设 $V(\text{terminal}) = 0$ 以保持定义一致。

58. 若一个环境是“确定性转移”，则更符合的描述是

- A. 同一 (s, a) 可能到多个 s'
- B. 同一 (s, a) 必到唯一 s'
- C. 奖励一定为正
- D. 策略必须是随机的

答案： B

解答：确定性环境中，给定状态和动作，下一状态（与奖励）不再随机变化。

59. 在价值函数框架下， $V^\pi(s)$ 与 $Q^\pi(s, a)$ 的关系更接近

- A. $Q^\pi(s, a)$ 是对 $V^\pi(s)$ 的动作平均
- B. $V^\pi(s)$ 是对 $Q^\pi(s, a)$ 的按策略加权平均
- C. $V^\pi(s)$ 恒等于 $\max_a Q^\pi(s, a)$
- D. $Q^\pi(s, a)$ 与 $V^\pi(s)$ 无关

答案： B

解答：对同一策略 π ，有 $V^\pi(s) = \sum_a \pi(a|s) Q^\pi(s, a)$ 。

60. 下列哪种做法最能体现“经验数据复用 (data reuse)”的思想？

- A. 每次更新只使用最新一步数据并丢弃历史
- B. 把历史交互样本存起来并多次随机抽取训练
- C. 只用人工标注数据训练策略
- D. 只在 episode 结束时更新一次

答案： B

解答：将经验存入回放池并反复采样，可提高样本利用率并减少相邻

样本相关性。

61. TD 学习相比 MC 的一个典型差异是

- A. TD 必须等到 episode 结束
- B. TD 可能引入偏差但通常方差更小
- C. MC 必须已知模型 P
- D. MC 必须使用 max 运算

答案： B

解答： TD 用 $r + \gamma V(s')$ 近似未来回报，减少等待、降低方差，但自举会带来偏差风险。

62. 下列哪个现象更可能由“探索过强”导致？

- A. 长期停留在次优策略附近
- B. 行为非常随机，短期回报较低
- C. 不再需要奖励函数
- D. 状态空间自动变小

答案： B

解答： 探索过强意味着大量随机动作，可能牺牲短期收益并导致训练过程波动更大。

63. “部分可观测”环境中，若只把单步观察当作状态，常见后果更可能是

- A. 马尔可夫性可能不成立，决策信息不足
- B. 奖励函数无法定义
- C. 动作空间不再存在
- D. 价值函数必然收敛得更快

答案： A

解答： 单步观察可能无法完整反映真实状态，从而破坏马尔可夫性质，导致策略难以最优。

64. 设回报定义为 $G_t = R_{t+1} + \gamma R_{t+2}$ 。若 $\gamma = 0.5$, $R_{t+1} = 2$, $R_{t+2} = 4$, 则 G_t 为

- A. 4
- B. 5
- C. 6
- D. 8

答案： A

解答： $G_t = 2 + 0.5 \times 4 = 4$ 。

65. 在 TD(0) 中，TD 目标 (target) 更接近

- A. R_{t+1}
- B. $R_{t+1} + \gamma V(S_{t+1})$
- C. $\max_a Q(S_t, a)$
- D. $\sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$

答案： B

解答： TD(0) 用一步奖励加折扣后的下一状态价值作为更新目标。

66. 若学习率 $\alpha = 1$ ，更新 $Q \leftarrow Q + \alpha(\text{Target} - Q)$ 的效果更接近

- A. 完全不更新
- B. 更新到目标值的一半
- C. 直接覆盖为目标值
- D. 只更新符号不更新大小

答案： C

解答： $\alpha = 1$ 时， $Q_{\text{new}} = \text{Target}$ ，即用目标值完全替换旧估计。

67. 在 Q-learning 的目标 $R + \gamma \max_{a'} Q(s', a')$ 中，“max” 操作更直接表达了

- A. 评估当前行为策略本身
- B. 假设未来采用最优动作选择
- C. 强制动作概率均匀分布
- D. 只适用于确定性环境

答案： B

解答：取最大值等价于用“最优后续动作”构造目标，从而学习最优价值函数。

68. 若动作空间是连续的，基于“枚举所有动作并取最大”的方法通常会遇到的直接困难是

- A. 无法定义奖励
- B. 无法定义状态
- C. 难以在连续集合上直接做 max 枚举
- D. 无法进行探索

答案： C

解答：连续动作无法像离散动作那样直接枚举求最大，通常需要额外的优化或策略参数化方法。

69. 在一个 continuing 任务中，若每一步奖励恒为 1 且 $\gamma = 0.9$ ，无穷折扣回报更接近

- A. 9
- B. 10
- C. 11
- D. 100

答案： B

解答： $G = \sum_{k=0}^{\infty} 0.9^k = 1/(1 - 0.9) = 10$ 。

70. 下列哪种说法更符合“值迭代 (value iteration)”的核心更新形式？

- A. $V(s) \leftarrow \sum_a \pi(a|s)Q(s, a)$
- B. $V(s) \leftarrow \max_a \mathbb{E}[r + \gamma V(s')]$
- C. $V(s) \leftarrow V(s) + \alpha(G_t - V(s))$
- D. $V(s) \leftarrow \nabla_{\theta} J(\theta)$

答案： B

解答：值迭代对动作取最大进行最优 Bellman 备份，用于逼近最优价值函数。

71. 若一个方法能够使用“来自任意行为策略收集的数据”来学习“目标策略”，它更可能属于

- A. On-policy
- B. Off-policy
- C. 无策略 (policy-free)
- D. 无奖励 (reward-free)

答案： B

解答： Off-policy 允许行为策略与目标策略不同，从而可利用更广泛来源的经验数据。

72. 在函数逼近（如用神经网络表示 Q ）时，最直接的潜在收益是

- A. 对未见过的状态也可给出估计（泛化）
- B. 状态空间大小自动减少为常数
- C. 必然不再需要探索
- D. 必然保证训练稳定且单调收敛

答案： A

解答： 参数共享使得相似状态可共享表示，从而对未见状态产生一定泛化能力。

73. 以下哪种现象最贴近“训练不稳定/发散”的风险来源？

- A. 目标随参数变化而变化，导致学习目标漂移
- B. 奖励一定为正
- C. 状态必须离散
- D. 动作空间恒为 1

答案： A

解答： 在自举与函数逼近结合时，目标与估计相互依赖，目标漂移会加剧不稳定风险。

二、判断题

1. 强化学习是一类决策型任务，智能体通过与环境交互并依据奖励信号学习。

答案：T

解析：RL 典型设定是“智能体—环境”闭环交互，通过奖励（及状态转移）学习策略以做序列决策。

2. 强化学习的训练只依赖离线标注数据，不需要与环境交互。

答案：F

解析：经典 RL 需要与环境交互采样经验；虽存在离线/批量 RL 主要依赖离线数据，但不能概括为“只依赖离线数据且不需要交互”。

3. 在完全可观测环境中，智能体获得的观察与环境真实状态一致。

答案：T

解析：完全可观测（Fully Observable）通常指观测 o_t 与真实状态 s_t 等价（或可一一映射），不存在信息缺失。

4. 在部分可观测环境中，智能体获得的观察信息是完整的。

答案：F

解析：部分可观测（POMDP）下观测 o_t 只包含状态信息的子集或带噪投影，信息不完整。

5. 强化学习中，动作空间可以是离散的也可以是连续的。

答案：T

解析：动作空间 $\mathcal{A}$ 既可为有限集合（离散），也可为区间/连续向量空间（连续）。

6. 离散动作空间意味着可选动作数量是无限的。

答案：F

解析：离散动作空间通常为有限个动作（如 $1, 2, \dots, K$ ）；“无限”更接近连续动作或可数无限的特殊设定，但并非离散动作空间的含义。

7. 情节型任务有起点与终点（终止状态），形成有限长度的交互序列。

答案：T

解析：Episodic 任务在终止状态结束一幕（episode），轨迹长度有限（或以终止为界）。

8. 连续型任务一定存在终止状态，只是很难到达。

答案：F

解析：Continuing 任务通常不设终止状态（可无限时域），通过折扣因子或平均回报定义目标。

9. 强化学习的目标通常是最大化期望的累计奖励，而不只是即时奖励。

答案：T

解析：目标一般为最大化期望回报 $\mathbb{E}[\sum_t \gamma^t r_t]$ （或平均回报），强调长期收益。

10. 策略（policy）描述了在给定状态下应采取的动作（或动作分布）。

答案：T

解析：策略 $\pi(a | s)$ 给出状态到动作（分布）的映射，可为确定性或随机性。

11. 马尔可夫性指未来状态分布只依赖当前状态（及当前动作），与过去历史无关。

答案：T

解析：马尔可夫性质： $P(s_{t+1} | s_t, a_t, \text{history}) = P(s_{t+1} | s_t, a_t)$ 。

12. MDP（马尔可夫决策过程）是强化学习问题的常见形式化模型。

答案：T

解析：MDP 用 $(\mathcal{S}, \mathcal{A}, P, r, \gamma)$ 形式化状态、动作、转移与奖励，是 RL 的标准建模框架。

13. Bellman 方程刻画了不同状态（或状态-动作）价值之间的递推关系。

答案：T

解析：Bellman 递推将价值表示为“一步奖励 + 折扣后的后继价值期望”，是值函数求解的核心。

14. 动态规划方法通常需要已知环境的转移概率 P 。

答案：T

解析：DP（如策略迭代、价值迭代）依赖已知的转移概率 $P(s' | s, a)$ 与奖励模型 R 。

15. 蒙特卡洛方法通过采样估计价值，优点是简单直接，缺点是方差可能较大。

答案：T

解析：MC 用完整回报样本的平均估计期望，通常无偏但方差较大，且需等待回合结束（episodic 更常见）。

16. Sarsa 属于 Off-policy 方法。

答案：F

解析：Sarsa 是 **On-policy**：用当前行为策略产生的 (s, a, r, s', a') 进行更新并评估/改进同一策略。

17. 在某些情形下，Sarsa 更偏“安全但慢”，Q-learning 可能更“高风险但更优”。

答案：T

解析：由于 Sarsa 评估的是包含探索的行为策略，可能更保守；Q-learning 学的是贪心目标策略，在存在危险状态/探索惩罚时可能更激进。

18. 强化学习与监督学习的主要区别之一在于，强化学习没有显式的“标签”作为指导，而是通过环境反馈的“奖励”来进行学习。

答案： T

解答：强化学习是通过智能体与环境交互获得的奖励信号来优化策略，而监督学习依赖于数据集中的正确标签（Ground Truth）。

19. 价值函数（Value Function）用于评估 RL 智能体在某个状态下采取行动后，能够获得的即时奖励的大小。

答案： F

解答：价值函数评估的是从当前状态开始，未来能获得的累积奖励的期望值，而非单次的即时奖励。

20. 折扣因子（Discount Factor） γ 的值通常大于 1，以强调 RL 中未来奖励的重要性。

答案： F

解答：折扣因子 γ 通常在 $[0, 1]$ 之间。 $\gamma < 1$ 保证了无限步任务中累积奖励的收敛，且表示未来的奖励不如当前的奖励值钱。

21. 蒙特卡洛（Monte Carlo）方法是一种 Model-free 的 RL 学习方法，它必须等待一个完整的回合（Episode）结束后才能更新价值估计。

答案： T

解答：蒙特卡洛方法利用完整的经验轨迹计算回报，因此必须等到回合结束获得所有奖励后才能进行更新。

22. Q-Learning 是一种 On-policy（同策略）算法，因为它优化的 RL 策略和实际执行的策略是同一个。

答案： F

解答：Q-Learning 是 Off-policy（异策略）算法，它在更新 Q 值时使用贪婪策略（Max Q），而实际行动可能遵循 ϵ -greedy 策略。

23. 奖励函数的设计对强化学习的效果影响很大，稀疏奖励 (Sparse Reward) 通常会导致学习变得更加容易。

答案： F

解答：稀疏奖励意味着智能体很难获得反馈，导致学习效率极低，是 RL 中的一大挑战，而非让学习变容易。

24. 强化学习智能体不仅是被动地接收数据，还可以通过动作主动地影响环境，进而改变未来的数据分布。

答案： T

解答：RL 的特点之一是数据分布由智能体的策略决定，策略变化会导致采样到的数据分布变化。

25. 深度 Q 网络 (DQN) 利用深度神经网络来近似 Q 值函数，从而解决了 RL 中状态空间过大导致无法使用表格法的问题。

答案： T

解答：DQN 使用神经网络作为函数近似器来拟合 Q 函数，能够处理高维状态输入（如图像）。

26. 在 RL 学习游戏策略时，DQN 通常直接使用游戏的原始像素图像作为输入状态。

答案： T

解答：DQN 的一大突破就是利用 CNN 直接处理高维的像素输入，实现了端到端的控制。

27. 如果折扣因子 $\gamma = 0$ ，RL 智能体将变得“短视”，只关心当前的即时奖励。

答案： T

解答：当 $\gamma = 0$ 时，未来奖励的权重为 0，目标函数退化为最大化 R_{t+1} 。

28. 最优 RL 策略 π_* 是指使得在所有状态下价值函数 $V^{\pi}(s)$ 均达到最大的策略。

答案： T

解答：强化学习的目标就是寻找这个最优策略，使得期望累积奖励最大化。

29. 股票交易可以被建模为强化学习中的情节型任务，因为每天收盘代表一个 Episode 结束。

答案： F

解答：股票交易通常被视为连续型任务（Continuing Task），因为市场持续运行，没有自然的终止状态（除非破产或强制停止，但本质是连续的）。

30. 在强化学习的人类反馈强化学习（RLHF）中，奖励模型（Reward Model）通常是由人类直接手动编写代码定义的。

答案： F

解答：在 RLHF（如 ChatGPT 的训练）中，奖励模型通常是通过监督学习，利用人类标注的偏好排序数据训练出来的神经网络，而不是人工写死的规则。

31. DeepSeek-R1 通过强化学习激励大模型产生“思考（Chain-of-Thought）”过程，从而提升了推理能力。

答案： T

解答：强化学习在后训练（Post-training）阶段被用于优化模型的推理链条，使其能够自我反思和纠错。

32. 探索（Exploration）是指 RL 智能体利用已知的最优策略来最大化当前的奖励。

答案： F

解答：这是利用（Exploitation）的定义。探索是指尝试未知的动作以获取更多关于环境的信息，以防遗漏潜在的更大奖励。

33. 在强化学习中，智能体在某一步获得的即时奖励 (Reward) 越大，说明它当前的策略一定越优。

答案：F

解析：强化学习的目标是最大化长期累积奖励（即回报），而非单步的即时奖励。某些策略可能导致短期高奖励但长期低回报（短视行为），因此即时奖励高并不直接代表策略最优。

34. 股票交易、自动控制等任务通常被建模为“连续型任务” (Continuing Task)，因为它们没有像围棋那样明确的自然结束状态。

答案：F

解析：与有明确胜负终点的“情节性任务” (Episodic Task) 不同，连续型任务在时间上无限延伸或持续很长时间，如服务器资源调度、股票交易等。

35. 动态规划 (Dynamic Programming) 方法通常用于解决“无模型” (Model-free) 的强化学习问题。

答案：F

解析：动态规划（如策略迭代、价值迭代）是基于模型 (Model-based) 的方法，它需要已知环境的状态转移概率 P 和奖励函数 R 才能进行计算。

36. 蒙特卡洛 (Monte Carlo) 方法必须等待一个完整的交互情节 (Episode) 结束后，才能计算回报并更新价值估计。

答案：T

解析：蒙特卡洛方法通过采样完整的轨迹来计算平均回报，因此必须等到回合结束获得最终结果后才能进行更新，无法像 TD 算法那样进行单步更新。

37. 时序差分 (TD) 学习结合了蒙特卡洛和动态规划的优点，它可以利用“自举” (Bootstrapping) 的方式，用下一时刻的估计值来更新当前时刻的估计值。

答案：T

解析：TD 学习不需要完整的轨迹（像 MC），也不需要环境模型（像 DP），它利用 $R + \gamma V(s')$ 作为目标来更新 $V(s)$ ，体现了自举的思想。

38. 深度强化学习 (Deep RL) 的核心是将深度神经网络作为函数近似器，用来拟合高维状态下的价值函数或策略函数。

答案：T

解析：传统强化学习在面对图像等高维输入时会出现“维度灾难”，Deep RL 引入神经网络（如 CNN）来近似 Q 函数或策略，解决了这一瓶颈。

39. 在强化学习中，“环境”可以是确定性的：同一状态下执行同一动作，总是转移到同一下一状态并得到同一奖励。

答案：T

解析：环境动力学既可以是随机的，也可以是确定性的；确定性环境是随机性环境的特殊情形。

40. 在部分可观测环境中，只要使用足够大的神经网络，就可以把单步观察当作“状态”而不影响问题建模。

答案：F

解析：部分可观测下单步观察通常不满足马尔可夫性；即使模型很大，若输入信息不足，也可能无法仅凭当前观察做出最优决策。

41. 奖励可以为负值，负奖励常用于表达“惩罚”或“不希望发生的事件”。

答案：T

解析：奖励是反馈信号，不要求非负；用负值表示惩罚是常见做法。

42. 折扣因子 γ 越接近 0，智能体越偏向关注短期收益。

答案：T

解析： γ 越小，未来奖励权重衰减越快，目标更偏向即时回报。

43. 探索行为一定会提高当前回合的总回报，因为它能找到更多信息。

答案：F

解析：探索可能短期“走弯路”导致回报下降，但目的是长期获得更好的策略。

44. 利用 (exploitation) 意味着智能体始终执行当前估计最好的动作，因此不会犯错。

答案：F

解析：“当前估计最好”可能是错的；利用减少了尝试新动作的机会，可能长期陷入次优策略。

45. 在有限状态空间且已知转移概率 P 的情况下，动态规划可以在不采样交互轨迹的前提下计算价值函数。

答案：T

解析：动态规划使用已知模型做期望递推，可直接计算（或迭代逼近）价值函数。

46. 蒙特卡洛方法属于 model-free 方法，因为它直接利用采样得到的回报进行估计，不需要显式的 P 。

答案：T

解析：MC 通过经验轨迹估计期望回报，不依赖环境转移模型。

47. 相比蒙特卡洛方法，时序差分 (TD) 方法通常可以在回合未结束时进行更新。

答案：T

解析：TD 使用一步目标（如 $R + \gamma V(s')$ ）进行自举更新，不必等待整段轨迹结束。

48. TD 学习使用“自举”会带来一个特点：更新目标依赖当前的价值估计，因此可能引入偏差。

答案：T

解析：自举用估计量更新估计量，可能降低方差，但也可能引入偏差，这是理解 TD 的关键点之一。

49. 若一个任务没有终止状态，则无法定义“累计奖励最大化”的目标。

答案：F

解析：连续型任务仍可通过折扣回报或平均回报等方式定义优化目标。

50. 动作价值函数 $Q(s, a)$ 与状态价值函数 $V(s)$ 的区别在于：前者区分具体动作，后者只评价状态本身。

答案：T

解析： Q 评估“在状态 s 选动作 a 后”的回报期望； V 评估“处于状态 s ”的回报期望。

51. 若已知 $Q^\pi(s, a)$ ，则可以通过对动作按策略分布求期望得到 $V^\pi(s)$ 。

答案：T

解析：在同一策略 π 下， $V^\pi(s) = \mathbb{E}_{a \sim \pi(\cdot|s)}[Q^\pi(s, a)]$ ，体现了二者的对应关系。

52. Bellman 方程本质上利用了“一步奖励 + 后继状态的价值”的递推结构。

答案：T

解析：它把长期回报拆为当前一步与未来部分的组合，这种递推是价值学习与规划的核心。

53. 最优策略可以通过“在每个状态选择使 $Q(s, a)$ 最大的动作”来构造，这要求 Q 表示的是最优动作价值。

答案：T

解析：若已得到 $Q^*(s, a)$ ，贪心选择 $\arg \max_a Q^*(s, a)$ 即得到最优策略。

54. On-policy 方法与 Off-policy 方法的关键差别之一在于：更新所依据的目标策略与实际采样的行为策略是否一致。

答案：T

解析：On-policy 用“当前行为策略”产生的数据评估并改进自身；Off-policy 允许用一种行为策略采样、用另一种目标策略更新。

55. Off-policy 方法一定比 On-policy 方法更稳定，因为它不受探索策略影响。

答案：F

解析：Off-policy 的“采样分布与更新目标不一致”可能带来额外不稳定因素；稳定性依赖具体算法与设定，不能一概而论。

56. 在表格型 (tabular) 表示下，状态或状态-动作空间一旦变得巨大，存储并更新整张表会变得不可行。

答案：T

解析：这正是高维/大规模问题的瓶颈之一，会促使使用函数近似（如神经网络）。

57. DQN 的核心思想之一是用神经网络近似 $Q(s, a)$ ，从而避免显式维护巨大 Q 表。

答案：T

解析：用参数化函数替代表格，可处理高维状态输入并进行泛化。

58. 使用神经网络做函数近似后，强化学习训练一定更容易收敛，因为模型表达能力更强。

答案：F

解析：表达能力更强不等于更易训练；高维参数空间可能带来训练不稳定、过拟合与数据需求更大等问题。

59. 在深度强化学习中，既需要计算资源来收集交互经验，也需要计算资源来训练神经网络参数。

答案：T

解析：经验采集与模型训练是两类开销，实际系统中常需要平衡二者的吞吐。

60. 若智能体在训练中不断更新策略，则它采集到的数据分布也会随之变化，这可能影响学习稳定性。

答案：T

解析：数据分布由策略诱导，策略变动会改变采样分布，从而影响估计与优化过程。

61. 在完全可观测的 MDP 中，只要满足马尔可夫性，智能体做决策不需要记住完整历史轨迹。

答案：T

解析：马尔可夫性保证“当前状态”已经包含决策所需信息，因此历史可被当前状态充分概括。

62. 在部分可观测环境中，引入“包含历史信息的内部记忆/状态表示”可能使问题更接近满足马尔可夫性。

答案：T

解析：通过把历史信息（或其压缩表示）纳入决策输入，能缓解单步观察信息不足的问题，这是应对部分可观测性的常见思路。

63. 若 γ 取值非常接近 1，则等价于把未来很远的奖励与当前奖励赋予几乎相同权重，这会扩大“有效决策视野”。

答案：T

解析： γ 越接近 1，有效时间跨度越长；这通常也会让估计更依赖长期信息。

64. 若 γ 越接近 1，就一定能学到更好的策略，因为智能体更重视长期收益。

答案：F

解析：更重视长期不必然更好：更长视野可能使估计方差更大、学习更难；策略质量取决于问题与算法稳定性。

65. 在同一个任务中，情节型与连续型的划分只由“是否存在终止状态”决定，而与算法选择无关。

答案：T

解析：任务类型的定义来自环境交互是否自然终止；算法当然会受任务类型影响，但类型本身不由算法决定。

66. 若一个任务被强行切分成固定长度的片段来训练，则它在形式上看起来像情节型任务，但这不一定等同于环境本身具有终止状态。

答案：T

解析：人为截断是训练策略，不改变环境是否天然终止；这一区分能帮助理解“回合结束”有时只是人为设定。

67. 对于同一策略 π ，若 Q^π 估计偏高，则由其构造的贪心动作选择可能被系统性误导。

答案：T

解析：贪心选择依赖相对大小；系统性偏差可能改变动作排序，从而影响决策质量，这是理解“估计误差如何影响策略”的关键。

68. 价值函数学习的目标是让“对未来回报的估计”更准确，而不是直接让即时奖励变大。

答案：T

解析：价值函数刻画长期回报期望；即时奖励只是回报的一部分，价值学习旨在对长期效果做评估与递推。

三、填空与计算题

1. 若折扣因子 $\gamma = 1$ ，奖励序列为 $r_0 = 2, r_1 = 1, r_2 = 3$ ，情节结束后不再获得奖励，累积回报定义为 $G = r_0 + \gamma r_1 + \gamma^2 r_2$ ，若折扣因子

- $\gamma = 0.5$, 则 $G =$ _____。
- 答案: 3.25
2. 在某一状态下, 仅考虑即时奖励, 累积回报定义为 $G = r_0 + \gamma r_1 + \dots$, 若 $\gamma = 0$, 且即时奖励 $r_0 = 5$, 则 $G =$ _____。
- 答案: 5
3. 某情节在两个时间步后结束, 对应奖励为 $r_0 = 1, r_1 = 2$ 。折扣因子 $\gamma = 0.5$, 则累积回报为 _____。
- 答案: 2
4. 若折扣因子 $\gamma = 1$, 奖励序列为 1, 1, 1, 情节结束后不再获得奖励, 则累积回报为 _____。
- 答案: 3
5. 某状态只被访问一次, 该次采样得到的累积回报为 9。基于样本平均的价值估计方法, 该状态的价值为 _____。
- 答案: 9
6. 在状态 s 下有两个动作, 其动作价值分别为 $Q(s, a_1) = 5$, $Q(s, a_2) = 2$ 策略满足 $\pi(a_1|s) = 0.6$, $\pi(a_2|s) = 0.4$ 状态价值定义为 $V(s) = \sum_a \pi(a|s)Q(s, a)$ 则 $V(s) =$ _____。
- 答案: 3.8
7. 在状态 s 下有三个可选动作, 其动作价值分别为 1, 3, 2 最优状态价值定义为 $V^*(s) = \max_a Q(s, a)$, 则 $V^*(s) =$ _____。
- 答案: 3
8. 在某状态下, 所有动作的动作价值均为 2。无论策略如何选择, 状态价值 $V(s) =$ _____。
- 答案: 2
9. 在某状态 s 下, 动作集合大小为 4, 策略在该状态下对各动作等概率选择。若动作价值之和为 12, 则 $V(s) =$ _____。
- 答案: 3
10. 在某状态下有两个动作, 其动作价值分别为 4 和 0, 策略以 0.5 的概率选择每个动作。则状态价值为 _____。
- 答案: 2
11. 在状态 s 下, 若策略总是选择动作价值最大的动作, 且 $Q(s, a_1) = 4$, $Q(s, a_2) = 1$ 则状态价值为 _____。

• 答案： 4

12. 在确定性环境中，状态 s 执行动作 a 后必然转移到状态 s' ，立即奖励为 2。若 $V(s') = 6$ ，折扣因子 $\gamma = 0.5$ ，动作价值定义为 $Q(s, a) = r + \gamma V(s')$ ，则 $Q(s, a) =$ _____。

• 答案： 5

13. 状态 s 执行动作 a 后，以 0.5 的概率转移到状态 s_1 ，奖励为 2，且 $V(s_1) = 4$ ；以 0.5 的概率转移到状态 s_2 ，奖励为 0，且 $V(s_2) = 2$ 。折扣因子 $\gamma = 1$ 。动作价值定义为 $Q(s, a) = \sum_{s'} p(s'|s, a)[r + \gamma V(s')]$ ，则 $Q(s, a) =$ _____。

• 答案： 4

14. 若状态价值满足 Bellman 方程 $V(s) = r + \gamma V(s')$ ，已知 $V(s) = 4, r = 1, V(s') = 4$ ，则折扣因子 $\gamma =$ _____。

• 答案： 0.75

15. 已知 $V(s) = 2$ ，下一状态价值 $V(s') = 4$ ，奖励 $r = 1$ ，折扣因子 $\gamma = 0.5$ 。根据 Bellman 更新，新的估计值为 _____。

• 答案： 4

16. 状态价值更新规则为 $V(s) \leftarrow V(s) + \alpha(r + \gamma V(s') - V(s))$ ，已知 $V(s) = 2, r = 1, V(s') = 4, \gamma = 0.5, \alpha = 0.5$ ，更新后的 $V(s) =$ _____。

• 答案： 2.5

17. 动作价值更新规则为 $Q(s, a) \leftarrow Q(s, a) + \alpha(r + \gamma \max_{a'} Q(s', a') - Q(s, a))$ ，若 $Q(s, a) = 1, r = 2, \max_{a'} Q(s', a') = 3, \gamma = 0.5, \alpha = 1$ ，更新后的 $Q(s, a) =$ _____。

• 答案： 3.5

18. 折扣回报，设折扣因子为 γ ，学习率为 α 。如无特殊说明，回报定义为 $G_t = \sum_{k=0}^{T-t-1} \gamma^k r_{t+k+1}$ 。已知： $\gamma = 0.9$ ，从时刻 t 起未来 3 步奖励依次为 1, 1, 1。求：回报 $G_t =$ _____。

答案: $G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1} = \gamma^0 r_{t+1} + \gamma^1 r_{t+2} + \gamma^2 r_{t+3} = 1 \cdot 1 + 0.9 \cdot 1 + 0.9^2 \cdot 1 = 1 + 0.9 + 0.81 = 2.71$.

解析: 折扣因子 $\gamma \in (0, 1)$ 使得越往后的奖励权重 γ^k 越小。

19. (Bellman 期望方程: 两状态)

已知: 两状态 A, B , 无动作。转移与奖励:

- 在 A :
 - 以 0.5 转到 A , 得奖 0;
 - 以 0.5 转到 B , 得奖 2。
- 在 B : 必转到 A , 得奖 1。

折扣因子: $\gamma = 0.9$ 。

写出并求解: $V(A), V(B)$ 的 Bellman 期望方程: $V(A) = \underline{\hspace{2cm}}$, $V(B) = \underline{\hspace{2cm}}$ (只需列算式, 不必精确数值)。

答案: (1) 写出方程:

- 对 A : $V(A) = 0.5(0 + V(A)) + 0.5(2 + V(B))$.
- 对 B : $V(B) = 1 + V(A)$.

(2) 代数化简 (列出消元步骤):

将 $V(A)$ 方程展开: $V(A) = 0.5 V(A) + 0.5 \cdot 2 + 0.5 V(B) = 0.5 V(A) + 1 + 0.5 V(B)$.

移项得到: $(1-0.5)V(A) = 1 + 0.5 V(B)$.

再用 $V(B) = 1 + \gamma V(A)$ 代入右侧: $(1-0.5)V(A) = 1 + 0.5(1 + V(A))$.

继续整理: $(1-0.5)V(A) = 1 + 0.5 + 0.5 V(A)$.

把含 $V(A)$ 的项移到左侧: $(1-0.5-0.5)V(A) = 1 + 0.5$.

因此: $V(A) = \frac{1+0.5\gamma}{1-0.5\gamma-0.5\gamma^2}$, $V(B) = 1 + \gamma V(A)$.

(若代入 $\gamma = 0.9$ 可继续算出具体数值, 但本题按要求到此即可。)

解析： Bellman 方程把价值写成“一步期望奖励 + 折扣后的后继状态价值期望”，形成联立方程求解。

20. (动作价值：一步最优)

已知：某状态 s 有两个动作 a_1, a_2 。

- 选 a_1 ：即时奖励 1，转移到 s' ，且 $V(s') = 5$ ；
- 选 a_2 ：即时奖励 3，转移到 s'' ，且 $V(s'') = 2$ ；
- $\gamma = 0.9$ 。

比较：分别计算 $Q(s, a_1) = \underline{\hspace{2cm}}$ 、 $Q(s, a_2) = \underline{\hspace{2cm}}$ 。

答案： 计算过程（算式）：

动作价值定义（已知后继价值）：\$ $Q(s,a)=r(s,a) + \gamma V(s_{next})$. \$

因此 \$ $Q(s,a_1) = 1 + \gamma V(s') = 1 + 0.9 \times 5$, $Q(s,a_2) = 3 + \gamma V(s'') = 3 + 0.9 \times 2$. \$

比较并选取：\$ 若 $Q(s,a_1) > Q(s,a_2)$ 则选 a_1 ； 否则选 a_2 . \$

解析： 即时奖励更大不一定最优，关键在于折扣后的长期价值（后继状态价值）。

21. 在确定性环境中，若 $Q(s, a) = 1 + 0.5V(s') = 7$ ，则 $V(s') = \underline{\hspace{2cm}}$ 。 答案： 12

22. (TD(0) 更新：状态价值)

已知：当前估计 $V(s) = 2.0$ ；采样到 $r = 1$ 、下一状态 s' 满足 $V(s') = 3.0$ ； $\gamma = 0.9$ ， $\alpha = 0.1$ 。

用 TD(0) 更新一次：更新后的 $V(s) = \underline{\hspace{2cm}}$ 。

答案：

TD(0) 目标 (target)：\$ $\text{Target} = r + V(s')$. \$

TD 误差 (TD error)：\$ $\delta = \text{Target} - V(s) = (r + V(s')) - V(s)$. \$

更新公式：\$ $V(s) \leftarrow V(s) + \alpha \delta = V(s) + \alpha (r + V(s') - V(s))$. \$

把题目数值代入到“算式层面”： $V(s) \leftarrow 2.0 + 0.1(1 + 0.9 \cdot 3.0 - 2.0) = 2.17$.
\$

解析：TD 用一步样本估计并通过自举 (bootstrapping) 利用 $V(s')$ 修正 $V(s)$ 。

23. (MC 估计：均值回报)

已知：同一状态-动作对 (s, a) 在 3 次完整情节中得到回报分别为 5, 1, 4。

用 MC 平均估计： $\widehat{Q}(s, a) = \underline{\hspace{2cm}}$ 。

答案：

蒙特卡洛估计 (样本均值)： $\widehat{Q}(s, a) = \frac{1}{N} \sum_{i=1}^N G^{(i)}$.

此处 $N = 3$, $G^{(1)} = 5, G^{(2)} = 1, G^{(3)} = 4$, 因此 $\widehat{Q}(s, a) = \frac{5+1+4}{3} = \frac{10}{3}$.

解析：MC 直接用完整回报做期望估计，一般无偏但可能方差较大。

24. (Sarsa 一次更新)

已知： $Q(s, a) = 1.5$ 。执行 a 得到 $r = 2$ 到达 s' ，并按当前策略在 s' 选到 a' ，此时 $Q(s', a') = 1.0$ 。 $\gamma = 0.9, \alpha = 0.2$ 。

更新后： $Q(s, a) = \underline{\hspace{2cm}}$ 。

答案： 计算过程 (算式)：

Sarsa 的 TD 目标： $\text{Target}_{\{\text{Sarsa}\}} = r + Q(s', a')$. \$

Sarsa 更新公式： $Q(s, a) \leftarrow Q(s, a) + (\text{Target}_{\{\text{Sarsa}\}} - Q(s, a))$. \$

代入本题： $Q(s, a) \leftarrow 1.5 + 0.2(2 + 0.9 \cdot 1.0 - 1.5) = 1.68$. \$

解析：Sarsa 使用“实际在 s' 采取的动作 a' ”作为下一步估计 (On-policy)。

25. (值迭代：一步更新)

某状态 s 有两个动作：

- a_1 ：以 1 转移到 s_1 ，即时奖励 0；
- a_2 ：以 1 转移到 s_2 ，即时奖励 1。

已知当前 $V(s_1) = 4, V(s_2) = 2, \gamma = 0.5$ 。

用一次“最优 Bellman 备份”更新 $V_{\text{new}}(s) = \max_a [r(s, a) + \gamma V(s')]$ 并给出新的状态价值 $V_{\text{new}}(s) = \underline{\hspace{2cm}}$ 。

答案： 计算过程（算式）：

- 对 a_1 : $Q_{\text{backup}}(s, a_1) = r(s, a_1) + \gamma V(s_1) = 0 + 0.5 \cdot 4 = 2$
- 对 a_2 : $Q_{\text{backup}}(s, a_2) = r(s, a_2) + \gamma V(s_2) = 1 + 0.5 \cdot 2 = 2$

因此 $V_{\text{new}}(s) = \max\{0 + 0.5 \cdot 4, 1 + 0.5 \cdot 2\} = \max\{2, 2\} = 2$ 。

解析：值迭代的核心操作就是对每个状态做一次“最优备份”（对动作取最大）。

26. (策略评估：给定策略的期望)

在状态 s , 策略以 0.7 选 a_1 、以 0.3 选 a_2 。已知 $Q(s, a_1) = 10, Q(s, a_2) = 0$ 。

则 $V^\pi(s) = \underline{\hspace{2cm}}$ 。

答案： 计算过程（算式）：

策略下的状态价值是对动作价值的期望： $V^\pi(s) = \sum_a \pi(a|s) Q(s, a)$ 。

代入： $V^\pi(s) = 0.7 Q(s, a_1) + 0.3 Q(s, a_2) = 0.7 \cdot 10 + 0.3 \cdot 0 = 7$ 。

解析：给定策略时， $V^\pi(s)$ 等于“按策略概率加权”的平均动作价值。

27. (“只利用”的陷阱：期望回报比较)

方案 A：每步稳定拿 1 分，持续 100 步，总回报（不折扣）为 $G_A = \underline{\hspace{2cm}}$ ；方案 B：前 10 步回报为 0，之后一次性拿 150 分并结束，总回报为 $G_B = \underline{\hspace{2cm}}$ 。

答案： 计算过程（算式）：

- 方案 A（逐步累加）： $G_A = \sum_{t=1}^{100} 1 = 100$ 。
- 方案 B（前 10 步为 0 + 末尾一次性）： $G_B = \sum_{t=1}^{10} 0 + 150 = 150$ 。

比较：若 $G_B > G_A$, 则 B 更优; 反之 A 更优。

解析：若只“利用”稳定小收益，可能错过需要等待/探索但回报更大的方案。

28. (连续型任务的折扣回报：等比级数)

连续型任务中，每步奖励恒为 1， $\gamma = 0.9$ 。从当前时刻起的无穷折扣回报为 $G = \underline{\hspace{2cm}}$ 。

答案： 计算过程（算式）：

定义：\$ $G = \sum_{k=0}^{\infty} \gamma^k \cdot 1$ \$

这是等比级数（首项 1、公比 γ ），因此 $G = \frac{1}{1-\gamma} = \frac{1}{1-0.9} = 10$ 。

解析：折扣因子 $\gamma < 1$ 使无穷和收敛，从而为 continuing 任务提供良定义的目标。

29. (DP vs 采样：用模型算期望)

已知：在状态 s 采取动作 a ：

- 以 0.6 转到 s_1 得奖 2；
- 以 0.4 转到 s_2 得奖 0。

且 $V(s_1) = 3, V(s_2) = 5, \gamma = 0.5$ 。

计算该动作的期望回报目标 $Q(s, a) = \mathbb{E}[r + \gamma V(s')]$ 并给出 $Q(s, a) = \underline{\hspace{2cm}}$ 。

答案： 计算过程（算式）：

按转移分支做期望：\$ $Q(s, a) = 0.6(2 + V(s_1)) + 0.4(0 + V(s_2)) = 0.6(2 + 0.5 \cdot 3) + 0.4(0 + 0.5 \cdot 5) = 0.6 \cdot 3.5 + 0.4 \cdot 2.5 = 2.1 + 1.0 = 3.1$ \$

解析：该类计算依赖已知的转移概率（模型），属于 DP/模型法可直接算期望的典型形式。

30. (TD 误差)

给定 $V(s) = 4$ ，采样到 $r = 1, V(s') = 6, \gamma = 0.9$ 。求 TD 误差 $\delta = r + \gamma V(s') - V(s)$ 。

答案： 计算过程（算式）： 并给出 $\delta =$ _____。 $\$ = 1 + 0.9 \times 6 - 4 = 2.4$. $\$$

解析： δ 衡量“目标（一步样本 + 自举）与当前估计”的偏差，是参数更新的驱动力。

31. (多步回报与折扣)

$\gamma = 0.8$ ，未来奖励序列为 $[3, -1, 2]$ 。求回报 $\$ G = 3 + 0.8(-1) + 0.8^2(2) = 3.48$. $\$$

答案： 计算过程（算式）： 并给出 $G =$ _____。

逐项写清折扣幂次： $\$ G = 0^0 3 + 0^1 (-1) + 0^2 2 = 1 \times 3 + 0.8 \times (-1) + 0.8^2 \times 2 = 3 - 0.8 + 1.28 = 3.48$. $\$$

解析： 负奖励同样进入累计回报，只是其影响也会随时间距离被折扣。

32. (从 Q 推导贪心策略)

某状态 s 下有 3 个动作， $\$ Q(s, \cdot) = [1.2, 1.2, 0.5]$. $\$$

写出一个贪心策略（文字描述即可）： _____。

答案：

答案（策略描述）：

贪心策略选择使 $Q(s, a)$ 最大的动作集合： $\arg \max_a Q(s, a) = \{a_1, a_2\}$.

因此可取任意一种等价表述：

- 确定性贪心：总是选 a_1 （或总是选 a_2 ）；
- 并列随机贪心：在 a_1, a_2 中均匀随机选一个，即 $\pi(a_1 | s) = 0.5$, $\pi(a_2 | s) = 0.5$, $\pi(a_3 | s) = 0$.

解析： 贪心只依赖相对大小；出现并列最大时，需要指定 tie-breaking 规则。

33. (DQN 的直观替代关系)

表格法中 Q 表大小约为 $|\mathcal{S}| \times |\mathcal{A}|$ 。若 $|\mathcal{S}| = 10^6$, $|\mathcal{A}| = 10$ ，问表格需要存多少个数（数量为 _____ 个），并解释为何更倾向用函数逼近。

答案： 计算过程（算式）：

表格中每个 (s, a) 需要存一个数，因此存储数量为 $|\mathcal{S}| \cdot |\mathcal{A}| = 10^6 \cdot 10 = 10^7$.

解析：

- 状态空间大时，表格存储规模随 $|\mathcal{S}|$ 线性爆炸，内存与数据需求都巨大；
- 表格法对未见状态无法泛化；
- 函数逼近（如 DQN 的神经网络 $Q(s, a; \theta)$ ）用共享参数表示大量状态，能对相似状态泛化，并显著降低显式存表开销。

34. 在一个简单的 MDP 中，智能体在 t 时刻获得即时奖励 $R_{t+1} = 2$ ，在 $t+1$ 时刻获得奖励 $R_{t+2} = 4$ ，之后游戏结束（后续奖励为 0）。设折扣因子 $\gamma = 0.5$ 。则 t 时刻的回报 $G_t = \underline{\hspace{2cm}}$ 。

解析： $G_t = 2 + 0.5 \times 4 + 0 = 2 + 2 = 4$

答案： 4

35. 在一个简单的 MDP 中，设当前状态为 s_1 ，即时奖励 $R(s_1) = 1$ ，折扣因子 $\gamma = 0.9$ 。从 s_1 出发有 100% 的概率转移到 s_2 ，且已知 $V(s_2) = 10$ 。则 $V(s_1) = \underline{\hspace{2cm}}$ 。

解析： $V(s_1) = 1 + 0.9 \times (1.0 \times 10) = 1 + 9 = 10$

答案： 10

36. 在一个简单的 MDP 中，考虑状态 s ，智能体采取动作 a 。环境有 0.8 的概率转移到 s_{win} ($V(s_{win}) = 10$)，有 0.2 的概率转移到 s_{lose} ($V(s_{lose}) = -5$)。该步的即时奖励为 0。折扣因子 $\gamma = 1.0$ 。则动作价值 $Q(s, a) = \underline{\hspace{2cm}}$ 。

解析： $Q(s, a) = 0.8 \times 10 + 0.2 \times (-5) = 8 - 1 = 7$

答案： 7

37. 在一个简单的 MDP 中，在一个有 4 个可选动作 ($|\mathcal{A}| = 4$) 的状态下，智能体使用 ϵ -greedy 策略，设定 $\epsilon = 0.2$ 。假设其中一个动作

是贪婪（最优）动作。则智能体选中该最优动作的概率为： $P(a^*) = (1 - \epsilon) + \frac{\epsilon}{|A|} = \underline{\hspace{2cm}}$

解析： $P(a^*) = (1 - 0.2) + \frac{0.2}{4} = 0.8 + 0.05 = 0.85$

答案：0.85

38. 考虑一个无限视界的 MDP。某状态 s 的即时奖励为 $R = 10$ ，且智能体以 100% 的概率再次回到状态 s （自循环）。设折扣因子 $\gamma = 0.9$ 。则该状态的价值 $V(s) = \underline{\hspace{2cm}}$ 。

解析：这是一个几何级数求和（无穷等比数列）： $V(s) = \frac{10}{1-0.9} = \frac{10}{0.1} = 100$

答案：100

39. 在一个简单的 MDP 中， ϵ -greedy 策略下 ($\epsilon = 0.2$) 设有 4 个动作。若当前 $Q(s, a)$ 值分别为： $a_1 : 2.5$, $a_2 : 3.0$, $a_3 : 3.0$, $a_4 : 1.0$ 。假设贪婪策略在最大值动作中均匀分配概率。则动作 a_2 被选中的总概率为： $P(a_2) = \underline{\hspace{2cm}}$

解析：

40. 随机探索部分贡献： $0.2/4 = 0.05$ 。

41. 贪婪利用部分贡献： $1 - 0.2 = 0.8$ 。

42. 因为 a_2 和 a_3 并列最大，贪婪部分平分： $0.8/2 = 0.4$ 。

43. 总概率： $0.05 + 0.4 = 0.45$ 。

答案：0.45

40. 在一个简单的 MDP 中，已知状态 A 和 B 。从 A 出发，有 0.5 概率到 A ($R = 2$)，0.5 概率到 B ($R = 4$)。已知 $V(A) = 12$, $V(B) = 8$ 。则折扣因子 $\gamma = \underline{\hspace{2cm}}$ 。

解析：代入数值： $12 = 0.5(2 + 12\gamma) + 0.5(4 + 8\gamma)$, $12 = 1 + 6\gamma + 2 + 4\gamma$, $12 = 3 + 10\gamma \Rightarrow 9 = 10\gamma \Rightarrow \gamma = 0.9$

答案：0.9

41. 给定两状态 MDP: s_1, s_2 。策略 π : 在 s_1 总是去 s_2 ($R = 0$); 在 s_2 总是去 s_1 ($R = 1$)。设 $\gamma = 0.9$ 。则 $V(s_1) =$ _____ (保留 2 位小数)。

解析: 将 (2) 代入 (1): $V(s_1) = 0.9(1 + 0.9V(s_1)) = 0.9 + 0.81V(s_1)$, $V(s_1)(1 - 0.81) = 0.9$, $0.19V(s_1) = 0.9 \Rightarrow V(s_1) = \frac{0.9}{0.19} \approx 4.736$

答案: 4.74

42. 在 Q-learning 中。 $Q(s, a)_{old} = 4$ 。采样数据: $(s, a, r = 2, s')$ 。在 s' 状态下, 有两个动作 a'_1, a'_2 , 其 Q 值分别为 3, 5。学习率 $\alpha = 0.5$, $\gamma = 0.8$ 。更新后的 $Q(s, a)_{new} =$ _____。

答案: 5

解析: Q-learning 使用 $\max Q(s', a')$ 作为目标: $\text{Target} = r + \gamma \max(3, 5) = 2 + 0.8 \times 5 = 6$ $Q_{new} = Q_{old} + \alpha(\text{Target} - Q_{old}) = 4 + 0.5(6 - 4) = 4 + 1 = 5$

43. 在一个简单的 MDP 中, 状态空间为 5×5 的棋盘。智能体在边界 $(0, 0)$ 尝试向左走 (无效移动), 即时奖励 $R = -1$, 状态保持 $(0, 0)$ 。设 $V(0, 0) = 10, \gamma = 0.9$ 。该动作的 $Q((0, 0), \text{Left}) =$ _____。

解析: $Q = -1 + 0.9 \times 10 = -1 + 9 = 8$

答案: 8

44. 在一个有限视界的 RL 任务中, 智能体接下来的 3 步奖励分别为 $R_{t+1} = 10, R_{t+2} = 0, R_{t+3} = 20$, 之后任务终止 (后续奖励为 0)。设折扣因子 $\gamma = 0.5$ 。则当前 t 时刻的回报 $G_t =$ _____。

解析: $G_t = 10 + 0.5 \times 0 + 0.5^2 \times 20 = 10 + 0 + 0.25 \times 20 = 10 + 5 = 15$

答案: 15

45. 在一个简单的 MDP 中, 已知某状态 s 下有两个动作 $\{a_1, a_2\}$ 。智能体采用随机策略 π , 其中选择 a_1 的概率为 0.8, 选择 a_2 的概率为 0.2。已知动作价值函数 $Q^\pi(s, a_1) = 10, Q^\pi(s, a_2) = 5$ 。则该策略下的状态价值 $V^\pi(s) = \sum_a \pi(a|s)Q^\pi(s, a) =$ _____。

解析: $\$ \hat{V}(s) = 0.8 \times 10 + 0.2 \times 5 = 8 + 1 = 9 \$$

答案: 9

46. 在一个简单的 MDP 中, ϵ -greedy 策略有 4 个动作 ($|A| = 4$), $\epsilon = 0.4$ 。假设当前 Q 值最大的动作有两个, 贪婪策略在它们之间均匀随机选择。则其中某一个最优动作被选中的总概率为 _____。

解析: 1. 随机探索贡献: $\frac{0.4}{4} = 0.1$

2. 贪婪利用贡献: $(1 - 0.4) \times \frac{1}{2} = 0.6 \times 0.5 = 0.3$

3. 总概率: $0.1 + 0.3 = 0.4$

答案: 0.4

47. 在一个简单的 MDP 中, 已知状态 s 下有两个动作 a_1, a_2 。 a_1 导致状态 s 转移到 s_1 ($V^*(s_1) = 20$), 奖励 $R = 2$ 。 a_2 导致状态 s 转移到 s_2 ($V^*(s_2) = 10$), 奖励 $R = 8$ 。 设 $\gamma = 0.5$ 。 则最优状态价值 $V^*(s) = \underline{\hspace{2cm}}$ 。

解析: $Q(s, a_1) = 2 + 0.5 \times 20 = 12$ $Q(s, a_2) = 8 + 0.5 \times 10 = 13$ $V^*(s) = \max(12, 13) = 13$

答案: 13

48. 在一个简单的 MDP 中, 状态 A 总是转移到 B , 奖励 $R = 10$; 状态 B 总是转移回 A , 奖励 $R = 0$ 。 设 $\gamma = 0.5$ 。 则 $V(A) = \underline{\hspace{2cm}}$ (保留 2 位小数)。

解析: 将 $V(B)$ 代入 $V(A)$: $V(A) = 10 + 0.5(0.5V(A)) = 10 + 0.25V(A)$

$0.75V(A) = 10 \implies V(A) = \frac{10}{0.75} = \frac{40}{3} \approx 13.33$

答案: 13.33

49. 在一个简单的 MDP 中, 在状态 s 采取动作 a , 有 0.5 的概率转移到 s_{win} ($V = 100$), 有 0.5 的概率转移到 s_{lose} ($V = 0$)。 该步即时奖励 $R = 0$, $\gamma = 0.9$ 。 则 $Q(s, a) = \underline{\hspace{2cm}}$ 。

解析: $Q(s, a) = 0 + 0.9 \times (0.5 \times 100 + 0.5 \times 0) = 0.9 \times 50 = 45$

答案： 45

50. 在一个简单的 MDP 中，对于状态 s ，智能体采样了两条轨迹，计算出的累积回报分别为 $G_1 = 100$ 和 $G_2 = 90$ 。则当折扣因子为 $\gamma = 0.9$ 时，基于这两次采样的 $V(s)$ 估计值为 _____。

解析：取平均值： $(100 + 90)/2 = 95$ 。

答案： 95

51. 已知在无限视界的自循环 RL 任务中， $\gamma = 0.5$ ，状态价值稳定在 $V(s) = 20$ 。则该状态每一步获得的即时奖励 $R =$ _____。

解析： $V = \frac{R}{1-\gamma} \Rightarrow 20 = \frac{R}{0.5} \Rightarrow R = 10$

答案： 10

52. 在一个简单的 MDP 中，状态 s 有两个动作 L, R 。策略 $\pi(L|s) = 0.8, \pi(R|s) = 0.2$ 。已知 $Q(s, L) = 10, Q(s, R) = 5$ 。则 $V^\pi(s) =$ _____。

解析： $0.8 \times 10 + 0.2 \times 5 = 8 + 1 = 9$

答案： 9

53. 在 Q-learning 更新中，若设置学习率 $\alpha = 1.0$ （最大值）。旧值 $Q(s, a) = 0$ ，目标值 Target = 10。则更新后的 $Q(s, a) =$ _____。

解析：当 $\alpha = 1$ 时， $Q_{new} = Q_{old} + 1.0 \times (\text{Target} - Q_{old}) = \text{Target}$ 。即完全覆盖旧值。

答案： 10

54. 在一个情节型任务中，智能体从 $t = 0$ 时刻开始，连续三步获得的奖励分别为 $R_1 = 5, R_2 = 10, R_3 = 20$ ，随后进入终止状态。若折扣因子 $\gamma = 0.5$ ，计算起始时刻的回报 G_0 为 _____。

公式提示： $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$

答案： 15

解析: $G_0 = 5 + 0.5 \times 10 + 0.5^2 \times 20 = 5 + 5 + 5 = 15$

55. 对于一个永不停止的连续型任务, 若智能体每一步都能获得恒定的奖励 $R = 3$, 且折扣因子 $\gamma = 0.7$ 。该状态的长期累积期望回报为 _____。

公式提示: $G = \frac{R}{1-\gamma}$

答案: 10

解析: $G = 3/(1 - 0.7) = 3/0.3 = 10$

56. 智能体在状态 s 下有两个等概率 (各 0.5) 采取的动作。动作 a_1 的价值 $Q(s, a_1) = 14$, 动作 a_2 的价值 $Q(s, a_2) = 6$ 。则该状态的状态价值 $V(s)$ 为 _____。

公式提示: $V(s) = \sum_a \pi(a|s)Q(s, a)$

答案: 10

解析: $V(s) = 0.5 \times 14 + 0.5 \times 6 = 7 + 3 = 10$

57. 在一次时序差分 (TD) 学习中, 已知 $V(S_t) = 10$, 观察到奖励 $R_{t+1} = 2$ 及下一状态估计值 $V(S_{t+1}) = 12$ 。设 $\gamma = 0.5$, 则该步的 TD 目标值 (TD Target) 为 _____。

公式提示: $Target = R_{t+1} + \gamma V(S_{t+1})$

答案: 8

解析: $Target = 2 + 0.5 \times 12 = 2 + 6 = 8$

58. 承接上题, 若学习率 $\alpha = 0.2$, 使用 TD 更新公式更新后的 $V(S_t)$ 为 _____。

公式提示: $V(S_t) \leftarrow V(S_t) + \alpha[Target - V(S_t)]$

答案: 9.6

解析: $V_{new} = 10 + 0.2 \times (8 - 10) = 10 - 0.4 = 9.6$

59. 已知最优动作价值分别为 $Q^*(s, up) = 4.5, Q^*(s, down) = 5.2, Q^*(s, left) = 1.0$ 。根据最优价值定义, 该状态的最优状态价值 $V^*(s)$ 为 _____。

答案: 5.2

解析: $V^*(s) = \max_a Q^*(s, a)$, 即所有动作价值中的最大值。

47. 在 ϵ -greedy 策略中, 若 $\epsilon = 0.1$, 动作空间大小为 10。智能体在探索时 (非贪婪模式) 选择具体某一个非最优动作的概率为 _____。

答案: 0.01

解析: 总探索概率为 0.1, 平分给 10 个动作, 即 $0.1/10 = 0.01$ 。

60. 某智能体在 $t = 0$ 时刻预测未来的回报。它得知在 $t = 2$ 时刻 (即两步后) 将获得唯一一次奖励 $R_2 = 100$ 。若 $\gamma = 0.9$, 该奖励对 $t = 0$ 时刻的回报贡献是 _____。

答案: 81

解析: $G_0 = \gamma^2 R_2 = 0.9^2 \times 100 = 0.81 \times 100 = 81$

61. 马尔可夫决策过程 (MDP) 由五元组 (S, A, P, R, γ) 组成。若状态转移矩阵 P 中, 从 s 转移到所有可能 s' 的概率之和不等于 1, 说明该模型违反了 _____。

答案: 概率公理 (或状态转移概率定义)

解析: 概率分布的总和必须为 1。

62. 在 Q-Learning 更新中, 若 $\gamma = 1, \alpha = 0.5$, 当前 $Q(s, a) = 10$, 动作后获得奖励 $R = 5$, 且 s' 状态下最大的 Q 值为 15。更新后的 $Q(s, a)$ 为 _____。

答案: 15

解析: $Target = 5 + 1 \times 15 = 20$ $Q_{new} = 10 + 0.5 \times (20 - 10) = 10 + 5 = 15$

63. 已知 $V(s) = R(s, a) + \gamma \sum_{s'} P(s'|s, a) V(s')$ 。若 $\gamma = 0.8$, 在状态 s 采取动作 a 后必然转移到状态 s_{next} (奖励为 2), 且 $V(s_{next}) = 5$ 。则 $Q(s, a)$ 的值为 _____。

答案： 6

解析： $Q(s, a) = 2 + 0.8 \times 5 = 2 + 4 = 6$

64. 若一个 MDP 任务只有即时奖励 (Short-term Reward)，完全不关心未来，则折扣因子 γ 应设为 _____。

答案： 0

解析： $\gamma = 0$ 时，回报 $G_t = R_{t+1}$ 。

65. 在一个 4 动作选择任务中，使用 Softmax 策略。若各动作的偏好值 (Preference) 相等，则选择动作 1 的概率为 _____。

答案： 0.25

解析： 偏好值相等时，Softmax 退化为均匀分布。

66. 智能体执行策略 π 。在状态 s 下， $Q^\pi(s, a_1) = 2, Q^\pi(s, a_2) = 4, Q^\pi(s, a_3) = 6$ 。已知 $\pi(a_1|s) = 0.5, \pi(a_2|s) = 0.5, \pi(a_3|s) = 0$ 。则 $V^\pi(s)$ 为 _____。

答案： 3

解析： $0.5 \times 2 + 0.5 \times 4 + 0 \times 6 = 1 + 2 = 3$

67.DQN 使用经验回放 (Experience Replay) 来打破数据之间的 _____ 性。

答案： 相关 (或时间相关)

解析： 相邻样本具有高度相关性，随机采样可使其符合独立同分布假设。

68. 若状态 s 为终止状态，则其状态价值 $V(s)$ 恒等于 _____。

答案： 0

解析： 终止状态后不再产生奖励，根据定义其价值为 0。

69. 在蒙特卡洛 (MC) 方法中，若一个情节长度为 100，每步奖励均为 1， $\gamma = 1$ 。则 G_0 的值为 _____。

答案： 100

解析： $1 \times 100 = 100$ 。

70. 若 TD 误差 $\delta = 0$ ，这意味着当前的状态价值估计与实际观察到的单步回报及下一时刻预估值之和达到 _____。

答案： 平衡（或一致）

解析： $\delta = 0$ 表示 $V(S_t) = R_{t+1} + \gamma V(S_{t+1})$ 。

71. 在 $\epsilon = 0.2$ 的贪婪策略中，如果动作空间有 2 个动作，智能体选择最优动作的概率是 _____。

答案： 0.9

解析： 利用概率 $1 - \epsilon = 0.8$ ，探索概率 $0.2/2 = 0.1$ 。总概率 $= 0.8 + 0.1 = 0.9$ 。

72. 某环境包含两个状态 A 和 B 。从 A 采取动作移动，有 0.8 概率到达 B （奖励 10），0.2 概率回到 A （奖励 -5）。已知 $V(B) = 10, V(A) = 0, \gamma = 1$ 。此时动作 a 的动作价值 $Q(A, a)$ 为 _____。

答案： 15

解析： $Q(A, a) = 0.8 \times (10 + 10) + 0.2 \times (-5 + 0) = 16 - 1 = 15$

673. 已知状态 s 有两个动作： a_1 收益确定为 5； a_2 有 50% 概率收益为 12，50% 概率收益为 0。若智能体是风险中性的（只追求期望最大化）且 $\gamma = 0$ ，它应该选择动作 _____。

答案： a_2

解析： $E[R|a_1] = 5$ ； $E[R|a_2] = 0.5 \times 12 + 0.5 \times 0 = 6$ 。因为 $6 > 5$ ，选 a_2 。

74. 在一个 10x10 的网格世界中，所有非终止状态的即时奖励 $R = -1$ 。若智能体陷入了死循环（在两个状态间不断跳跃），且折扣因子 $\gamma = 1$ ，其累积回报 G 会变为 _____。

答案： 负无穷

解析： -1 的无穷级数求和。

75. 在 Sarsa 算法更新中, 已知 $Q(S_t, A_t) = 2, R_{t+1} = 1, Q(S_{t+1}, A_{t+1}) = 4$ 。若 $\gamma = 0.5, \alpha = 0.5$, 更新后的 $Q(S_t, A_t)$ 为 _____。

公式提示: $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha[R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)]$

答案: 2.5

解析: $Target = 1 + 0.5 \times 4 = 3 \quad Q_{new} = 2 + 0.5 \times (3 - 2) = 2.5$

76. 对于状态序列 $S \rightarrow S' \rightarrow Terminate$, 奖励分别为 $R_{t+1} = 2, R_{t+2} = 4$ 。如果使用 $n = 2$ 的多步 TD 方法 (2-step TD), 其目标值 $G_{t:t+2}$ 的计算表达式 (带入具体数字, $\gamma = 0.5$) 为 _____。

公式提示: $G_{t:t+n} = R_{t+1} + \gamma R_{t+2} + \dots + \gamma^n V(S_{t+n})$

答案: 4

解析: 由于 S_{t+2} 是终止状态, $V(S_{t+2}) = 0$ 。因此 $G = 2 + 0.5 \times 4 + 0.5^2 \times 0 = 2 + 2 = 4$ 。

66. 在一个情节型任务中, 智能体从 $t = 0$ 时刻开始, 连续三步获得的奖励分别为 $R_1 = 2, R_2 = 2, R_3 = 2$, 随后进入终止状态。若折扣因子 $\gamma = 0.5$, 计算起始时刻的回报 G_0 为 _____。

公式提示: $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$

答案: 3.5

解析: $G_0 = 2 + 0.5 \times 2 + 0.5^2 \times 2 = 2 + 1 + 0.5 = 3.5$

77. 对于一个永不停止的连续型任务, 若智能体每一步都能获得恒定的奖励 $R = 5$, 且折扣因子 $\gamma = 0.9$ 。该状态的长期累积期望回报为 _____。

公式提示: $G = \frac{R}{1-\gamma}$

答案: 50

解析: $G = 5/(1 - 0.9) = 5/0.1 = 50$

78. 已知回报的递归关系 $G_t = R_{t+1} + \gamma G_{t+1}$ 。若 $R_{t+1} = -1, G_{t+1} = 10$, 折扣因子 $\gamma = 0.9$, 则 G_t 为 _____。

公式提示: $G_t = R_{t+1} + \gamma G_{t+1}$

答案: 8.0

解析: $G_t = -1 + 0.9 \times 10 = -1 + 9 = 8.0$

79. 已知在状态 s 下, 动作 a_1 的即时奖励为 0, 转移到状态 s_1 的价值 $V(s_1) = 10$; 动作 a_2 的即时奖励为 3, 转移到状态 s_2 的价值 $V(s_2) = 4$ 。若折扣因子 $\gamma = 0.8$, 则最优动作是 _____。

答案: a_1

解析: $Q(s, a_1) = 0 + 0.8 \times 10 = 8.0$ $Q(s, a_2) = 3 + 0.8 \times 4 = 3 + 3.2 = 6.2$
因为 $8.0 > 6.2$, 所以最优动作是 a_1 。